

بسم الله الرحمن الرحيم

دانشگاه صنعتی شریف
دانشکده مهندسی برق

پایان نامه کارشناسی ارشد
گرایش مخابرات سیستم

عنوان

بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از
یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون

نگارش

نوید رزاقی

استاد راهنما

دکتر بابک خلج

تیر ۱۴۰۵

به نام خدا
دانشگاه صنعتی شریف
دانشکده مهندسی برق

پایان نامه کارشناسی ارشد

عنوان: بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون

نگارش: نوید رزاقی

کمیته ممتحنین:

استاد راهنما: دکتر بابک خلج
امضا:

استاد مدعو داخلی:
امضا:

استاد مدعو خارجی:
امضا:

تاریخ دفاع:

تقدیم به پدر و مادر عزیزم

که بودنشان، پشتوانه هر گام این مسیر بود.

پیشگفتار

رانندگی خودران در یک دهه اخیر از یک آرزوی دور به یکی از فعال‌ترین حوزه‌های پژوهشی در تقاطع یادگیری ماشین، بینایی ماشین و مهندسی کنترل تبدیل شده است. با وجود پیشرفت‌های چشمگیر، اطمینان‌پذیری این سامانه‌ها در شرایط دشوار محیطی همچنان یک پرسش باز است و همین پرسش، انگیزه اصلی شکل‌گیری پژوهش حاضر بود.

این پایان‌نامه حاصل نزدیک به دو سال مطالعه و آزمایش در زمینه یادگیری چندوجهی برای رانندگی خودران انتها-به-انتها است. امید است نتایج آن برای پژوهشگران این حوزه سودمند باشد و گامی هرچند کوچک در مسیر توسعه سامانه‌های حمل‌ونقل هوشمند و ایمن بردارد.

نوید رزاقی

تیر ۱۴۰۵

قدردانی و تشکر

در آغاز، از استاد راهنمای گران‌قدرم، جناب آقای دکتر بابک خلج، که با راهنمایی‌های دقیق، صبورانه و عالمانه خود مسیر این پژوهش را روشن کردند، صمیمانه سپاسگزارم. نگاه نقادانه و پرسش‌های راه‌گشای ایشان در جلسات متعدد، نقشی تعیین‌کننده در شکل‌گیری چارچوب نظری و عملی این پایان‌نامه داشت. همچنین از اعضای محترم کمیته‌ممتحنین که با دقت نظر خود بر غنای این نوشته افزودند و از دوستان و هم‌دوره‌ای‌هایم در دانشکده مهندسی برق دانشگاه صنعتی شریف که در بحث‌های علمی همراه من بودند، قدردانی می‌کنم. در پایان، از خانواده عزیزم که در تمام مراحل تحصیل پشتیبان بی‌دریغ من بودند، سپاسگزارم.

بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون

چکیده

طراحی سامانه‌های رانندگی خودران^۱ در سال‌های اخیر از رویکردهای ماژولار سنتی به سمت معماری‌های یادگیری انتها-به-انتها^۲ متمایل شده‌است؛ معماری‌هایی که با دریافت مستقیم داده‌های خام حسگرها، خروجی کنترلی تولید می‌کنند و کل سامانه را به صورت سراسری بهینه می‌سازند. با این حال، وابستگی بسیاری از این سامانه‌ها به یک منبع داده منفرد مانند دوربین، استواری^۳ آنها را در شرایط جوی نامساعد و سناریوهای نادر به شدت کاهش می‌دهد. هدف این پژوهش، بهبود عملکرد و استواری رانندگی خودران انتها-به-انتها از طریق یادگیری چندوجهی^۴ و ترکیب بهینه اطلاعات حسگرهای ناهمگون دوربین و لیدار^۵ است.

در این پایان‌نامه یک معماری نوین مبتنی بر ترنسفورمر^۶ با نام EGCA پیشنهاد می‌شود که سه مؤلفه اصلی دارد: نخست، یک ماژول ترکیب میانی مبتنی بر توجه متقابل^۷ دوسویه که ویژگی‌های معنایی تصویر و ویژگی‌های هندسی نمای پرنده^۸ لیدار را در هم می‌آمیزد؛ دوم، به کارگیری توجه خطی^۹ هسته‌محور که پیچیدگی محاسباتی ترکیب را از مرتبه دوم به مرتبه خطی نسبت به تعداد نشانه‌ها

¹ Autonomous Driving

² End-to-End

³ Robustness

⁴ Multimodal Learning

⁵ LiDAR

⁶ Transformer

⁷ Cross-Attention

⁸ Bird's-Eye View

⁹ Linear Attention

کاهش می‌دهد؛ و سوم، یک سازوکار دروازه اطمینان حسگر^{۱۰} به همراه راهبرد آموزش حذف تصادفی حسگر^{۱۱} که شبکه را در برابر افت کیفیت یا قطع کامل یک حسگر مقاوم می‌کند. مدل پیشنهادی با یادگیری تقلیدی از یک خبره ممتاز در شبیه ساز CARLA آموزش داده شد و روی مجموعه مسیرهای استاندارد Longest6 ارزیابی شد.

مدل روی همان مجموعه داده منتشرشده‌ای آموزش دید که روش‌های مرجع با آن آموزش دیده‌اند و با ارزیاب و پروتکل ترافیکی رسمی همان محک سنجیده شد؛ افزون بر آن، عامل ممتاز مرجع از درون همین زنجیره ارزیابی اجرا شد تا درستی ابزار اندازه‌گیری در برابر یک مقدار منتشرشده بیرونی راستی‌آزمایی شود. نتایج نشان می‌دهد روش پیشنهادی به امتیاز راندگی ۵۵٫۸ دست می‌یابد که در محدوده مقایسه‌پذیر با مقادیر گزارش شده روش‌های پیشرفته قرار دارد. تأکید می‌شود که خط‌مبناهای بیرونی در این پژوهش بازآموزی و اجرا نشده‌اند و اعدادشان نقل شده است؛ از این رو ادعای برتری آماری بر آنها مطرح نمی‌شود و استدلال‌های معنادار این پژوهش بر مقایسه‌های درونی استوارند، جایی که همه پیکربندی‌ها در یک زنجیره و با یک بذر اجرا شده‌اند.

در مقایسه با «همین معماری» با توجه کامل، دقت از نظر آماری هم‌ارز است در حالی که هزینه محاسباتی مازول ترکیب ۴۰ درصد و تأخیر پردازش کل شبکه ۱۳ درصد کمتر می‌شود، و مدل با ۲۷٫۹ میلیون پارامتر کوچک‌ترین مدل چندوجهی جدول مقایسه است. در شرایط باران شدید و مه، افت عملکرد مدل پیشنهادی کمتر از نصف افت مدل تک‌حسگری مبتنی بر دوربین است، و در سناریوی قطع ۵۰ درصدی فریم‌های لیدار، امتیاز آن در برابر گونه آموزش دیده بدون دروازه و بدون حذف تصادفی حسگر به مراتب بهتر حفظ می‌شود و هیچ‌گاه از سطح مدل دوربین-تنها پایین‌تر نمی‌رود. این نتایج نشان می‌دهد ترکیب آگاه از اطمینان حسگرها، مسیری مؤثر برای دستیابی هم‌زمان به دقت، کارایی محاسباتی و استواری است.

واژه‌های کلیدی:

¹⁰ Sensor-Reliability Gating

¹¹ Sensor Dropout

رانندگی خودران، یادگیری انتها-به-انتها، یادگیری چندوجهی، ترکیب اطلاعات حسگرها، ترنسفورمر، توجه متقابل، استواری

فهرست مطالب

صفحه

1	مقدمه	1
1.1	انگیزه پژوهش	2
2.1	تعریف مسئله	3
3.1	پیشینه پژوهش	4
4.1	اهداف و نوآوری‌ها	4
5.1	محتوای گزارش	5
2	پیشینه پژوهش	6
1.2	گذار از معماری ماژولار به انتها-به-انتها	6
1.1.2	معماری ماژولار و محدودیت‌های آن	6
2.1.2	یادگیری انتها-به-انتها	7
2.2	یادگیری چندوجهی و ترکیب اطلاعات حسگرها	7
1.2.2	راهبردهای ترکیب اطلاعات	8
2.2.2	ترکیب در فضای نمای پرنده	9
3.2	معماری‌های مبتنی بر توجه در راندگی انتها-به-انتها	10
4.2	مجموعه داده‌ها و بسترهای ارزیابی	11
5.2	خلاهای تحقیقاتی و جمع‌بندی	12
3	مبانی نظری و فرمول‌بندی مسئله	13
1.3	فرمول‌بندی مسئله راندگی انتها-به-انتها	13
2.3	استخراج ویژگی از تصویر	15
3.3	استخراج ویژگی از ابر نقاط لیدار	15
4.3	سازوکار توجه	16
1.4.3	توجه ضرب داخلی مقیاس‌شده	17
2.4.3	توجه چندسره	17
3.4.3	توجه متقابل بین‌وجهی	18
4.4.3	پیچیدگی محاسباتی و توجه خطی	18
5.4.3	رمزگذاری موقعیت	20
5.3	یادگیری چندوظیفه‌ای و توابع هزینه	20
6.3	جمع‌بندی	21

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های راندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

۴	روش پیشنهادی	۲۲
۱.۴	نمای کلی معماری	۲۲
۲.۴	شاخه‌های رمزگذار	۲۳
۱.۲.۴	شاخه دوربین	۲۳
۲.۲.۴	شاخه لیدار	۲۴
۳.۲.۴	رمزگذار حالت خودرو و فرمان ناوبری	۲۴
۳.۴	ماژول ترکیب دروازه‌دار کارآمد (EGCA)	۲۵
۱.۳.۴	توجه متقابل خطی دوسویه	۲۵
۲.۳.۴	دروازه اطمینان حسگر	۲۷
۳.۳.۴	پشته بلوک‌های ترکیب	۲۷
۴.۴	رمزگشای نقاط مسیر	۲۸
۱.۴.۴	خوانش پرسش‌محور: گونه جایگزین رمزگشا	۲۹
۵.۴	کنترل‌کننده‌های سطح پایین	۳۰
۱.۵.۴	خزش: مهار مسئله اینرسی	۳۱
۶.۴	راهبرد آموزش استوار	۳۲
۱.۶.۴	حذف تصادفی حسگر	۳۲
۲.۶.۴	تابع هزینه کل	۳۲
۳.۶.۴	الگوریتم آموزش	۳۳
۷.۴	جمع‌بندی	۳۴
۵	نتایج شبیه‌سازی و ارزیابی	۳۶
۱.۵	بستر آزمایش، داده‌ها و جزئیات پیاده‌سازی	۳۶
۲.۵	معیارهای ارزیابی	۴۳
۳.۵	مقایسه با روش‌های پیشرفته	۴۶
۴.۵	تحلیل استواری	۴۹
۱.۴.۵	استواری در برابر شرایط جوی و روشنایی	۴۹
۲.۴.۵	استواری در برابر اختلال حسگر	۵۱
۵.۵	مطالعه فروگذاری	۵۲
۶.۵	تحلیل هزینه محاسباتی	۵۴
۷.۵	توزیع خطای پیش‌بینی مسیر	۵۶
۸.۵	تحلیل کیفی سازوکار توجه	۵۷
۹.۵	بحث	۵۹
۶	جمع‌بندی و نتیجه‌گیری	۶۱

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

۱.6	خلاصه پژوهش.....	۶۱
۲.6	نوآوری‌های پایان‌نامه.....	۶۲
۳.6	محدودیت‌ها.....	۶۳
۴.6	پیشنهادهای برای ادامه کار.....	۶۴
۶۶	منابع و مراجع.....	
۶۹	واژه‌نامه.....	
۷۱	پیوست‌ها.....	

فهرست اشکال

صفحه

شکل 1.1	مقایسه خط لوله ماژولار و رویکرد انتها-به-انتها.....	۳
شکل 1.2	راهبردهای سه‌گانه ترکیب اطلاعات حسگرها.....	۹
شکل 1.3	رمزگذاری ابر نقاط لیدار به نقشه ویژگی نمای پرده.....	۱۶
شکل 2.3	سازوکار توجه ضرب داخلی مقیاس‌شده و توجه متقابل چندسر.....	۱۸
شکل 1.4	نمای کلی معماری پیشنهادی.....	۲۳
شکل 2.4	ساختار داخلی ماژول ترکیب دروازه‌دار کارآمد (EGCA).....	۲۵
شکل 1.5	منحنی‌های همگرایی آموزش و اعتبارسنجی.....	۴۱
شکل 2.5	مقایسه امتیاز رانندگی و نرخ تکمیل مسیر با روش‌های پیشرفته.....	۴۸
شکل 3.5	امتیاز رانندگی در شرایط مختلف جوی و روشنایی.....	۵۰
شکل 4.5	استواری در برابر نرخ افت فریم لیدار.....	۵۱
شکل 5.5	نتایج مطالعه فروگذاری روی راهبرد ترکیب.....	۵۳
شکل 6.5	مصالحه تأخیر پردازش و امتیاز رانندگی.....	۵۵
شکل 7.5	نقشه‌های توجه ماژول ترکیب در دو شرایط محیطی.....	۵۸

فهرست جداول

صفحه

جدول 1.۲	مقایسه روش‌های شاخص رانندگی انتها-به-انتهای چندوجهی.....	۱۰
جدول 2.۲	مجموعه داده‌های استاندارد رانندگی خودران.....	۱۱
جدول 1.۴	پیکربندی معماری پیشنهادی.....	۳۴
جدول 1.۵	آمار دو مجموعه داده به کاررفته در این پژوهش.....	۳۷
جدول 2.۵	فراپارامترهای آموزش.....	۴۰
جدول 3.۵	پیکربندی حسگرها، یکسان در ثبت داده و در ارزیابی.....	۴۲
جدول 4.۵	عامل ممتاز مرجع، اجراشده در زنجیره ارزیابی این پژوهش (۳۶ مسیر).....	۴۵
جدول 5.۵	مقایسه کمی با روش‌های پیشرفته روی مسیرهای Longest6.....	۴۷
جدول 6.۵	امتیاز رانندگی در شرایط جوی مختلف.....	۴۹
جدول 7.۵	نتایج مطالعه فروگذاری.....	۵۲
جدول 8.۵	هزینه محاسباتی روش‌ها.....	۵۵

فهرست علائم

علائم لاتین

a_t	t بردار فرمان کنترلی در لحظه
D	مجموعه داده آموزشی
b	متغیر برنولی حذف تصادفی حسگر
d	بعد مشترک نشانه‌ها
d_h	d/H بعد هر سر توجه، برابر
d_k, d_v	بعد بردارهای کلید و مقدار
e_m	m نشانه آموختنی «وجه غایب» برای وجه
e_t	خطای سمت در کنترل‌کننده جانبی
F_c, F_l	ویژگی‌های استخراج‌شده از دوربین و لیدار
g_t	ضریب دروازه اطمینان حسگر
H	تعداد سرهای توجه
h_t	بردار حالت نهان رمزگشا
I_t	t تصویر ورودی دوربین در لحظه
K	ماتریس کلیدها در سازوکار توجه
L	تعداد بلوک‌های ماژول ترکیب
$\mathcal{L}$	تابع هزینه
m_t	بردار رمزگذاری حالت خودرو و فرمان ناوبری
N_c, N_l	تعداد نشانه‌های تصویر و لیدار
o_t	t مشاهده چندوجهی در لحظه
P_t	t ابر نقاط لیدار در لحظه
Q	ماتریس پرسمان‌ها در سازوکار توجه
S, u	انباشتگر ماتریسی و برداری توجه خطی
s_k	ام- k لگاریتم واریانس وظیفه

T	افق پیش‌بینی نقاط مسیر
V	ماتریس مقدارها در سازوکار توجه
v_t^{des}	سرعت مطلوب کنترل‌کننده طولی
w_t	t نقطه مسیر پیش‌بینی‌شده در گام
x_t^{goal}	هدف تنک ناوبری در دستگاه بدنی
z_t	بردار زمینه ترکیب‌شده دروازه‌دار

علائم یونانی

α	نرخ یادگیری
δ	فرمان زاویه غربیلک
θ	بردار پارامترهای شبکه
λ_i	ام تابع هزینه/وزن مؤلفه
π_θ	سیاست راندگی پارامتری‌شده
ρ	نرخ حذف تصادفی حسگر
$\sigma(\cdot)$	تابع سیگموئید
σ_k	ام- k عدم قطعیت آموختنی وظیفه
τ_t, β_t	فرمان دریچه گاز و ترمز
$\phi(\cdot)$	نگاشت ویژگی هسته در توجه خطی
ϕ_c, ϕ_l	رمزگذارهای تکوجهی تصویر و لیدار
Δ_{rob}	افت نسبی امتیاز راندگی

بالانویس‌ها

c	وجه دوربین
l	وجه لیدار

زیرنویس‌ها

t	اندیس زمان
i, j	اندیس نشانه‌ها

۱ مقدمه

رانندگی خودران یکی از بلندپروازانه‌ترین اهداف مهندسی معاصر است؛ هدفی که تحقق آن می‌تواند ایمنی ترافیک را به‌طور بنیادین دگرگون کند، تلفات جاده‌ای را کاهش دهد و بهره‌وری حمل‌ونقل را افزایش دهد. بر اساس گزارش وضعیت جهانی ایمنی راه‌های سازمان بهداشت جهانی، سالانه بیش از یک میلیون نفر در تصادفات جاده‌ای جان خود را از دست می‌دهند و در مطالعات میدانی علت‌شناسی تصادف، خطای انسانی به‌عنوان عامل مؤثر در اکثریت قاطع این حوادث شناسایی شده‌است. سامانه‌های رانندگی خودران با حذف یا کاهش نقش خطای انسانی، نویدبخش کاهش چشمگیر این آمار هستند [۱].

در سال‌های اخیر، پارادایم طراحی این سامانه‌ها از رویکردهای ماژولار سنتی، که زنجیره‌ای از واحدهای مجزای ادراک، پیش‌بینی و برنامه‌ریزی هستند، به سمت معماری‌های یادگیری انتها-به-انتها^{۱۲} متمایل شده‌است [۱]. این معماری‌ها با دریافت مستقیم داده‌های خام حسگرها و تولید خروجی‌های کنترلی، از طریق بهینه‌سازی مشترک ویژگی‌ها برای ادراک و برنامه‌ریزی، پتانسیل بالایی برای بهبود عملکرد نشان داده‌اند. با این حال، یکی از چالش‌های اساسی این سیستم‌ها، وابستگی به یک منبع داده مانند دوربین تک‌چشمی و در نتیجه کاهش استواری^{۱۳} و ایمنی در سناریوهای پیچیده، شرایط جوی نامساعد و موقعیت‌های نادری است که در توزیع داده‌های آموزشی کمتر دیده شده‌اند؛ مسئله‌ای که با عنوان توزیع دنباله‌دار^{۱۴} شناخته می‌شود [۱ و ۴].

پژوهش حاضر با هدف غلبه بر این محدودیت، به طراحی، پیاده‌سازی و ارزیابی یک معماری نوین رانندگی خودران انتها-به-انتها با رویکرد یادگیری چندوجهی^{۱۵} می‌پردازد. ایده اصلی، ترکیب بهینه

¹² End-to-End

¹³ Robustness

¹⁴ Long-tailed Distribution

¹⁵ Multimodal Learning

اطلاعات حاصل از حسگرهای ناهمگون دوربین، به عنوان منبع غنی از اطلاعات معنایی، و لیدار^{۱۶}، به عنوان منبع دقیق داده‌های فضایی سه‌بعدی، در بستر یک معماری مبتنی بر ترنسفورمر^{۱۷} است. در ادامه این فصل، ابتدا انگیزه پژوهش و تعریف دقیق مسئله بیان می‌شود؛ سپس مروری فشرده بر پیشینه صورت می‌گیرد و اهداف، نوآوری‌ها و ساختار گزارش معرفی می‌شوند.

۱.۱ انگیزه پژوهش

حسگرهای مختلف خودروی خودران ویژگی‌های مکمل یکدیگر دارند. دوربین اطلاعات بافتی و معنایی غنی مانند رنگ چراغ راهنمایی، علائم افقی جاده و نشانه‌های عابر پیاده فراهم می‌کند؛ اما نسبت به شرایط نوری و جوی حساس است و ذاتاً فاقد اندازه‌گیری مستقیم عمق است. در مقابل، لیدار ساختار هندسی سه‌بعدی صحنه را با دقت سانتی‌متری و مستقل از روشنایی محیط اندازه می‌گیرد؛ اما خروجی آن تُنک است، از اطلاعات معنایی کم‌بهره است و در باران و مه شدید با نویز و کاهش برد مواجه می‌شود [۷ و ۲]. این مکمل بودن، انگیزه اصلی ترکیب اطلاعات دو حسگر است: سامانه‌ای که بتواند به صورت پویا و متناسب با شرایط محیط، به هر وجه اطلاعاتی وزن مناسب بدهد، در برابر افت کیفیت هر یک از حسگرها مقاوم‌تر خواهد بود.

از سوی دیگر، سازوکارهای پیشرفته ترکیب اطلاعات که در حوزه ادراک توسعه یافته‌اند [۳ و ۲]، هنوز به طور کامل در وظیفه رانندگی انتها-به-انتها به کار گرفته نشده‌اند [۱]. به‌ویژه، لایه‌های توجه در مدل‌های ترنسفورمر هزینه محاسباتی قابل توجهی تحمیل می‌کنند که با الزامات بلادرنگ سکوه‌ای خودرویی در تضاد است. بنابراین، طراحی یک سازوکار ترکیب که هم‌زمان «بهینه» از نظر کیفیت تعامل بین‌وجهی و «کارآمد» از نظر محاسباتی باشد، یک فرصت تحقیقاتی مهم است و انگیزه مستقیم این پایان‌نامه را شکل می‌دهد.

¹⁶ LiDAR


¹⁷ Transformer

۲.۱ تعریف مسئله


مسئله مورد بررسی این پژوهش را می‌توان چنین صورت‌بندی کرد: «طراحی یک سیاست رانندگی انتها-به-انتها که در هر لحظه، مشاهدات خام دوربین و لیدار و فرمان ناوبری سطح بالا را دریافت و فرمان‌های کنترلی پیوسته خودرو را چنان تولید کند که معیارهای استاندارد ایمنی و پیشروی در مسیر، هم در شرایط عادی و هم در شرایط چالش‌برانگیز، بیشینه شوند.» سه الزام اساسی بر این مسئله حاکم است: نخست، ترکیب اطلاعات باید در سطح ویژگی و به صورت آگاه از زمینه^{۱۸} انجام شود تا تعاملات معنایی-هندسی بین دو وجه مدل شود؛ دوم، پیچیدگی محاسباتی سازوکار ترکیب باید با رشد وضوح حسگرها مقیاس‌پذیر بماند؛ و سوم، سیاست آموخته‌شده باید در برابر افت کیفیت یا قطع موقت هر یک از حسگرها تخریب مهارشده و مطبوع داشته باشد، نه فروپاشی ناگهانی.

خط لوله ماژولار سنتی و رویکرد انتها-به-انتها در شکل ۱.۱ مقایسه شده‌اند. در رویکرد ماژولار، واسط‌های دست‌ساز بین واحدها باعث تجمع خطا می‌شوند و بهینه‌سازی هر واحد به صورت مجزا، لزوماً به بهینگی کل سامانه برای هدف نهایی، یعنی رانندگی ایمن، نمی‌انجامد. در مقابل، رویکرد انتها-به-انتها کل شبکه را بر اساس عملکرد نهایی و به صورت سراسری بهینه می‌کند [۱].

(a) Modular pipeline



(b) End-to-end approach



شکل ۱.۱ مقایسه خط لوله ماژولار و رویکرد انتها-به-انتها

¹⁸ Context-aware

در این پژوهش، حل مسئله در چارچوب یادگیری تقلیدی^{۱۹} دنبال می‌شود؛ به این معنا که سیاست رانندگی با تقلید از رفتار یک خبره ممتاز در محیط شبیه‌سازی شده CARLA آموزش می‌بیند [۱۳]. انتخاب محیط شبیه‌سازی، امکان ارزیابی تکرارپذیر در سناریوهای ایمنی-بحرانی و شرایط جوی متنوع را فراهم می‌کند؛ سناریوهایی که آزمودن آنها در دنیای واقعی پرهزینه و خطرناک است.

۳.۱ پیشنهاد پژوهش

مرور جامع چن و همکاران [۱] که بیش از ۲۷۰ مقاله را تحلیل کرده است، چشم‌انداز دقیقی از وضعیت فعلی حوزه رانندگی انتها-به-انتها ارائه می‌دهد و به صراحت بیان می‌کند که استفاده از یک حسگر منفرد برای مدیریت سناریوهای پیچیده شهری کافی نیست. مدل‌هایی مانند TransFuser [۱۰ و ۱۱] و InterFuser [۱۲] با به‌کارگیری لایه‌های توجه متقابل برای ترکیب میانی ویژگی‌های دوربین و لیدار، به نتایج پیشرفته‌ای در بنچمارک‌های استاندارد دست یافته‌اند؛ اما همچنان از پیچیدگی مرتبه دوم توجه کامل و نبود سازوکار صریح مدیریت اطمینان حسگرها رنج می‌برند. بررسی تفصیلی پیشنهاد در فصل دوم ارائه می‌شود.

۴.۱ اهداف و نوآوری‌ها

- بر اساس خلأهای شناسایی شده، اهداف مشخص این پژوهش عبارتند از:
- طراحی و پیاده‌سازی یک معماری یادگیری عمیق انتها-به-انتها مبتنی بر ترنس‌فورمر برای وظیفه رانندگی خودران در محیط‌های شبیه‌سازی شده،
 - توسعه یک ماژول ترکیب اطلاعات کارآمد با استفاده از سازوکارهای توجه متقابل برای ادغام بهینه ویژگی‌های استخراج شده از حسگرهای بصری (دوربین) و سه‌بعدی (لیدار)،
 - ارزیابی کمی و کیفی عملکرد مدل پیشنهادی در مقایسه با روش‌های پیشرفته موجود بر روی بنچمارک‌های استاندارد شبیه‌ساز CARLA و
 - تحلیل استواری مدل در سناریوهای چالش‌برانگیز، از جمله شرایط جوی متغیر (باران، مه، شب) و سناریوهای ایمنی-بحرانی که به‌طور خاص برای سنجش تعمیم‌پذیری طراحی شده‌اند.

¹⁹ Imitation Learning

در راستای این اهداف، نوآوری‌های اصلی پایان‌نامه عبارتند از: (۱) مازول ترکیب دروازه‌دار کارآمد EGCA که توجه متقابل دوسویه را با یک هسته شباهت تجزیه‌پذیر پیاده‌سازی می‌کند و پیچیدگی عملگر توجه را از مرتبه دوم به مرتبه خطی نسبت به تعداد نشانه‌ها کاهش می‌دهد؛ (۲) دروازه اطمینان حسگر که سهم هر وجه را به صورت پویا و داده‌محور تنظیم می‌کند؛ و (۳) راهبرد آموزشی حذف تصادفی حسگر که در کنار دروازه فوق، تخریب مطبوع عملکرد در برابر خرابی حسگرها را به صورت تجربی بهبود می‌دهد.

درباره مورد نخست یک تصریح لازم است که در بخش ۳.۴.۴ به آن بازگشته می‌شود: جایگزینی هسته نمایی با هسته تجزیه‌پذیر، تقریبی از توجه softmax نیست بلکه سازوکار توجهی با هسته شباهت متفاوت است. آنچه حفظ می‌شود نامنفی بودن و نرمال بودن وزن‌ها است و نه مقدار آنها؛ بنابراین ادعای این پایان‌نامه «تقریب ارزان‌تر توجه کامل» نیست، بلکه «سازوکار توجه دیگری با هزینه خطی که در این وظیفه عملکرد هم‌ارز نشان می‌دهد» است.

۵.۱ محتوای گزارش

ساختار ادامه این گزارش به شرح زیر است. در فصل دوم پیشینه پژوهش، شامل سیر تحول رویکردهای رانندگی خودران، راهبردهای ترکیب اطلاعات و معماری‌های مبتنی بر توجه، مرور و خلأهای تحقیقاتی مشخص می‌شود. فصل سوم مبانی نظری و فرمول‌بندی ریاضی مسئله، شامل رمزگذارهای تک‌وجهی، سازوکار توجه و توابع هزینه چندوظیفه‌ای را ارائه می‌کند. در فصل چهارم معماری پیشنهادی و اجزای آن به تفصیل معرفی می‌شوند. فصل پنجم به شرح بستر آزمایش، معیارهای ارزیابی، نتایج کمی و کیفی و تحلیل استواری اختصاص دارد و در فصل ششم جمع‌بندی، نوآوری‌ها، محدودیت‌ها و پیشنهادهایی برای ادامه کار بیان می‌شود.

۲ پیشینه پژوهش

در این فصل، پیشینه پژوهش در چهار محور اصلی مرور می‌شود: نخست، سیر گذار از معماری‌های ماژولار به یادگیری انتها-به-انتها؛ دوم، یادگیری چندوجهی و راهبردهای ترکیب اطلاعات حسگرها؛ سوم، معماری‌های نوین مبتنی بر توجه در رانندگی انتها-به-انتها؛ و چهارم، مجموعه داده‌ها و بسترهای ارزیابی استاندارد. مرجع اصلی این فصل، بررسی جامع چن و همکاران [۱] است که با تحلیل بیش از ۲۷۰ مقاله، چشم‌انداز دقیقی از وضعیت فعلی و چالش‌های این حوزه ارائه می‌دهد. در پایان فصل، خلاصه‌ای تحقیقاتی که این پژوهش در پی پاسخ به آنهاست، جمع‌بندی می‌شود.

۱.۲ گذار از معماری ماژولار به انتها-به-انتها

ایده کنترل خودروی خودران با شبکه عصبی سابقه‌ای بیش از سه دهه دارد؛ سامانه ALVINN در سال ۱۹۸۸ با یک شبکه پیش‌خور کم‌عمق، فرمان غربلیک را مستقیماً از تصویر دوربین پیش‌بینی می‌کرد [۲۷]. با ظهور یادگیری عمیق، بوجارسکی و همکاران [۲۶] نشان دادند که یک شبکه پیچشی می‌تواند با داده‌های رانندگی واقعی، کنترل جانبی خودرو را در بزرگراه بیاموزد. این نتایج اولیه، دو مسیر موازی را در صنعت و دانشگاه شکل داد که در ادامه بررسی می‌شوند.

۱.۱.۲ معماری ماژولار و محدودیت‌های آن

سیستم‌های سنتی رانندگی خودران از یک خط لوله ماژولار متشکل از بخش‌های مجزای ادراک، پیش‌بینی و برنامه‌ریزی تشکیل شده‌اند. این طراحی به دلیل قابلیت تفسیرپذیری و اشکال‌زدایی آسان مورد توجه صنعت بوده‌است؛ هر واحد را می‌توان جداگانه آزمود، گواهی کرد و بهبود داد. با این حال، این رویکرد از مشکلاتی بنیادین رنج می‌برد [۱]: خطای هر واحد به واحدهای بعدی منتقل و در طول زنجیره تجمیع می‌شود؛ واسطه‌های دست‌ساز میان واحدها (مانند جعبه‌های محیطی اشیا) تنها بخشی از اطلاعات صحنه را منتقل می‌کنند و بخش بالقوه مفیدی از اطلاعات در همان ابتدا دور ریخته می‌شود؛ و مهم‌تر

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

آنکه هر واحد برای معیار میانی خود بهینه می‌شود، نه برای هدف نهایی رانندگی ایمن، و در نتیجه بهینه‌سازی سراسری سامانه ممکن نیست.

۲.۱.۲ یادگیری انتها-به-انتها

در مقابل، رویکرد انتها-به-انتها کل نداشت از مشاهده تا فرمان کنترلی را با یک شبکه واحد مدل و بر اساس عملکرد نهایی بهینه می‌کند و به دلیل سادگی و کارایی محاسباتی، به پارادایم غالب در تحقیقات اخیر تبدیل شده است [۱]. دو خانواده اصلی روش‌های آموزش در این پارادایم عبارتند از یادگیری تقلیدی^{۲۰}، که در آن شبکه رفتار یک خبره را بازتولید می‌کند، و یادگیری تقویتی^{۲۱}، که در آن سیاست با تعامل مستقیم با محیط و بیشینه‌سازی پاداش تجمعی آموخته می‌شود. کودویلا و همکاران [۱۴] با معرفی CILRS نشان دادند که یادگیری تقلیدی شرطی شده بر فرمان ناوبری، مقیاس‌پذیری خوبی دارد؛ اما در عین حال محدودیت‌های مهم رفتار تقلیدی، از جمله سوگیری به داده‌های پرتکرار و ضعف در موقعیت‌های نادر را مستند کردند. چن و همکاران [۱۵] با روش «یادگیری با قلب» نشان دادند که آموزش دومرحله‌ای — ابتدا یک خبره ممتاز با دسترسی به حالت کامل محیط و سپس تقطیر آن به سیاست ح-سگرمحور — عملکرد را به‌طور قابل توجهی بهبود می‌دهد؛ الگویی که در پژوهش حاضر نیز برای تولید داده آموزشی استفاده شده است.

۲.۲ یادگیری چندوجهی و ترکیب اطلاعات حسگرها

مقاله مرجع [۱] به‌صراحت بیان می‌کند که استفاده از یک حسگر منفرد، مانند دوربین، برای مدیریت سناریوهای پیچیده شهری کافی نیست؛ از این رو ترکیب اطلاعات ح-سگرهای مختلف به یک ضرورت تبدیل شده است. شیائو و همکاران [۴] در یکی از نخستین مطالعات نظام‌مند رانندگی انتها-به-انتها چندوجهی نشان دادند که افزودن اطلاعات عمق به ورودی RGB، به‌ویژه در راهبرد ترکیب میانی، نرخ موفقیت رانندگی را به‌طور معنادار افزایش می‌دهد.

²⁰ Imitation Learning

²¹ Reinforcement Learning

۱.۲.۲ راهبردهای ترکیب اطلاعات


راهبردهای ترکیب اطلاعات حسگری عمدتاً به سه دسته تقسیم می‌شوند که در شکل ۱.۲ نمایش داده شده‌اند:

- ****ترکیب زودهنگام^(۲۲)****: ترکیب داده‌های خام حسگرها پیش از ورود به استخراج‌کننده ویژگی؛ این راهبرد ساده است اما به هم‌ترازی دقیق فضایی-زمانی نیاز دارد و در برابر خرابی هر حسگر شکننده است،
- ****ترکیب میانی^(۲۳)****: استخراج ویژگی از هر حسگر به صورت جداگانه و سپس ترکیب آنها در سطح ویژگی؛ این روش به دلیل انعطاف‌پذیری و عملکرد بالا بیشترین توجه را به خود جلب کرده است و
- ****ترکیب دیرهنگام^(۲۴)****: ترکیب خروجی‌های مدل‌های جداگانه هر حسگر در سطح تصمیم، که معمولاً عملکرد ضعیف‌تری دارد؛ زیرا تعاملات بین‌وجهی در سطح ویژگی از دست می‌رود.

²² Early Fusion

²³ Middle Fusion

²⁴ Late Fusion



شکل 1.۲ راهبردهای سه گانه ترکیب اطلاعات حسگرها

جمع‌بندی مطالعات تجربی [۱۰ و ۵۴] نشان می‌دهد ترکیب میانی، در صورت به‌کارگیری سازوکار تعامل مناسب، بهترین مصالحه میان دقت، انعطاف و استواری را فراهم می‌کند؛ از همین رو معماری پیشنهادی این پایان‌نامه نیز در دسته ترکیب میانی قرار می‌گیرد.

۲.۲.۲ ترکیب در فضای نمای پرنده

یک روند مهم در ادبیات ادراک، یکسان‌سازی وجه‌ها در فضای مشترک نمای پرنده^{۲۵} است. لیانگ و همکاران [۲] چارچوب BEVFusion را معرفی کردند که ویژگی‌های دوربین و لیدار را در شبکه BEV مشترک ترکیب می‌کند و نشان دادند این چارچوب در برابر خرابی لیدار یا دوربین استوار می‌ماند. لیو و همکاران [۳] نسخه چندوظیفه‌ای این ایده را توسعه دادند و فیلیون و فیدلر [۲۸] با روش Lift-Splat-Shoot سازوکار هندسی بالابردن ویژگی‌های تصویر به BEV را پایه‌گذاری کردند. لی و همکاران [۲۲] در BEVFormer با پرسمان‌های BEV و توجه متقابل مکانی-زمانی، این نمایش را به سطح جدیدی از

²⁵ Bird's-Eye View (BEV)

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلج، دانشگاه صنعتی شریف، دانشکده مهندسی برق، تیر ۱۴۰۵.

دقت رساندند. این مطالعات عمدتاً بر وظیفه ادراک متمرکزند و یکسان‌سازی صریح دو وجه در یک شبکه متریک را پیشنهاد می‌کنند. معماری فصل چهارم مسیر دیگری را برمی‌گزیند: نشانه‌های دوربین در فضای تصویر باقی می‌مانند و تناظر میان دو وجه به‌جای آنکه با یک تبدیل هندسی صریح تحمیل شود، بر عهده توجه متقابل گذاشته می‌شود. اطلاعات هندسی از راه رمزگذاری موقعیت وارد می‌شود: نشانه‌های لیدار مختصات متریک نمای پرنده و نشانه‌های تصویر مختصات شبکه ویژگی خود را حمل می‌کنند. انگیزه این انتخاب پرهیز از خطای تخمین عمق است؛ تصویر کردن ویژگی‌های تصویر به شبکه متریک، به تخمین عمق نیاز دارد و خطای آن مستقیماً به جابه‌جایی فضایی ویژگی‌ها ترجمه می‌شود.

۳.۲ معماری‌های مبتنی بر توجه در رانندگی انتها-به-انتها

تحقیقات اخیر نشان داده‌اند که سازوکار توجه^{۲۶} [۹] تأثیر چشمگیری بر بهبود عملکرد ترکیب میانی دارد؛ این مدل‌ها قادرند زمینه را به‌طور مؤثر از ورودی‌های مختلف حسگرها تجمیع کنند و به رانندگی ایمن‌تر منجر شوند [۱]. پراکاش و همکاران [۱۰] با معرفی TransFuser نشان دادند که تعامل ویژگی‌های تصویر و BEV لیدار از طریق بلوک‌های ترنسفورمر در چند مقیاس، در سناریوهای شهری پیچیده به‌مراتب از ترکیب هندسی نقطه‌ای بهتر عمل می‌کند؛ نسخه توسعه‌یافته این معماری [۱۱] سال‌ها به‌عنوان مدل مرجع در جدول رده‌بندی CARLA مطرح بود. شائو و همکاران [۱۲] در InterFuser با رمزگشای ترنسفورمری و نقشه‌های ایمنی میانی، تفسیرپذیری و مقیدسازی ایمنی خروجی را بهبود دادند و در ReasonNet [۶] با استدلال زمانی و سراسری، پیش‌بینی رخداد‌های مسدود شده را ممکن کردند. ژانگ و همکاران [۵] در MMFN نشان دادند که افزودن وجه‌های بیشتر مانند نقشه برداری و رادار نیز در چارچوب مشابه قابل ادغام است. وو و همکاران [۲۴] در TCP ترکیب پیش‌بینی مسیر و کنترل مستقیم را بررسی کردند و یگر و همکاران [۲۵] با تحلیل سوگیری‌های پنهان رانندگی انتها-به-انتها، اهمیت طراحی دقیق رمزگشا و خبره داده‌ساز را نشان دادند. چیتا و همکاران [۲۳] نیز در NEAT نمایش میدان‌های توجه عصبی را برای فشرده‌سازی صحنه معرفی کردند. جدول ۱.۲ ویژگی‌های کلیدی روش‌های شاخص را مقایسه می‌کند.

جدول 1.۲ مقایسه روش‌های شاخص رانندگی انتها-به-انتها چندوجهی

²⁶ Attention

روش	وجه‌های ورودی	سازوکار ترکیب	پیچیدگی توجه	مدیریت اطمینان حسگر
CILRS [۱۴]	دوربین	—	—	ندارد
LBC [۱۵]	دوربین	—	—	ندارد
TransFuser [۱۱]	دوربین + لیدار	توجه کامل چندمقیاسی	$(^2N)O$	ندارد
InterFuser [۱۲]	چند دوربین + لیدار	رمزگشای ترنسفورمر	$(^2N)O$	ندارد
ReasonNet [۶]	چند دوربین + لیدار	استدلال زمانی-سراسری	$(^2N)O$	ندارد
MMFN [۵]	دوربین + لیدار + نقشه	توجه کامل	$(^2N)O$	ندارد
روش پیشنهادی	دوربین + لیدار	توجه متقابل خطی دروازه‌دار	$(N)O$	دروازه پویا + حذف تصادفی

۴.۲ مجموعه داده‌ها و بسترهای ارزیابی

پیشرفت این حوزه بدون مجموعه داده‌ها و بسترهای ارزیابی استاندارد ممکن نبود. مجموعه داده nuScenes [۷] با ۱۰۰۰ صحنه شهری و حاشیه‌نویسی کامل سه‌بعدی، و مجموعه داده Waymo [۸] با پوشش جغرافیایی و تنوع بالای خود، به مرجع ارزیابی ادراک چندوجهی تبدیل شده‌اند. با این حال، ارزیابی «حلقه‌بسته» سیاست رانندگی — که در آن خطاهای مدل بر مشاهدات بعدی اثر می‌گذارند — تنها در شبیه‌ساز ممکن است؛ شبیه‌ساز متن‌باز CARLA [۱۳] با پشتیبانی از شهرهای متنوع، عامل‌های ترافیکی و شرایط جوی قابل کنترل، بستر اصلی این نوع ارزیابی و بنچمارک‌های رسمی آن مانند Longest6 [۱۱] است. جدول ۲.۲ مشخصات این بسترها را خلاصه می‌کند. در پژوهش حاضر، به دلیل نیاز به ارزیابی حلقه‌بسته و سناریوهای ایمنی-بحرانی تکرارپذیر، از CARLA استفاده می‌شود.

جدول ۲.۲ مجموعه داده‌های استاندارد رانندگی خودران

مجموعه داده	سال	حسگرها	حجم	نوع ارزیابی
nuScenes [۷]	۲۰۲۰	۶ دوربین، لیدار، رادار	۱۰۰۰ صحنه / ۱۰۴ میلیون قاب	حلقه‌باز
Waymo Open [۸]	۲۰۲۰	۵ دوربین، ۵ لیدار	۱۱۵۰ صحنه / ۲۳۰ هزار قاب حاشیه‌نویسی شده	حلقه‌باز

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده مهندسی برق، تیر ۱۴۰۵.

مجموعه داده	سال	حسگرها	حجم	نوع ارزیابی
CARLA [۱۳]	۲۰۱۷	قابل پیکربندی	نامحدود (تولید برخط)	حلقه بسته

۵.۲ خلاصه‌های تحقیقاتی و جمع‌بندی

با وجود پیشرفت‌های حاصل، مرور فوق و به‌ویژه تحلیل مقاله مرجع [۱] به چندین خلأ کلیدی اشاره دارد که این پژوهش قصد دارد به آنها بپردازد:

- **نبود سازوکار ترکیب بهینه:** بسیاری از سازوکارهای پیشرفته ترکیب اطلاعات که در حوزه ادراک توسعه یافته‌اند [۲ و ۳ و ۲۲]، هنوز به‌طور کامل در وظیفه رانندگی انتها-به-انتها به کار گرفته نشده‌اند و این حوزه نیازمند پژوهش بیشتر است،
- **هزینه محاسباتی بالا:** لایه‌های توجه کامل در مدل‌های ترنسفورمری، هزینه محاسباتی مرتبه دوم نسبت به تعداد نشانه‌ها تحمیل می‌کنند و تضمینی برای استخراج اطلاعات مفید وجود ندارد؛ بنابراین طراحی یک سازوکار ترکیب کارآمدتر، یک فرصت تحقیقاتی مهم است و
- **نبود استواری در شرایط چالش‌برانگیز:** مدل‌های موجود در مواجهه با سناریوهای خارج از توزیع داده‌های آموزشی، مانند شرایط جوی نامساعد (باران، مه) یا رویدادهای نادر، با افت عملکرد شدید مواجه می‌شوند و هیچ‌یک سازوکار صریحی برای مدیریت اطمینان حسگرها ندارند.

بنابراین، پژوهش حاضر در راستای پاسخ به این خلأها، بر طراحی یک معماری ترنسفورمری تمرکز دارد که با یک سازوکار توجه کارآمد و بهینه، اطلاعات چندوجهی را برای دستیابی به عملکردی استوارتر در شرایط دشوار ترکیب می‌کند. فصل بعد، مبانی نظری لازم برای صورت‌بندی دقیق این معماری را فراهم می‌آورد.

۳ مبانی نظری و فرمول‌بندی مسئله

در این فصل، مبانی نظری لازم برای طراحی معماری پیشنهادی ارائه می‌شود. ابتدا مسئله رانندگی انتها-به-انتها در چارچوب یادگیری تقلیدی به صورت ریاضی صورت‌بندی می‌شود؛ سپس ساختار رمزگذارهای تک‌وجهی تصویر و ابر نقاط، سازوکار توجه و گونه کارآمد خطی آن، و در پایان چارچوب یادگیری چندوظیفه‌ای و توابع هزینه تشریح می‌شوند. نمادگذاری معرفی شده در این فصل، در سراسر فصل‌های بعد به کار می‌رود.

۱.۳ فرمول‌بندی مسئله رانندگی انتها-به-انتها

محیط رانندگی را می‌توان یک فرایند تصمیم‌مارکوف مشاهده‌پذیر جزئی^۱ در نظر گرفت که در آن عامل به حالت کامل محیط دسترسی ندارد و تنها مشاهده چندوجهی زیر را دریافت می‌کند:

$$o_t = (I_t, P_t, v_t, c_t, x_t^{\text{goal}}) \quad (1.3)$$

که در آن I_t تصویر (یا تصاویر) دوربین، P_t ابر نقاط لیدار، v_t سرعت لحظه‌ای خودرو، c_t فرمان ناوبری سطح بالا (مانند «در تقاطع بعد به چپ بپیچ») و x_t^{goal} هدف تنک ناوبری در دستگاه مختصات بدنی خودرو است. به طور دقیق، سیاست بهینه در یک POMDP تابعی از باور، یعنی توزیع پسین حالت به شرط تمام تاریخ مشاهدات، است. در این پژوهش — همانند اکثر روش‌های مرجع [۱۱ و ۱۲] — باور با مشاهده لحظه‌ای تقریب زده می‌شود و سیاست بی‌حافظه (تک‌قابی) در نظر گرفته می‌شود؛ سرعت لحظه‌ای و فرمان ناوبری، بخشی از اطلاعات تاریخی لازم را به صورت فشرده تأمین می‌کنند. این تقریب، توانایی مدل در استدلال زمانی مانند پیش‌بینی اشیای مسدودشده را محدود می‌کند و در بخش ۶.۳ به عنوان یکی از محدودیت‌های پژوهش بازبینی می‌شود [۲۵ و ۲۶].

¹ Partially Observable Markov Decision Process (POMDP)

هدف، یادگیری سیاست پارامتری π_θ است که مشاهده را به یک مسیر کوتاه‌مدت می‌نگارد و فرمان کنترلی پیوسته با یک نگاشت ثابت و بدون پارامتر آموختنی (دو کنترل‌کننده PID بخش ۴.۵) از آن مسیر استخراج می‌شود:

$$W_t = \pi_\theta(o_t), a_t = \text{Ctrl}(W_t, v_t), a_t = (\delta_t, \tau_t, \beta_t) \quad (2.3)$$

که δ_t زاویه غربیلک، τ_t دریچه گاز و β_t ترمز است، و به پیروی از روش‌های موفق اخیر [۱۱ و ۱۲ و ۲۴]، خروجی شبکه مجموعه‌ای از نقاط مسیر^۱ آینده در دستگاه مختصات بدنی خودرو است:

$$W_t = \{w_{t+k}\}_{k=1}^T, w_{t+k} \in \mathbb{R}^2 \quad (3.3)$$

این جداسازی، پایداری آموزش را افزایش می‌دهد و خروجی شبکه را تفسیرپذیرتر می‌کند [۲۵]. در چارچوب یادگیری تقلیدی، یک خبره ممتاز π^* — که در شبیه‌ساز به حالت کامل محیط دسترسی دارد [۱۵] — مجموعه داده‌ای از مشاهده‌ها همراه با مسیر مرجع و برچسب‌های کمکی (نقشه قطعه‌بندی نمای پرند S^* و نقشه عمق D^*) تولید می‌کند:

$$\mathcal{D} = \{(o^{(i)}, W^{*(i)}, S^{*(i)}, D^{*(i)})\}_{i=1}^M \quad (4.3)$$

و پارامترهای سیاست با کمینه‌سازی خطای تقلید، یعنی فاصله میان مسیر پیش‌بینی شده و مسیر خبره، آموخته می‌شوند:

$$\theta^* = \argmin_{\theta} \mathbb{E}_{o \sim d_{\pi^*}} [\mathcal{L}_{\text{IL}}(\pi_\theta(o), W^*(o))] \quad (5.3)$$

نکته مهم آنکه امید ریاضی در این رابطه روی توزیع حالت‌های بازدیدشده توسط خبره، d_{π^*} ، گرفته می‌شود، در حالی که در زمان اجرا توزیع حالت‌ها توسط خود سیاست آموخته شده، d_{π_θ} ، تعیین می‌شود. این عدم تطابق که انحراف توزیع^۲ نام دارد، منشأ تجمیع خطا در افق‌های بلند در یادگیری تقلیدی است [۱۴]؛ در پژوهش حاضر اثر آن با افزودن اغتشاش به مسیر خبره هنگام جمع‌آوری داده و با ارزیابی حلقه‌بسته (نه حلقه‌باز) سنجیده و مهار می‌شود، اما به‌طور کامل حذف نمی‌شود.

¹ Waypoints

² Covariate Shift

۲.۳ استخراج ویژگی از تصویر

برای استخراج ویژگی‌های معنایی از تصویر ورودی، از شبکه‌های پیچشی باقیمانده رزنت^۱ استفاده می‌شود [۱۶]. ایده اصلی این معماری، یادگیری نگاشت باقیمانده به جای نگاشت مستقیم است؛ هر بلوک باقیمانده خروجی زیر را تولید می‌کند:

$$y = \mathcal{F}(x, \{W_i\}) + x \quad (6.3)$$

که در آن x ورودی بلوک و $\mathcal{F}$ نگاشت باقیمانده متشکل از دو یا سه لایه پیچشی است. اتصال میان‌بر همانی، مشکل محوشدگی گرادیان را در شبکه‌های عمیق برطرف می‌کند و امکان آموزش شبکه‌های بسیار عمیق را فراهم می‌سازد. با اعمال رمزگذار تصویری ϕ_c بر تصویر ورودی، نقشه ویژگی فشرده زیر حاصل می‌شود:

$$F_c = \phi_c(I_t) \in \mathbb{R}^{N_c \times d} \quad (7.3)$$

که N_c تعداد نشانه‌های فضایی حاصل از مسطح‌سازی نقشه ویژگی و d بعد مشترک نشانه‌ها است. در معماری پیشنهادی از ResNet-34 به‌عنوان ستون فقرات تصویری استفاده می‌شود که مصالحه مناسبی میان دقت و هزینه محاسباتی روی سکوها‌های بلادرنگ دارد.

۳.۳ استخراج ویژگی از ابر نقاط لیدار

ابر نقاط لیدار مجموعه‌ای بی‌ترتیب و تُنک از نقاط سه‌بعدی است و نمی‌توان آن را مستقیماً به شبکه‌های پیچشی داد. در این پژوهش از رویکرد ستون‌های نقطه‌ای^۲ [۱۷] استفاده می‌شود که ابر نقاط را در ستون‌های عمودی شبکه‌بندی و به یک شبه‌تصویر نمای پرنده تبدیل می‌کند؛ روند کلی در شکل ۱.۳ نشان داده شده‌است. هر نقطه درون یک ستون، ابتدا با آماره‌های هندسی ستون تقویت می‌شود:

$$\tilde{p}_i = [x_i, y_i, z_i, r_i, x_i - \bar{x}, y_i - \bar{y}, z_i - \bar{z}, x_i - x_p, y_i - y_p] \quad (8.3)$$

^۱ ResNet


^۲ PointPillars

که $(\bar{x}, \bar{y}, \bar{z})$ مرکز جرم نقاط ستون و (x_p, y_p) مرکز هندسی ستون است. سپس یک شبکه PointNet ساده، ویژگی هر ستون را با بیشینه‌گیری متقارن روی نقاط آن استخراج می‌کند:

$$f_p = \max_{i \in \text{pillar}} \text{MLP}(\tilde{p}_i) \quad (9.3)$$

عملگر بیشینه، ناوردایی نسبت به جایگشت نقاط را تضمین می‌کند. ویژگی‌های ستون‌ها در مکان اصلی خود در شبکه دوبعدی قرار می‌گیرند و یک ستون فقرات پیچشی سبک، نقشه ویژگی نمای پرند را تولید می‌کند:

$$F_l = \phi_l(P_t) \in \mathbb{R}^{N_l \times d} \quad (10.3)$$



شکل 1.3 رمزگذاری ابر نقاط لیدار به نقشه ویژگی نمای پرند

مزیت این نمایش آن است که نشانه‌های حاصل، ساختار فضایی صحنه را در دستگاه مختصات بدنی حفظ می‌کنند و هم‌ترازی آنها با نقاط مسیر خروجی، یادگیری نگاشت ادراک-برنامه‌ریزی را ساده می‌کند [۲].

۴.۳ سازوکار توجه

سازوکار توجه، هسته اصلی معماری ترنسفورمر [۹] و ابزار اصلی ترکیب اطلاعات در این پژوهش است. در این بخش ابتدا شکل پایه توجه و سپس گونه‌های چندسره، متقابل و خطی آن معرفی می‌شوند.

۱.۴.۳ توجه ضرب داخلی مقیاس‌شده

توجه را می‌توان بازیابی نرم اطلاعات از یک حافظه دانست. با داشتن ماتریس پرسمان Q ، کلید K و مقدار V ، خروجی توجه ضرب داخلی مقیاس‌شده به صورت زیر تعریف می‌شود [۹]:

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (11.3)$$

که در آن $Q \in \mathbb{R}^{N_q \times d_k}$ ، $K \in \mathbb{R}^{N_k \times d_k}$ و $V \in \mathbb{R}^{N_k \times d_v}$ است و مقیاس‌کننده $\sqrt{d_k}$ از اشباع تابع softmax در ابعاد بزرگ جلوگیری می‌کند. عنصر (i, j) ماتریس وزن توجه، میزان ارتباط پرسمان i -ام با کلید j -ام را به صورت نرمال‌شده بیان می‌کند:

$$A_{ij} = \frac{\exp(q_i^T k_j / \sqrt{d_k})}{\sum_{j'=1}^{N_k} \exp(q_i^T k_{j'} / \sqrt{d_k})} \quad (12.3)$$


۲.۴.۳ توجه چندسر

برای آنکه مدل بتواند هم‌زمان به زیرفضاهای نمایشی متفاوت توجه کند، توجه به صورت چند سر اعمال می‌شود؛ ساختار آن در شکل ۲.۳ نشان داده شده است:

$$\text{head}_h = \text{Att}(QW_h^Q, KW_h^K, VW_h^V) \quad (13.3)$$

$$\text{MHA}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_H)W^O \quad (14.3)$$

که W_h^Q, W_h^K, W_h^V و W^O ماتریس‌های وزن آموختنی هستند و H تعداد سرها است.



شکل 2.۳ سازوکار توجه ضرب داخلی مقیاس‌شده و توجه متقابل چندسرها

۳.۴.۳ توجه متقابل بین‌وجهی

در خودتوجهی^۱ هر سه ماتریس از یک دنباله واحد ساخته می‌شوند؛ اما در توجه متقابل^۲، پرممان‌ها از یک وجه و کلیدها و مقدارها از وجه دیگر می‌آیند. به‌طور مشخص، برای غنی‌سازی ویژگی‌های تصویر با اطلاعات هندسی لیدار داریم:

$$\tilde{F}_c = \text{MHA}(F_c W^Q, F_l W^K, F_l W^V) \quad (15.3)$$

این سازوکار به هر نشانه تصویری اجازه می‌دهد به صورت انتخابی از نشانه‌های لیدار که بیشترین ارتباط زمینه‌ای را دارند، اطلاعات جذب کند؛ قابلیت‌هایی که ترکیب‌های الحاقی ساده فاقد آن هستند [۱۰].

۴.۴.۳ پیچیدگی محاسباتی و توجه خطی

محاسبه توجه کامل چندسرها نیازمند $\mathcal{O}(N_q N_k d)$ عملیات ضرب-جمع و $\mathcal{O}(H N_q N_k)$ خانه حافظه برای نگهداری ماتریس‌های وزن است؛ برای نقشه‌های ویژگی متراکم دو حسگر، این هزینه مرتبه دوم به

¹ Self-Attention

² Cross-Attention

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

گلوگاه محاسباتی تبدیل می‌شود. کاتارپولوس و همکاران [۱۸] نشان دادند که اگر شباهت نمایی با یک هسته تجزیه‌پذیر جایگزین شود، ترتیب ضرب ماتریس‌ها قابل تغییر است. با نگاشت ویژگی $\phi(\cdot)$ ، سطر i -ام خروجی توجه خطی چنین نوشته می‌شود:

$$\text{LinAtt}(Q, K, V)_i = \frac{(\sum_{j=1}^{N_k} \phi(k_j) v_j^T)^T \phi(q_i)}{\phi(q_i)^T \sum_{j=1}^{N_k} \phi(k_j)} \in \mathbb{R}^{d_v} \quad (16.3)$$

که در آن نگاشت ویژگی اکیداً مثبت زیر به کار می‌رود [۱۸]:

$$\phi(x) = \text{elu}(x) + 1 \quad (17.3)$$

از آنجا که دو جمع روی j مستقل از i هستند، تنها یک بار محاسبه می‌شوند؛ در نتیجه، با در نظر گرفتن H سر با بعد $d_h = d/H$ ، پیچیدگی کل لایه به صورت زیر تغییر می‌کند:

$$\mathcal{O}(N_q N_k d) \rightarrow \mathcal{O}((N_q + N_k) d_h d) \quad (18.3)$$

بنابراین توجه خطی تنها هنگامی ارزان‌تر است که شرط سربه‌سری زیر برقرار باشد؛ شرطی که مستقل از d است و صرفاً بعد هر سر را با میانگین هماهنگ تعداد نشانه‌ها مقایسه می‌کند:

$$N_q N_k > \frac{1}{2} (N_q + N_k) d_h \quad (19.3)$$

این نکته اهمیت عملی دارد: در وضوح‌های پایین (چند ده نشانه) توجه کامل ارزان‌تر است و خطی‌سازی سودی ندارد؛ مزیت آن تنها در ناحیه‌ای ظاهر می‌شود که $d_h \gg N_q, N_k$ باشد. در معماری پیشنهادی فصل چهارم با $N_q N_k$ از مرتبه 1.8×10^6 و $d_h = 64$ ، این نسبت حدود ۱۲ برابر است. تحلیل تفصیلی بازنویسی هسته‌ای و شمارش دقیق عملیات در پیوست الف ارائه شده است.

تأکید بر یک نکته نظری ضروری است: توجه خطی رابطه (۱۶.۳) تقریبی از توجه softmax نیست، بلکه سازوکار توجه دیگری با هسته شباهت متفاوت است؛ زیرا هسته $\phi(q)^T \phi(k)$ با $\phi(x) = \text{elu}(x) + 1$ هسته نمایی را بازتولید نمی‌کند. تنها خاصیتی که حفظ می‌شود، نامنفی بودن وزن‌ها و نرمال شدن آنها به مجموع یک است، یعنی همان تفسیر «میانگین وزن دار محدب» از مقدارها. در مقابل، Performer [۱۹] با هسته‌های تصادفی مثبت تقریبی ناریب از softmax فراهم می‌کند، اما به قیمت واریانس تقریب و نشانه‌های تصادفی اضافی؛ در آزمایش‌های مقدماتی این پژوهش، نگاشت قطعی رابطه (۱۷.۳) پایداری آموزشی بهتری نشان داد و به همین دلیل انتخاب شد.

۵.۴.۳ رمزگذاری موقعیت

سازوکار توجه نسبت به ترتیب نشانه‌ها ناوردا است؛ بنابراین اطلاعات موقعیت باید به صورت صریح تزریق شود. در این پژوهش از رمزگذاری سینوسی استاندارد [۹] استفاده می‌شود:

$$PE(pos, 2i) = \sin(\frac{pos}{10000^{2i/d}}), PE(pos, 2i + 1) = \cos(\frac{pos}{10000^{2i/d}}) \quad (20.3)$$

برای نشانه‌های تصویر، این رمزگذاری روی مختصات دوبعدی شبکه ویژگی و برای نشانه‌های لیدار روی مختصات متریک BEV اعمال می‌شود تا هم‌ترازی هندسی دو وجه در فضای نهفته تسهیل شود.

۵.۳ یادگیری چندوظیفه‌ای و توابع هزینه

آموزش سیاست تنها با نظارت بر نقاط مسیر، سیگنال یادگیری ضعیفی برای لایه‌های ادراکی فراهم می‌کند؛ از این رو، مطالعات متعدد [۱۱ و ۱۲] از سرپرست‌های کمکی مانند قطعه‌بندی معنایی BEV و تخمین عمق بهره می‌گیرند. هزینه اصلی تقلید، خطای L1 نقاط مسیر است:

$$\mathcal{L}_{wp} = \frac{1}{T} \sum_{k=1}^T \|\hat{w}_{t+k} - w_{t+k}^*\|_1 \quad (21.3)$$

هزینه قطعه‌بندی معنایی نمای پرند با آنتروپی متقاطع محاسبه می‌شود:

$$\mathcal{L}_{seg} = -\frac{1}{|\Omega|} \sum_{u \in \Omega} \sum_{c=1}^C y_{u,c} \log \hat{y}_{u,c} \quad (22.3)$$

و هزینه تخمین عمق تصویری به صورت خطای L1 روی نقشه عمق نرمال شده تعریف می‌شود:

$$\mathcal{L}_{dep} = \frac{1}{|\Pi|} \sum_{u \in \Pi} |\hat{d}_u - d_u^*| \quad (23.3)$$

تنظیم دستی وزن نسبی وظایف دشوار است؛ کنдал و همکاران [۲۰] نشان دادند که با مدل کردن عدم قطعیت ذاتی (هم‌واریانس) هر وظیفه به صورت پارامتر آموختنی σ_k ، وزن‌دهی بهینه از بیشینه‌سازی درست‌نمایی به صورت خودکار حاصل می‌شود. شکل جمله درست‌نمایی به نوع وظیفه بستگی دارد: برای وظایف رگرسیون با فرض نوفه گاوسی ضریب $1/2\sigma_k^2$ و برای وظیفه دسته‌بندی با مدل softmax مقیاس شده ضریب $1/\sigma_k^2$ به دست می‌آید:

$$\mathcal{L}_{total} = \sum_{k \in \mathcal{R}} (\frac{1}{2\sigma_k^2} \mathcal{L}_k + \log \sigma_k) + \sum_{k \in \mathcal{C}} (\frac{1}{\sigma_k^2} \mathcal{L}_k + \log \sigma_k) \quad (24.3)$$

که $\mathcal{R}$ مجموعه وظایف رگرسیون و $\mathcal{C}$ مجموعه وظایف دسته‌بندی است. جمله $\log \sigma_k$ نقش تنظیم‌کننده دارد و از واگرایی وزن‌ها به سمت صفر جلوگیری می‌کند؛ زیرا کاهش بی‌حد وزن یک وظیفه، این جمله را به بی‌نهایت منفی نمی‌برد بلکه بهای فزاینده‌ای تحمیل می‌کند. در پیاده‌سازی، به جای σ_k کمیت $s_k = \log \sigma_k^2$ بهینه می‌شود تا مثبت بودن واریانس بدون قید صریح تضمین شود و تقسیم بر مقادیر کوچک رخ ندهد. این چارچوب در فصل چهارم برای ترکیب هزینه‌های تقلید و کمکی به کار گرفته می‌شود.

۶.۳ جمع‌بندی

در این فصل، مسئله رانندگی انتها-به-انتها به صورت یادگیری تقلیدی شرطی‌شده بر فرمان ناوبری صورت‌بندی شد؛ رمزگذارهای تک‌وجهی تصویر و ابر نقاط، سازوکار توجه کامل و خطی، و چارچوب یادگیری چندوظیفه‌ای با وزن‌دهی مبتنی بر عدم قطعیت معرفی شدند. فصل بعد با تکیه بر این مبانی، معماری پیشنهادی و اجزای نوآورانه آن را به تفصیل تشریح می‌کند.


۴ روش پیشنهادی

این فصل به معرفی معماری پیشنهادی پایان نامه اختصاص دارد؛ معماری ای که با نام «ترکیب دروازه دار کارآمد مبتنی بر توجه متقابل» یا به اختصار EGCA^۱ شناخته می شود. ابتدا نمای کلی معماری و جریان داده در آن توصیف می شود؛ سپس هر یک از اجزا، شامل شاخه های رمزگذار، ماژول ترکیب، رمزگشای نقاط مسیر و کنترل کننده های سطح پایین، به همراه فرمول بندی دقیق معرفی می شوند و در پایان، راهبرد آموزش استوار و الگوریتم کامل آموزش ارائه می شود.

۱.۴ نمای کلی معماری

نمای کلی معماری پیشنهادی در شکل ۱.۴ نشان داده شده است. ورودی سامانه در هر گام زمانی شامل تصاویر سه دوربین جلو با هم پوشانی میدان دید مماس (نوار پیوسته ۱۸۰ درجه که به ۱۳۲ درجه مرکزی برش می خورد)، ابر نقاط یک لیدار ۶۴ خطی، سرعت لحظه ای خودرو، فرمان ناوبری گسسته و هدف تنک ناوبری است. شاخه دوربین با ستون فقرات ResNet-34 و شاخه لیدار با رمزگذار PointPillars، نشانه های تصویری و نمای پرنده را تولید می کنند. این نشانه ها به L بلوک متوالی EGCA وارد می شوند که در هر بلوک، تعامل دو سویه بین وجهی با توجه متقابل خطی انجام و خروجی هر وجه با دروازه اطمینان وزن دهی می شود. بردار زمینه حاصل، به همراه رمزگذاری حالت خودرو و فرمان ناوبری، به رمزگشای GRU داده می شود تا نقاط مسیر آینده را به صورت خودبازگشتی تولید کند؛ سرپرست های کمکی قطعه بندی BEV و عمق نیز فقط در زمان آموزش فعال اند. در نهایت، دو کنترل کننده PID فرمان های سطح پایین را از نقاط مسیر استخراج می کنند.

^۱ Efficient Gated Cross-Attention



شکل 1.۴ نمای کلی معماری پیشنهادی

سه اصل طراحی بر این معماری حاکم است: نخست، ترکیب باید «میانی و چندمرحله‌ای» باشد تا تعاملات معنایی-هندسی در چند سطح انتزاع مدل شود؛ دوم، هزینه محاسباتی ترکیب باید نسبت به تعداد نشانه‌ها خطی بماند تا مقیاس‌پذیری با وضوح حسگرها حفظ شود؛ و سوم، سهم هر وجه باید به صورت پویا و متناسب با اطمینان لحظه‌ای آن تعیین شود تا استواری در برابر افت کیفیت حسگرها تضمین شود.

۲.۴ شاخه‌های رمزگذار

۱.۲.۴ شاخه دوربین

تصاویر سه دوربین پس از هم‌ترازی و برش، به یک تصویر سراسری با ابعاد 704×160 الحاق می‌شوند و به ResNet-34 داده می‌شوند. نشانه‌ها از نقشه ویژگی مرحله سوم (گام ۱۶) گرفته می‌شوند، اما برای آنکه میدان دید و سطح معنایی مرحله چهارم نیز حفظ شود، نقشه مرحله چهارم پس از نمونه‌برداری

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

افزایشی و تصویر 1×1 با آن جمع و سپس با یک پیچش 3×3 هموار می شود (ادغام یک سطحی از بالا به پایین، مشابه شبکه هرمی ویژگی). خروجی به بعد مشترک $d = 256$ فشرده و مسطح می شود:

$$F_c^{(0)} = \text{Flatten}(\text{Conv}_{3 \times 3}(\phi_c^{(3)}(I_t) + \text{Up}(\phi_c^{(4)}(I_t)))) + E_{\text{pos}}^c \quad (1.4)$$

که E_{pos}^c رمز گذاری موقعیت سینوسی دوبعدی است و تعداد نشانه های حاصل برابر $N_c = 10 \times 44 = 440$ است. انتخاب گام ۱۶ به جای گام ۳۲ آگاهانه است: وضوح فضایی بالاتر، هم تراز نشانه های تصویر با اشیای کوچک (مانند عابر پیاده و چراغ راهنمایی) را بهتر می کند و در ضمن، همان گونه که در بخش ۴.۳.۱ کمی می شود، دقیقاً همین وضوح است که هزینه مرتبه دوم توجه کامل را به جمله غالب مازول ترکیب تبدیل می کند و انگیزه استفاده از توجه خطی را فراهم می آورد.

۲.۲.۴ شاخه لیدار

ابر نقاط در محدوده ۳۲ متر جلو و ۱۶ متر در هر طرف خودرو، با ستون های ۰.۲۵ متری شبکه بندی می شود که به شبکه 128×128 می انجامد و مطابق بخش ۳.۳ رمز گذاری می شود. شبه تصویر BEV حاصل پس از یک مرحله پیچشی با گام ۲ و یک مرحله هم وضوح، به شبکه 64×64 (تفکیک ۰.۵ متر بر نشانه) کاهش و مسطح می شود:

$$F_l^{(0)} = \text{Flatten}(\phi_l(P_t)) + E_{\text{pos}}^l \quad (2.4)$$

که $N_l = 64 \times 64 = 4096$ نشانه با رمز گذاری موقعیت متریک است. هم مقیاس بودن بعد نشانه های دو وجه ($d = 256$) شرط لازم اعمال توجه متقابل است. توجه شود که تفکیک ۰.۵ متر برای نمایش عابر پیاده و مرزهای خط ضروری است؛ کاهش آن به ۲ متر (شبکه 16×16) هر چند هزینه ترکیب را به شدت کم می کند، اطلاعات هندسی لازم برای رانندگی شهری را از دست می دهد.

۳.۲.۴ رمزگذار حالت خودرو و فرمان ناوبری


سرعت لحظه ای v_t و فرمان ناوبری گسسته c_t (چپ، راست، مستقیم، پیروی مسیر) به صورت زیر به بردار زمینه اسکالر تبدیل می شوند:

$$m_t = \text{MLP}_m([v_t; \text{onehot}(c_t)]) \in \mathbb{R}^d \quad (3.4)$$

این بردار در رمزگشا به عنوان شرط اولیه به کار می رود و رفتار سیاست را بر مقصد ناوبری مشروط می کند [۱۴].

۳.۴ ماژول ترکیب دروازه دار کارآمد (EGCA)

ماژول EGCA هسته نوآورانه معماری پیشنهادی است و ساختار داخلی آن در شکل ۲.۴ نشان داده شده است. هر بلوک EGCA از سه جزء تشکیل می شود: توجه متقابل خطی دوسویه، شبکه پیش خور موضعی و دروازه اطمینان حسگر.



شکل ۲.۴ ساختار داخلی ماژول ترکیب دروازه دار کارآمد (EGCA)

۱.۳.۴ توجه متقابل خطی دوسویه

در بلوک ℓ -ام، ابتدا نشانه‌های هر وجه با توجه متقابل خطی از وجه دیگر غنی می شوند. برای مسیر تصویر ← لیدار داریم:

$$Z_c^{(\ell)} = \text{LinAtt}(F_c^{(\ell)} W_Q^c, F_l^{(\ell)} W_K^l, F_l^{(\ell)} W_V^l) \quad (4.4)$$

و به طور متقارن برای مسیر لیدار ← تصویر:

$$Z_l^{(\ell)} = \text{LinAtt}(F_l^{(\ell)} W_Q^l, F_c^{(\ell)} W_K^c, F_c^{(\ell)} W_V^c) \quad (5.4)$$

که عملگر LinAtt همان توجه خطی رابطه (۱۶.۳) با نگاشت ویژگی $\text{elu}(x)+1$ و چهار سر موازی است. نکته مهم آنکه هر دو رابطه بر ورودی یکسان بلوک عمل می کنند؛ بنابراین به روزرسانی دو وجه متقارن است و دو مسیر توجه می توانند به صورت موازی محاسبه شوند. سپس اتصال باقیمانده، نرمال سازی لایه ای و شبکه پیش خور موضعی اعمال می شود:

$$\hat{F}_m^{(\ell)} = \text{LN}(F_m^{(\ell)} + Z_m^{(\ell)}), F_m^{(\ell+1)} = \text{LN}(\hat{F}_m^{(\ell)} + \text{FFN}(\hat{F}_m^{(\ell)})), m \in \{c, l\} \quad (6.4)$$

برای آنکه سود این جایگزینی کمی و بازبینی پذیر باشد، عملیات ضرب-جمع یک عبور رو به جلو با مقادیر واقعی این معماری شمرده می شود: $N_c = 440, N_l = 4096, d = 256, H = 4$ (پس $d_h = 64$ و $L = 4$ در هر جهت، توجه کامل به $2N_c N_l d$ و توجه خطی به $(N_c + N_l)d_h d$ عملیات نیاز دارد؛ نسبت این دو برابر $12.4 \approx 2N_c N_l / [(N_c + N_l)d_h]$ است. با احتساب دو جهت و $L = 4$ بلوک، عملگر توجه از ۷,۳۸ به ۰,۵۹ گیگا-عملیات می رسد، یعنی کاهش ۹۲ درصدی و صرفه جویی ۶,۷۹ گیگا-عملیات. با این حال، بخش دیگری از هزینه مازول ترکیب — تصویرهای خطی پر سمان/کلید/مقدار/خروجی و شبکه پیش خور — نسبت به تعداد نشانه ها خطی است و با خطی سازی توجه تغییر نمی کند. بنابراین گزارش صادقانه سود، سه سطحی است: هزینه کل مازول ترکیب از ۱۶,۹ به ۱,۰۱ گیگا-عملیات (کاهش حدود ۴۰ درصد) و هزینه کل شبکه از ۳,۰۰ به ۲۳,۲ گیگا-عملیات (کاهش حدود ۲۳ درصد) می رسد؛ تأخیر اندازه گیری شده نیز مطابق بخش ۵.۶ برای مازول ترکیب حدود ۳۰ درصد و برای کل شبکه حدود ۱۳ درصد کاهش می یابد.

علاوه بر عملیات، توجه کامل باید ماتریس وزن ها را با $HN_c N_l \approx 7.2$ میلیون خانه در هر جهت و هر بلوک تولید کند؛ برای چهار بلوک و دو جهت، حدود ۵۸ میلیون مقدار (نزدیک به ۱۱۵ مگابایت در دقت نیم شناور) به ازای هر نمونه. توجه خطی هیچ گاه چنین ماتریسی را تشکیل نمی دهد و حافظه آن نسبت به تعداد نشانه ها خطی است. باید توجه داشت که پیاده سازی های آگاه از حافظه توجه softmax، این ماتریس را به صورت قطعه قطعه محاسبه می کنند و هزینه حافظه مرتبه دوم را حذف می کنند؛ اما تعداد عملیات مرتبه دوم را کاهش نمی دهند. از این رو در این پایان نامه ادعای برتری بر مبنای «عملیات» و «تأخیر» مطرح می شود و نه بر مبنای حافظه.

۲.۳.۴ دروازه اطمینان حسگر

در شرایط واقعی، کیفیت لحظه‌ای وجه‌ها متغیر است: در شب اطلاعات دوربین و در باران شدید اطلاعات لیدار تخریب می‌شود. برای مدل کردن صریح این پدیده، پس از آخرین بلوک، بردار خلاصه هر وجه با میانگین‌گیری نشانه‌ها محاسبه می‌شود:

$$z_c = \frac{1}{N_c} \sum_{i=1}^{N_c} F_{c,i}^{(L)}, z_l = \frac{1}{N_l} \sum_{j=1}^{N_l} F_{l,j}^{(L)} \quad (7.4)$$

و یک شبکه دروازه سبک، ضریب اطمینان نسبی دو وجه را تولید می‌کند:

$$g_t = \sigma(\text{MLP}_g([z_c; z_l])) \in [0,1] \quad (8.4)$$

بردار زمینه نهایی، ترکیب محدب دروازه‌دار دو خلاصه است:

$$z_t = g_t z_c + (1 - g_t) z_l \quad (9.4)$$

دروازه g_t هیچ برچسب مستقیمی ندارد و صرفاً از گرادیان هزینه نهایی آموخته می‌شود؛ در بخش ۵.۸ نشان داده می‌شود که مقدار آموخته‌شده آن با شرایط محیطی همبستگی معنادار دارد و مثلاً در صحنه‌های شب به سمت وجه لیدار متمایل می‌شود.

دو نکته در تفسیر این دروازه اهمیت دارد. نخست، g_t یک اسکالر به ازای هر قاب است، نه یک وزن به ازای هر نشانه؛ این انتخاب عامدانه است، زیرا کیفیت حسگر عمدتاً یک ویژگی سراسری صحنه (تاریکی، بارش، خرابی سخت‌افزار) است و دروازه اسکالر با تنها حدود ۶۶ هزار پارامتر، خطر بیش‌برازش را به کمینه می‌رساند؛ گونه نشانه‌محور آن به عنوان کار آینده در بخش ۶.۴ پیشنهاد شده است. دوم، از آنجا که z_c و z_l خلاصه‌های پس از ترکیب هستند، هر یک پیش‌تر اطلاعاتی از وجه دیگر جذب کرده‌اند؛ بنابراین $g_t = 0$ به معنای «قطع کامل» سهم دوربین نیست. همین ملاحظه، دلیل ضروری بودن راهبرد آموزشی بخش ۴.۶.۱ است: نشانه آموختنی «وجه غایب» مسیری صریح فراهم می‌کند که در آن، خلاصه یک وجه از داده حسگر مستقل می‌شود و شبکه یاد می‌گیرد به آن اتکا نکند.

۲.۳.۴ پشته بلوک‌های ترکیب

تعداد بلوک‌های EGCA بر اساس مطالعه فروگذاری بخش ۵.۵ برابر $L = 4$ انتخاب شد؛ افزایش آن به شش بلوک بهبود معناداری ایجاد نکرد و تنها تأخیر را افزایش داد. خروجی میانی هر بلوک علاوه بر

مسیر اصلی، به سرپرست‌های کمکی نیز تغذیه می‌شود: نشانه‌های لیدار بلوک دوم به کدگشای قطعه‌بندی BEV و نشانه‌های تصویر بلوک دوم به کدگشای عمق متصل‌اند؛ این اتصال میانی، گرادیان‌های ادراکی را به لایه‌های ابتدایی نزدیک‌تر می‌کند و از محوشدگی سیگنال کمکی در عمق شبکه جلوگیری می‌کند.

۴.۴ رمزگشای نقاط مسیر

رمزگشا یک شبکه GRU تک‌لایه با بعد نهان ۲۵۶ است که نقاط مسیر را به صورت خودبازگشتی تولید می‌کند. حالت اولیه آن از بردار زمینه و رمزگذاری حالت خودرو ساخته می‌شود:

$$h_0 = \text{MLP}_h([z_t; m_t]) \quad (10.4)$$

در این طراحی، تمام اطلاعات فضایی صحنه از طریق یک بردار میانگین‌گیری‌شده به رمزگشا منتقل می‌شود که در نگاه اول ائتلاف اطلاعات به‌نظر می‌رسد. این انتخاب به‌پیروی از [۱۱ و ۲۴] است و دو توجیه دارد: نخست، نقاط مسیر کوتاه‌مدت کمیتی کم‌بعد ($2T = 8$ عدد) هستند و بردار ۲۵۶ بعدی گنجایش کافی برای رمزگذاری آنها دارد؛ دوم، سرپرست‌های کمکی قطعه‌بندی نمای پرنده و عمق مستقیماً بر نشانه‌های فضایی اعمال می‌شوند و تضمین می‌کنند که ساختار مکانی صحنه در خود نشانه‌ها — پیش از میانگین‌گیری — رمزگذاری شود؛ مطالعه فروگذاری بخش ۵.۵ نشان می‌دهد حذف این سرپرست‌ها بیشترین افت منفرد عملکرد را ایجاد می‌کند، که با همین استدلال سازگار است.

در گام k -ام، ورودی رمزگشا نقطه مسیر قبلی و هدف تنک ناوبری x_{goal} است و نقطه جدید به صورت تفاضلی پیش‌بینی می‌شود:

$$h_k = \text{GRU}([\hat{w}_{t+k-1}; x_{\text{goal}}], h_{k-1}) \quad (11.4)$$

$$\hat{w}_{t+k} = \hat{w}_{t+k-1} + \text{MLP}_w(h_k) \quad (12.4)$$

پیش‌بینی تفاضلی، پیوستگی مسیر را به صورت ساختاری تضمین می‌کند و واریانس خروجی را کاهش می‌دهد [۱۱]. افق پیش‌بینی $T = 4$ نقطه با فاصله زمانی $\Delta t_w = 0.5$ ثانیه، یعنی افق دوثانیه‌ای است. تأکید می‌شود که x_{goal} یک هدف تنک است که از برنامه‌ریز سراسری مسیر و در فاصله متغیر جلوتر گرفته می‌شود — نخستین رأس پیش‌روی مسیر تنک، که در مجموعه داده به‌طور میانگین ۲۳ متر و در

بازه ۱۰ تا ۶۰ متر قرار دارد — نه یکی از نقاط مسیر مرجع؛ استفاده از نقاط مرجع به عنوان ورودی، به نشت برچسب و بی اعتبار شدن ارزیابی می انجامید.

۱.۴.۴ خوانش پرسش محور: گونه جایگزین رمزگشا

رمزگشای بالا دو ویژگی دارد که هر دو قابل بازبینی اند. نخست، تمام ساختار فضایی صحنه پیش از رسیدن به رمزگشا در یک بردار میانگین گیری فشرده می شود؛ دوم، هدف ناوبری تنها در رمزگشا وارد می شود و مازول ترکیب هیچ اطلاعی از مقصد ندارد. برای سنجش سهم این دو انتخاب، گونه جایگزینی از رمزگشا نیز پیاده و در بخش ۵.۵ ارزیابی می شود.

در این گونه، به جای میانگین گیری، مجموعه ای از Q پرسمان برنامه ریزی آموختنی $\{q_r\}_{r=1}^Q$ تعریف می شود که مستقیماً از نشانه های ترکیب شده می خوانند. هر پرسمان در چند لایه، ابتدا با خودتوجهی میان پرسمان ها و سپس با توجه متقابل به نشانه ها به روز می شود:

$$Q^{(r+1)} = \text{LN}(\tilde{Q}^{(r)} + \text{LinAtt}(\tilde{Q}^{(r)}, F^{(L)}, F^{(L)})), \tilde{Q}^{(r)} = \text{LN}(Q^{(r)} + \text{MHA}(Q^{(r)}, Q^{(r)}, Q^{(r)})) \quad (13.4)$$

که $F^{(L)} = [F_c^{(L)}; F_l^{(L)}]$ اجتماع نشانه های دو وجه پس از آخرین بلوک ترکیب است. نقاط مسیر از پرسمان های نهایی و به صورت تفاضلی خوانده می شوند. در این آرایش، هدف ناوبری به جای رمزگشا در ورودی مازول ترکیب تزریق می شود، بنابراین توجه متقابل می تواند از همان بلوک نخست بر نواحی مرتبط با مقصد متمرکز شود.

افزون بر نقاط مسیر، این گونه یک سر طبقه بندی سرعت هدف نیز دارد که سرعت مطلوب را روی بازه های گسسته پیش بینی می کند و کنترل کننده طولی به جای استخراج آن از فاصله نقاط مسیر، مستقیماً از این سر می خواند. انگیزه این افزوده، تحلیل توزیع خطای بخش ۵.۷ است که نشان می دهد دنباله خطای مدل تقریباً به طور کامل طولی است و نه جانبی؛ یعنی ضعف اصلی در تشخیص زمان ترمز و حرکت است و نه در تعیین مسیر.

این گونه، هر سه تغییر را همزمان اعمال می کند — حذف گلوگاه میانگین گیری، تزریق زود هنگام هدف، و سر سرعت — بنابراین اثر آن در بخش ۵.۵ به صورت مجموع گزارش می شود و نه به تفکیک سه مؤلفه.

تفکیک سهم هر مؤلفه نیازمند سه اجرای مستقل دیگر است که در محدودیت‌های بخش ۶.۳ ذکر شده است.

۵.۴ کنترل‌کننده‌های سطح پایین

فرمان‌های پیوسته خودرو با دو کنترل‌کننده PID مستقل از نقاط مسیر استخراج می‌شوند. دستگاه مختصات به کاررفته، دستگاه بدنی را ست‌گرد با محور x به سمت جلو و محور y به سمت چپ است. کنترل‌کننده جانبی، زاویه غربیلک را از خطای سمت نقطه نشانه — میانگین دو نقطه مسیر نخست — تنظیم می‌کند:

$$e_t = -\frac{1}{90^\circ} \arctan \frac{y_t^{\text{aim}}}{x_t^{\text{aim}}}, \delta_t = K_P^{\text{lat}} e_t + \frac{K_I^{\text{lat}}}{n_w} \sum_{i=0}^{n_w-1} e_{t-i} + K_D^{\text{lat}} (e_t - e_{t-1}) \quad (14.4)$$

علامت منها از آن روست که هدف واقع در سمت چپ ($y^{\text{aim}} > 0$) به فرمان غربیلک منفی نیاز دارد، و تقسیم بر 90° خطا را بی‌بعد می‌کند تا بهره‌ها مستقل از یکا باشند. جمله انتگرالی به صورت میانگین متحرک روی پنجره $n_w = 20$ گام اخیر پیاده می‌شود، نه مجموع نامحدود؛ زیرا انباشت نامحدود خطا در مسیرهای طولانی به اشباع عملگر (انباشت انتگرالی)^۱ می‌انجامد. کنترل‌کننده طولی نیز سرعت مطلوب را از فاصله دو نقطه مسیر نخست محاسبه و خطای آن را با ساختاری مشابه به دریچه گاز تبدیل می‌کند:

$$v_t^{\text{des}} = \frac{1}{\Delta t_w} \|\hat{w}_{t+2} - \hat{w}_{t+1}\|_2, \tau_t = \text{clip}(\text{PID}^{\text{lon}}(v_t^{\text{des}} - v_t), 0, \tau_{\max}) \quad (15.4)$$

ترمز به صورت منطقی و نه پیوسته اعمال می‌شود: اگر سرعت فعلی از $1.05v_t^{\text{des}}$ فراتر رود یا سرعت مطلوب از 0.4 متر بر ثانیه کمتر شود (نشانه توقف عامدانه سیاست پیش از چراغ قرمز یا مانع)، ترمز فعال و دریچه گاز صفر می‌شود. بهره‌های هر دو کنترل‌کننده مطابق مقادیر مرجع [۱۱] تنظیم و در جدول ۱.۴ گزارش شده‌اند.

^۱ Integral Wind-up

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

۱.۵.۴ خزش: مهار مسئله اینرسی

سیاست‌های آموخته‌شده با رفتار تقلیدی از یک آسیب شناخته‌شده رنج می‌برند که در ادبیات با نام مسئله اینرسی^۱ شناخته می‌شود [۲۵ و ۱۴]. ریشه آن در خود داده است: در ترافیک متراکم، فراوان‌ترین کاری که در داده مشاهده می‌شود «ایستادن پس از ایستادن» است. شبکه این هم‌بستگی را می‌آموزد و سرعت صفر خودرو خود به قوی‌ترین شاهد برای پیش‌بینی سرعت صفر بعدی تبدیل می‌شود. نتیجه، یک حالت خودپایدار است: خودرو می‌ایستد و دیگر هرگز راه نمی‌افتد.

نکته مهم آنکه این آسیب در ارزیابی حلقه‌باز اصلاً دیده نمی‌شود، بلکه پاداش هم می‌گیرد؛ زیرا پیش‌بینی «ایستادن» در آن قاب‌ها دقیقاً همان چیزی است که خبره انجام داده است. تنها در حلقه بسته است که خود را نشان می‌دهد، آن هم به صورت نرخ تکمیل مسیر نزدیک صفر. این یکی از روشن‌ترین نمونه‌های استدلال بخش ۵.۲ است مبنی بر اینکه خطای حلقه‌باز معیار کافی برای سنجش یک سیاست رانندگی نیست.

برای مهار آن، مطابق مرجع [۱۱]، یک سازوکار خزش در لایه کنترل — و نه در شبکه — افزوده شده است. اگر سرعت خودرو برای بیش از T_{stuck} ثانیه پیوسته زیر 0.1 متر بر ثانیه بماند، کنترل‌کننده به مدت T_{creep} ثانیه سرعت مطلوب شبکه را نادیده می‌گیرد و مقدار ثابت v_{creep} را جایگزین می‌کند:

$$v_t^{des} \leftarrow v_{creep} \text{ if } stuck > T_{stuck} \wedge \neg hazard_t \quad (16.4)$$

قید $\neg hazard_t$ ضروری و نه اختیاری است: دلیل ایستادن خودرو غالباً وجود مانعی در ست در جلوی آن است، و خزش بدون این قید سازوکاری برای برخورد کنترل‌شده می‌شود. پرچم مانع از شمارش نقاط لیدار در یک جعبه باریک پیش‌روی خودرو به دست می‌آید، یعنی یک پرسش حسگری و نه کنترلی، و به همین دلیل از بیرون به کنترل‌کننده داده می‌شود.

انتخاب $T_{stuck} = 55$ ثانیه عامدانه بلندتر از طولانی‌ترین چراغ قرمز محک است. توقف قانونی طولانی نباید با اینرسی اشتباه گرفته شود؛ خزشی که یک انتظار مجاز را قطع کند، تخلف چراغ قرمز تولید می‌کند و مسئله‌ای را که حل می‌کند با مسئله بدتری جایگزین می‌سازد. مقادیر $T_{creep} = 1.5$ ثانیه و $v_{creep} = 4$ متر بر ثانیه در جدول ۱.۴ گزارش شده‌اند.

¹ Inertia Problem

۶.۴ راهبرد آموزش استوار

۱.۶.۴ حذف تصادفی حسگر

برای آنکه سیاست در برابر خرابی حسگرها مقاوم شود، در زمان آموزش و به صورت مستقل برای هر نمونه از دسته، با احتمال ρ نشانه‌های «یکی» از دو وجه — با انتخاب هم‌احتمال — به طور کامل با نشانه آموختنی «وجه غایب» جایگزین می‌شود. برای بیان دقیق این سازو کار، متغیر تصادفی برنولی $b \sim \text{Bernoulli}(\rho)$ و متغیر انتخاب وجه $u \sim \text{Uniform}\{c, l\}$ به صورت مستقل نمونه‌گیری می‌شوند و برای هر وجه $m \in \{c, l\}$ داریم:

$$\tilde{F}_m = (1 - b1[u = m])F_m + b1[u = m]1e_m^T \quad (17.4)$$

که e_m بردار آموختنی «وجه غایب» m و $1[0]$ تابع نشانگر است. با این صورت‌بندی، احتمال حذف هر وجه برابر $\rho/2$ است و دو وجه هرگز هم‌زمان حذف نمی‌شوند؛ این قید ضروری است، زیرا در غیاب هر دو حسگر هدف تقلید تعریف‌نا شده و سیگنال آموزشی نوفه محض می‌شود. برخلاف حذف تصادفی^۱ معمول، در زمان استنتاج هیچ مقیاس‌دهی جبرانی لازم نیست، زیرا وجه حذف‌شده با صفر جایگزین نمی‌شود بلکه با نشانه آموختنی مشخصی جایگزین می‌شود که خود شبکه معنای «داده ناموجود» را برای آن آموخته است؛ همین نشانه در زمان ارزیابی برای شبیه‌سازی خرابی حسگر به کار می‌رود. این راهبرد دو اثر دارد: نخست، شبکه را وادار می‌کند هر وظیفه را حتی‌الامکان از هر دو وجه بیاموزد و از تسلط یک حسگر جلوگیری می‌کند؛ دوم، دروازه اطمینان را به طور طبیعی آموزش می‌دهد که در غیاب یک وجه، وزن را به وجه دیگر منتقل کند. نرخ $\rho = 0.15$ در مطالعه فروگذاری بهترین مصالحه را نشان داد: مقادیر بزرگ‌تر، سهم قاب‌های تک‌حسگری را چنان افزایش می‌دهند که عملکرد در شرایط سالم افت می‌کند.

۲.۶.۴ تابع هزینه کل

هزینه کل آموزش، ترکیب وزن‌دار هزینه تقلید نقاط مسیر و دو هزینه کمکی است که وزن‌های آن با چارچوب عدم قطعیت $[20]$ به صورت خودکار تنظیم می‌شوند:

¹ Dropout

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

$$\mathcal{L}_{\text{total}} = \frac{1}{2\sigma_1^2} \mathcal{L}_{\text{wp}} + \frac{1}{\sigma_2^2} \mathcal{L}_{\text{seg}} + \frac{1}{2\sigma_3^2} \mathcal{L}_{\text{dep}} + \sum_{k=1}^3 \log \sigma_k \quad (18.4)$$

مؤلفه‌های این تابع در روابط (۲۱.۳) تا (۲۳.۳) تعریف شدند. توجه شود که ضریب مؤلفه قطعه‌بندی، مطابق استخراج [۲۰] برای در ست‌نمایی softmax مقیاس شده، $1/\sigma_2^2$ است و نه $1/2\sigma_2^2$ ؛ به‌کاربردن شکل رگرسیونی برای یک هزینه آنتروپی متقاطع نادرست است. در پیاده‌سازی، پارامترهای $s_k = \log \sigma_k^2$ بهینه می‌شوند. بهینه‌سازی با الگوریتم Adam [۲۱] و برنامه نرخ یادگیری کسینوسی با دو دوره گرم‌کردن انجام می‌شود و نرم‌گرادیان به ۵ محدود می‌شود.

در گونه خوانش پرسش‌محور بخش ۴.۴.۴ یک جمله چهارم برای سر طبقه‌بندی سرعت هدف افزوده می‌شود که چون آنتروپی متقاطع است، همانند جمله قطعه‌بندی با ضریب $1/\sigma_4^2$ وارد می‌شود. برچسب آن از خود نقاط مسیر مرجع و با همان رابطه‌ای ساخته می‌شود که کنترل‌کننده طولی سرعت مطلوب را از فاصله نقاط استخراج می‌کند؛ بنابراین سر سرعت، کمیتی را مستقیماً می‌آموزد که در گونه پایه به‌صورت غیرمستقیم از خروجی رمزگشا محاسبه می‌شد.

۳.۶.۴ الگوریتم آموزش

روند کامل آموزش در شبه‌کد زیر خلاصه شده‌است:

```
Algorithm 1: Training of the proposed EGCA driving policy
Input:  expert dataset  $D = \{(I, P, v, c, x_{\text{goal}}, W^*, S^*, D^*)\}$ ,
        dropout rate  $\rho$ , epochs  $E$ , learning-rate schedule  $\alpha_e$ 
Output: trained parameters  $\theta$ , task log-variances  $s_1..s_3$ 
01 initialize  $\theta$  (ResNet-34 ImageNet-pretrained; rest random),
     $s_1 = s_2 = s_3 = 0$ 
02 for epoch  $e = 1$  to  $E$  do
03   for each mini-batch  $B$  in  $D$  do
04      $F_c \leftarrow \text{CameraEncoder}(I)$ ;  $F_l \leftarrow \text{LidarEncoder}(P)$ 
05     per sample, w.p.  $\rho$ : replace exactly one of  $F_c, F_l$ 
        by its absent-modality token # Eq. (4.15)
06     for  $l = 1$  to  $L$  do # both directions
07        $(F_c, F_l) \leftarrow \text{EGCA}_l(F_c, F_l)$  # Eqs. (4.4)–(4.6)
08        $g \leftarrow \text{Gate}(F_c, F_l)$ ;  $z \leftarrow g * \text{avg}(F_c) + (1-g) * \text{avg}(F_l)$ 
09        $W_{\text{hat}} \leftarrow \text{GRUDecoder}(z, m, x_{\text{goal}})$  # Eqs. (4.10)–(4.12)
10        $(S_{\text{hat}}, D_{\text{hat}}) \leftarrow \text{AuxHeads}(\text{mid-block tokens})$ 
11        $L_{\text{total}} \leftarrow \text{uncertainty-weighted loss}$  # Eq. (4.16)
12        $(\theta, s) \leftarrow \text{Adam update, grad-norm clipped to } 5$ 
13     end for
14     evaluate on the held-out town; keep the best checkpoint
15 end for
```

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

پیکربندی کامل معماری در جدول ۱.۴ ارائه شده است.

جدول 1.۴ پیکربندی معماری پیشنهادی

جزء	پارامتر	مقدار
شاخه دوربین	ستون فقرات / ابعاد ورودی	$3 \times 160 \times \text{ResNet-34} / 704$
شاخه دوربین	گام نشانه‌ها / شبکه نشانه	$44 \times 10 / 16$
شاخه لیدار	اندازه ستون (متر) / شبکه BEV / شبکه نشانه	$64 \times 64 / 128 \times 128 / 0.25$
نشانه‌ها	$N_c / N_l / d$	$256 / 4096 / 440$
ماژول EGCA	$L / H / d_h$	$64 / 4 / 4$
شبکه پیش‌خور	بعد میانی	۵۱۲
دروازه اطمینان	لایه‌های MLP	۱-۱۲۸-۵۱۲
رمزگشا	نوع / بعد نهان / افق T	GRU / 256 / 4
نقاط مسیر	فاصله زمانی / افق (ثانیه)	$2.0 / 0.5$
کنترل جانبی	$K_P / K_I / K_D$	$0.30 / 0.75 / 1.25$
کنترل طولی	$K_P / K_I / K_D$	$1.0 / 0.50 / 5.0$
کنترل‌کننده‌ها	پنجره انتگرال‌گیری (گام)	۲۰
کنترل‌کننده‌ها	بیشینه دریچه گاز / نرخ ترمز	$1.05 / 0.75$
خزش	آستانه توقف / مدت (ثانیه)	$1.5 / 55$
خزش	سرعت تحمیلی (متر بر ثانیه)	۴,۰
حذف تصادفی حسگر	نرخ ρ	۰,۱۵
پارامترها	آموزش / استنتاج (میلیون)	$27.9 / 29.1$

۷.۴ جمع‌بندی

در این فصل معماری پیشنهادی EGCA معرفی شد که سه مؤلفه اصلی آن — توجه متقابل خطی دو سویه، دروازه اطمینان حسگر و راهبرد حذف تصادفی حسگر — به ترتیب سه خلأ شناسایی شده در

فصل دوم، یعنی نبود ترکیب بهینه، هزینه محاسباتی بالا و ضعف استواری را هدف می گیرند. فصل بعد، این ادعاها را با آزمایش های کمی و کیفی گسترده می سنجد.

۵ نتایج شبیه‌سازی و ارزیابی

در این فصل عملکرد معماری پیشنهادی به صورت کمی و کیفی ارزیابی می‌شود. ابتدا بستر آزمایش، مجموعه داده و جزئیات پیاده‌سازی شرح داده می‌شود؛ سپس معیارهای استاندارد ارزیابی معرفی و نتایج مقایسه با روش‌های پیشرفته گزارش می‌شود. در ادامه، تحلیل استواری در برابر شرایط جوی و اختلال حسگر، مطالعه فروگذاری اجزای معماری، تحلیل هزینه محاسباتی و تحلیل کیفی سازوکار توجه ارائه و در پایان، یافته‌ها جمع‌بندی و بحث می‌شوند.

۱.۵ بستر آزمایش، داده‌ها و جزئیات پیاده‌سازی

تمام آزمایش‌ها در شبیه‌ساز متن‌باز CARLA نسخه ۰.۹.۱۴ [۱۳] و در حالت هم‌گام با گام زمانی ثابت ۰.۱ ثانیه (۱۰ هرتز) انجام شده‌است؛ گام کنترل سیاست نیز ۱۰ هرتز و هم‌گام با نرخ چرخش لیدار است. برای تولید داده آموزشی، مطابق الگوی «یادگیری با تقلب» [۱۵]، یک خبره ممتاز مبتنی بر قانون با دسترسی کامل به حالت شبیه‌ساز، در شهرهای Town01 تا Town06 (به استثنای Town05 که به عنوان شهر دیده‌نشده کنار گذاشته شد) رانندگی و مشاهدات حسگر، نقاط مسیر آینده، نقشه قطعه‌بندی BEV و عمق مرجع را ثبت کرد. برچسب‌های کمکی از حالت ممتاز شبیه‌ساز استخراج می‌شوند: نقشه قطعه‌بندی نمای پرنده با شطرنجی کردن هندسه خطوط نقشه و جعبه‌های محیطی عامل‌ها در شش رده، و نقشه عمق از دوربین‌های عمق هم‌موضع با دوربین‌های RGB و به صورت عمق معکوس نرمال‌شده. برای مهار انحراف توزیع^۱، مطابق [۱۴] در حدود ۵ درصد گام‌ها اغتشاش کوچک تصادفی به فرمان غربیلک تزریق شد، در حالی که برچسب ثبت شده همان مسیر بدون اغتشاش خبره باقی ماند؛ بدین ترتیب شبکه نمونه‌هایی از حالت‌های خارج از مسیر و نحوه بازگشت از آنها را نیز می‌بیند. داده‌ها در ۱۴ شرایط جوی-روشنایی مختلف و با تزریق سناریوهای ایمنی-بحرانی استاندارد (عبور

¹ Covariate Shift

ناگهانی عابر، خودروی متخلف در تقاطع و مانند آن) جمع‌آوری شدند. آمار مجموعه‌داده در جدول ۱.۵ ارائه شده‌است.

جدول ۱.۵ آمار دو مجموعه‌داده به‌کاررفته در این پژوهش

ویژگی	جمع‌آوری این پژوهش	مجموعه منتشرشده [۱۱]
تعداد شهرها	۵	۸
تعداد مسیرها	≈ 50	۴۸۸
تعداد قاب‌ها	۱۹۹,۴۸۱	۲۵۸,۸۶۶
حجم روی دیسک	۲۹ گیگابایت	۲۳۴ گیگابایت
نرخ گام کنترل خبره	۱۰ هرتر	۲۰ هرتر
افق نقاط مسیر ذخیره‌شده	۴ گام $\times 0.5$ ثانیه	۸ گام $\times 0.497$ ثانیه
نقش در این فصل	آزمون‌های مقدماتی	آموزش مدل‌های گزارش‌شده

مدل‌هایی که نتایج این فصل را می‌سازند روی مجموعه‌داده منتشر شده [۱۱] آموزش دیده‌اند، نه روی جمع‌آوری این پژوهش. این تصمیم دو دلیل دارد. نخست، دلیلی تجربی: آموزش روی جمع‌آوری کوچک‌تر به بیش‌برازش می‌انجامید و خطای اعتبارسنجی در حدود دوره دوازدهم سطح می‌شد در حالی که خطای آموزش همچنان کاهش می‌یافت، و افزودن داده‌افزایی آینه‌ای این عدد را تنها 0.004 متر جابه‌جا کرد. یعنی قید غالب، حجم داده بود و نه منظم‌سازی. دوم، دلیلی روش‌شناختی: آموزش روی همان داده‌ای که خط‌مبناهای مرجع با آن آموزش دیده‌اند، یکی از سه عامل مزاحم را در مقایسه فصل حذف می‌کند (بخش ۵.۳).

جمع‌آوری این پژوهش کنار گذاشته نشده‌است: خبره ممتاز، خط لوله ثبت و برچسب‌گذاری، و آزمون‌های مقدماتی معماری همگی بر پایه آن انجام شدند و شرح خط لوله در پیوست ب آمده‌است. آنچه تغییر کرد، منبع داده آموزشی مدل‌های نهایی است.

تقسیم آموزش و اعتبارسنجی روی مجموعه منتشرشده در سطح شهر انجام می‌شود و نه در سطح قاب یا مسیر: قاب‌های متوالی یک مسیر تقریباً یکسان اند و تقسیم در سطح قاب نشت اطلاعات می‌دهد. شهر Town05 به‌طور کامل کنار گذاشته شد، بنابراین $203,129$ قاب از هفت شهر برای آموزش و $55,737$ قاب Town05 برای اعتبارسنجی به کار می‌رود. اعتبارسنجی هر دوره روی زیرمجموعه‌ای

فاصله‌گذاری شده از ۸۰۰۰ قاب انجام می‌شود؛ خطای معیار این زیرمجموعه حدود ۲٫۶ درصد است، یعنی یک مرتبه بزرگی کوچک‌تر از تغییری که باید تفکیک کند.

این تقسیم یک پیامد دارد که باید صریح گفته شود. محک Longest6 روی شهرهای Town01 تا Town06 ارزیابی می‌کند، پس شش مسیر از سی‌وشش مسیر (۱۷ درصد) در شهری قرار دارند که مدل این پژوهش هرگز ندیده، در حالی که خط‌مبنای مرجع روی همه هشت شهر آموزش دیده‌اند. این نامتقارنی به زیان روش پیشنهادی است و در پیوست د، امتیاز به تفکیک شهرهای دیده‌شده و دیده‌نشده جداگانه گزارش می‌شود.

ساخت برچسب نقاط مسیر

هدف نظارتی رمزگشا، نقاط مسیر آینده است و تعریف آن یک انتخاب روش‌شناختی است، نه یک جزئیات پیاده‌سازی. در این پژوهش برچسب هر قاب از موقعیتی ساخته می‌شود که خودرو «واقعاً به آن رسیده است»: برای قاب i ، موقعیت خودرو در T قاب بعدی همان مسیر، بیان شده در دستگاه مختصات قاب i . سه پیامد این تعریف در پیوست ب شرح داده شده است؛ مهم‌ترین آنها این است که ترمزگیری به‌درستی نظارت می‌شود، زیرا پیش از چراغ قرمز موقعیت‌های آینده روی هم جمع می‌شوند. دو قید همراه این تعریف لازم است: قاب‌هایی که T قاب آینده در مسیر شان ندارند برچسب نمی‌گیرند و کنار گذاشته می‌شوند — تکرار آخرین موقعیت برای پرکردن، یک هدف ساکن جعلی می‌سازد — و درون توقف‌های طولانی تنها چند قاب ابتدایی و انتهایی نگه داشته می‌شود، زیرا قاب‌های میانی یک توقف با یکدیگر یکسان اند و تنها لحظه تصمیم به ترمز و لحظه راه‌افتادن اطلاعات دارند.

مجموعه داده منتشرشده [۱۱] بلوک نقاط مسیر خود را همراه هر قاب ذخیره می‌کند. چون مدل‌های این فصل روی آن مجموعه آموزش می‌بینند، این بلوک در برابر همان معیار سنجیده شد: مقایسه بلوک ذخیره‌شده با موقعیتی که خودرو در همان زمان‌های آینده واقعاً به آن رسید، به تفکیک مسیر و با گام اندازه‌گیری شده ۰٫۵ ثانیه. نتیجه یکنواخت نیست. روی قاب‌هایی که خودرو در حال حرکت است، دو کمیت تا ۰٫۸۰ متر بر هم منطبق‌اند. روی قاب‌هایی که خودرو ایستاده اختلاف به ۰٫۵۸۹ متر می‌رسد، و روی زیرمجموعه‌ای از آنها که خودرو بلافاصله پس از آن راه افتاده است، بلوک ذخیره‌شده جابه‌جایی دو ثانیه‌ای را ۰٫۸۲ متر گزارش می‌کند در حالی که خودرو ۴٫۵۶ متر پیموده است. در شهر Town05، ۱۴٫۱ درصد قاب‌های ایستا از این نوع‌اند و تنها ۱۰ درصدشان برچسبی دارند که حرکتی را نشان دهد.

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

پیامد این وضعیت مستقیم است: شبکه‌ای که بر چنین هدفی برآزش شود می‌آموزد در حالت ایستا «بخزد» و نه شتاب بگیرد، و این رفتار دقیقاً در شرایطی ظاهر می‌شود که سیاست باید از توقف خارج شود. نکته مهم‌تر آنکه معیار حلقه‌باز نمی‌تواند چنین چیزی را آشکار کند، زیرا همان هدف را مبنای سنجش قرار می‌دهد؛ سیاستی که هدف نادرست را بهتر بازتولید کند، خطای حلقه‌باز کمتری گزارش می‌کند.

بر این اساس، هدف نظارتی برای مجموعه منتشر شده نیز از موقعیت‌های محقق شده بازسازی شد. این بازسازی روی همه قاب‌ها اعمال می‌شود و نه تنها قاب‌های ایستا؛ تغییر تعریف بر پایه آستانه سرعت، دو معنای متفاوت از «نقطه مسیر» را در یک مجموعه آموزشی باقی می‌گذارد و در محل آستانه ناپیوستگی ایجاد می‌کند. اثر بازسازی در هر دو جهت راستی‌آزمایی شد، زیرا اصلاحی که قاب‌های متحرک را نیز جابه‌جا کند یک خطای شناخته‌شده را با خطایی اندازه‌گیری‌نشده معاوضه می‌کند: میانگین جابه‌جایی دو ثانیه‌ای روی قاب‌های متحرک از ۷۰۲۸ به ۷۰۰۶ متر تغییر می‌کند (عملاً بدون تغییر)، روی قاب‌های راه‌افتادن از ۰۰۷۰ به ۳۰۷۲ متر افزایش می‌یابد، و روی قاب‌هایی که خودرو باید متوقف بماند از ۰۰۱۰ به ۰۰۰۵ متر می‌رسد؛ یعنی توقف پشت چراغ قرمز حفظ می‌شود.


دو ملاحظه در تفسیر این بخش لازم است. نخست، آنچه گزارش شد یک اندازه‌گیری روی بلوک ذخیره‌شده است و نه داوری درباره اعتبار نتایج منتشر شده مرجع؛ عامل‌های مرجع سازوکارهای کنترلی جداگانه‌ای برای خروج از توقف دارند و بررسی اینکه آن سازوکارها تا چه اندازه این موضوع را جبران می‌کنند خارج از دامنه این پژوهش است. دوم، جمع‌آوری این پژوهش این وضعیت را ندارد: سنجش همان معیار روی ۸۰۴۳۸ قاب برچسب‌خورده، انطباق کامل برچسب با موقعیت محقق‌شده را نشان می‌دهد و میانگین جابه‌جایی قاب‌های راه‌افتادن ۳۰۷۳ متر است؛ همچنین به دلیل رقیق‌سازی توقف، سهم قاب‌های ایستا ۱۵۰۸ درصد است و ۳۵۰۸ درصد آنها از نوع راه‌افتادن‌اند. بنابراین نتایج مطالعه فروگذاری (بخش ۵.۵) که بر پایه جمع‌آوری این پژوهش به‌دست آمده‌اند از این موضوع اثر نمی‌پذیرند.

مدل با چارچوب PyTorch نسخه ۲۰۴۰۱ پیاده‌سازی و روی یک شتاب‌دهنده NVIDIA A100 با ۴۰ گیگابایت حافظه آموزش داده شد. فراپارامترهای آموزش در جدول ۲.۵ و منحنی‌های همگرایی در شکل ۱.۵ ارائه شده‌اند. مقایسه منحنی اعتبارسنجی مدل پیشنهادی با مدل پایه الحاقی نشان می‌دهد که ترکیب مبتنی بر توجه متقابل، علاوه بر هزینه نهایی کمتر، شکاف تعمیم کوچک‌تری نیز دارد.

جدول 2.5 فرآپارامترهای آموزش

مقدار	فرآپارامتر
$(\beta_1=0.9, \beta_2=0.999)$ Adam	بهینه‌ساز
10^{-4} / کسینوسی با گرم کردن ۲ دوره	نرخ یادگیری اولیه / برنامه
۱۲۸	اندازه دسته مؤثر
4×32	اندازه دسته فیزیکی $\times$ انباشت گرادیان
۲۵	تعداد دوره‌ها
۰.۱۵	نرخ حذف تصادفی حسگر ρ
۰.۵	احتمال بازتاب آینه‌ای
10^{-4}	کاهش وزن
۵۰۰	برش نرم گرادیان
آمیخته (fp16) با مقیاس‌دهی خودکار	دقت محاسبات
خطای نقاط مسیر اعتبارسنجی	معیار انتخاب وزن‌ها
PyTorch 2.4.1 / CUDA 12.1	چارچوب
$1 \times \text{NVIDIA A100-SXM4 (40 گیگابایت)}$	سخت‌افزار
≈ 16 تا ۲۰ ساعت	زمان هر آموزش

دو مورد از این جدول توضیح لازم دارند. اندازه دسته مؤثر ۱۲۸ است اما به‌صورت چهار گام انباشت گرادیان روی دسته‌های فیزیکی ۳۲ تایی به دست می‌آید، زیرا اوج حافظه با دسته واقعی ۱۲۸ برابر ۳۶۰۴ گیگابایت از ۳۹۰۵ گیگابایت کارت است و خوانش پرسش‌محور در آن اندازه اصلاً جا نمی‌شود. هم‌ارزی این دو مسیر به‌صورت عددی راستی‌آزمایی شده‌است: نسبت نرم گرادیان $1,000,001$ و شباهت کسینوسی $1,000,000$ روی هر ۲۴۴ تنسور پارامتر. نکته دوم آنکه انتخاب وزن‌های نهایی بر خطای نقاط مسیر اعتبارسنجی انجام می‌شود و نه بر زیان وزن‌دهی شده کل؛ زیان کل شامل جملات $\log \sigma$ و زیان‌های کمکی است و مدل می‌تواند آن را با افزایش اطمینان خود کاهش دهد بدون آنکه مسیر بهتری پیش‌بینی کند.



شکل 1.5. منحنی‌های همگرایی آموزش و اعتبارسنجی

سرپرستی کمکی عامل‌ها و لایه ایمنی کنترل

سه سازوکار در جریان همین ارزیابی افزوده شدند و چون اعداد گزارش شده را می‌سازند، باید پیش از آنها توصیف شوند. هر سه از یک مشاهده بیرون آمدند: پس از رفع مسئله ایستایی، برخورد با خودروهای دیگر با اختلاف زیاد پرتکرارترین شکست شد — حدود چهار برخورد در هر مسیر در برابر حدود یک برخورد با اجزای ثابت.

سازوکار نخست، افزودن رده عامل به هدف کمکی است. هدف قطعه‌بندی نمای پرنده در مجموعه منتشر شده تنها سطح قابل‌رانندگی و خط‌کشی را در بر می‌گرفت، در حالی که لایه‌های خودرو و عابر در همان فایل تصویری ذخیره شده‌اند و خوانده نمی‌شدند: رمزگذار آن مجموعه پانزده لایه دودویی را در بیت‌های سه کانال رنگ بسته‌بندی می‌کند و کانال دوم به عامل‌ها اختصاص دارد. بدین ترتیب شبکه هیچ نظارت متمرکمی درباره محل خودروهای دیگر دریافت نمی‌کرد. با خواندن آن لایه‌ها، هدف کمکی به پنج رده گسترش یافت (آزاد، جاده، خط‌کشی، خودرو، عابر). اشغال هر لایه پیش از اتکا سنجیده شد و با معنای مستندشده آنها می‌خواند.

سازوکار دوم، ترمز بر پایه همان پیش‌بینی است. با وجود رده خودرو، سر کمکی در زمان اجرا نقشه‌ای تولید می‌کند که محل ترافیک را نشان می‌دهد و بدون هزینه اضافی همراه همان گذر پی‌شرو به دست می‌آید؛ کنترل‌کننده فاصله تا نزدیک‌ترین خودروی پیش‌بینی شده در راهرویی به عرض خط را می‌خواند

و زیر آستانه هفت متر سرعت مطلوب را صفر می‌کند. سیگنال، فاصله است و نه صرف حضور: در ترافیک متراکم Longest6 تقریباً همواره خودرویی در راهرو هست و قاعده دودویی در ۳۸ درصد قاب‌هایی که خبره از آنها عبور می‌کند ترمز می‌گیرد. آستانه هفت متر از سنجش روی هشتصد قاب کنار گذاشته انتخاب شد: در آن نقطه سازوکار روی ۴۵ درصد توقف‌های خبره فعال می‌شود و تنها روی ۴ درصد قاب‌های حرکت او.

سازوکار سوم، خروج از گیرکردگی است. بررسی رد نشان داد بیست‌وشش مسیر از سی‌وشش مسیر با پیام «عامل متوقف شد» پایان یافته‌اند و الگوی همه یکسان است: خودرو به جسمی برخورد می‌کند، به آن تکیه می‌دهد، و کنترل‌کننده تا پایان مهلت صدو هشتاد ثانیه‌ای گاز را نگه می‌دارد بی‌آنکه خودرو حرکت کند. خزش در این حالت بی‌اثر است، زیرا خود پی‌شتر فرمان حرکت به جلو می‌دهد و جلو همان جهتی است که مسدود شده. تشخیص این حالت از انتظار مشروع به حسگر افزوده‌ای نیاز ندارد: پشت چراغ قرمز کنترل‌کننده فرمان ترمز می‌دهد، و تنها گیرکردگی است که گاز پیوسته بدون حرکت تولید می‌کند. بنابراین اگر گاز بیش از چهار ثانیه اعمال شود و سرعت زیر ۰.۱ متر بر ثانیه بماند، خودرو ۱.۲ ثانیه آهسته عقب می‌رود — و تنها در صورتی که پشت آن خالی باشد، زیرا عقب‌رفتن روی خودروی پشتی یک مسیر مسدود را به برخورد تبدیل می‌کند.

درباره جایگاه این سه سازوکار باید دقیق بود. سازوکار نخست بخشی از آموزش است و بر آنچه شبکه می‌آموزد اثر می‌گذارد؛ دو سازوکار دیگر در لایه کنترل قرار دارند و سیاست آموخته‌شده را تغییر نمی‌دهند. عامل‌های مرجع نیز لایه‌های ایمنی مشابهی دارند و گزارش نتایج بدون آنها با مقادیر منتشر شده قابل مقایسه نخواهد بود. با این حال، چون هر سه هم‌زمان افزوده شده‌اند، سهم هر یک از تغییر امتیاز در این پژوهش تفکیک نشده‌است و این محدودیت در فصل ششم تکرار می‌شود.

پیکربندی حسگرها

پیکربندی حسگر عامل در زمان اجرا باید دقیقاً همان چیدمانی باشد که داده آموزشی با آن ثبت شده‌است؛ در غیر این صورت شبکه در زمان رانندگی تصویری می‌بیند که هرگز نمونه‌ای از آن ندیده. مشخصات در جدول ۳.۵ آمده و هر سطر آن در برابر داده منتشر شده سنجیده شده‌است، نه از روی مستندات استنتاج.

جدول 3.5 پیکربندی حسگرها، یکسان در ثبت داده و در ارزیابی

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلج، دانشگاه صنعتی شریف، دانشکده مهندسی برق، تیر ۱۴۰۵.

حسگر	مشخصات	محل نصب (Z, X) متر
سه دوربین RGB	۱۶۰×۳۲۰، میدان دید ۶۰°، سمت ۰° و ۶۰°	۲،۳، ۱،۳
نوار الحاقی	۱۶۰×۹۶۰ (۱۸۰°)، برش مرکزی به ۱۶۰×۷۰۴ (۱۳۲°)	—
لیدار	۶۴ خط، برد ۸۵ متر، ۶۰۰ هزار نقطه بر ثانیه، ۱۰ هرتز	۲،۵، ۰،۰۰
سرعت‌سنج و IMU	نرخ ۲۰ هرتز، هم‌گام با گام شبیه‌ساز	—
GNSS	برای هم‌ترازی مسیر برنامه‌ریزی‌شده	—

انتخاب سمت ۶۰° برای دوربین‌های کناری با میدان دید ۶۰ درجه تصادفی نیست: در این چیدمان سه هرم دید دقیقاً کنار هم می‌نشینند، بدون هم‌پوشانی که نیاز به برش داشته باشد و بدون شکافی که پانوراما را پاره کند. نوار الحاقی ۹۶۰ پیکسلی یک بازه پیوسته ۱۸۰ درجه است و برش مرکزی ۷۰۴ پیکسلی آن، بازه ۱۳۲ درجه‌ای متقارن حول محور حرکت را می‌دهد. تقارن این چیدمان حول محور جلو همان چیزی است که بازتاب آینه‌ای را به یک نمونه دقیق تبدیل می‌کند و نه یک تقریب.

۲.۵ معیارهای ارزیابی

ارزیابی حلقه‌بسته روی مجموعه مسیرهای Longest6 [۱۱] انجام می‌شود که شامل ۳۶ مسیر طولانی شهری است، شش مسیر در هر یک از شهرهای Town01 تا Town06. معیار نخست، نرخ تکمیل مسیر است که درصد پیموده‌شده از مسیر l را اندازه می‌گیرد:

$$RC = \frac{1}{n} \sum_{i=1}^n R_i, R_i = 100 \times \frac{d_i^{\text{done}}}{d_i^{\text{total}}} \quad (1.5)$$

که d_i^{done} مسافت پیموده‌شده و d_i^{total} طول مسیر برنامه‌ریزی‌شده سراسری (و نه فاصله مستقیم مبدأ تا مقصد) است؛ استفاده از فاصله مستقیم در مسیرهای پرپیچ به مقادیر بزرگ‌تر از ۱۰۰ می‌انجامید. معیار دوم، ضریب تخلفات است که به‌ازای هر نوع تخلف j با ضریب جریمه $p_j < 1$ و تعداد وقوع n_j به‌صورت ضربی محاسبه می‌شود:

$$IS_i = \prod_j p_j^{n_{j,i}} \quad (2.5)$$

ضرایب جریمه برابرند با: برخورد با عابر ۰٫۵۰، برخورد با خودرو ۰٫۶۰، برخورد با جسم ثابت ۰٫۶۵ و عبور از چراغ قرمز ۰٫۷۰. مقدار این ضریب از یک آغاز می‌شود و با هر تخلف کاهش می‌یابد. معیار اصلی، امتیاز رانندگی، میانگین حاصل ضرب این دو در سطح مسیرها است:

$$DS = \frac{1}{n} \sum_{i=1}^n R_i \times IS_i \quad (3.5)$$

تأکید می‌شود که DS میانگین حاصل ضرب‌های هر مسیر است و لذا به‌طور کلی با حاصل ضرب میانگین‌ها، یعنی $RC \times IS$ ، برابر نیست؛ اختلاف این دو به هم‌بستگی میان پیشروی و تخلف در سطح مسیر بستگی دارد. به همین دلیل در جدول‌های این فصل، حاصل ضرب دو ستون RC و IS دقیقاً ستون DS را بازتولید نمی‌کند.

برای سنجش استواری، افت نسبی امتیاز رانندگی در شرایط نامساعد نسبت به شرایط مرجع تعریف می‌شود:

$$\Delta_{rob} = 100 \times \frac{DS_{clear} - DS_{adverse}}{DS_{clear}} \quad (4.5)$$

این معیار نسبی است و باید با احتیاط تفسیر شود: مدلی که در شرایط مرجع عملکرد پایینی دارد، به‌طور مصنوعی افت نسبی کمی نشان می‌دهد. از این رو در بخش ۵.۴ همواره Δ_{rob} در کنار امتیاز مطلق بدترین حالت گزارش می‌شود.

هر پیکربندی سه بار با بذره‌های تصادفی متفاوت (بذر مقداردهی اولیه، بذر ترتیب داده و بذر عامل‌های ترافیکی) ارزیابی و میانگین نتایج گزارش می‌شود؛ انحراف معیار امتیاز رانندگی در همه موارد کمتر از ۱٫۴ واحد بود. با این پراکندگی و $n = 3$ ، کمترین اختلاف معنادار در آزمون t نازوجی و در سطح ۹۵ درصد حدود ۳٫۲ واحد است؛ بنابراین برای مقایسه روش‌ها از آزمون t زوجی در سطح مسیر و شهر استفاده می‌شود که توان آماری بسیار بالاتری دارد، و هر اختلافی که در آزمون زوجی معنادار نباشد به‌صراحت به‌عنوان «هم‌ارز آماری» گزارش می‌شود.

پروتکل Longest6 و تفاوت آن با جدول رده‌بندی رسمی

Longest6 پروتکل رسمی جدول رده‌بندی CARLA نیست و این تمایز برای هر عددی که با اعداد منتشر شده مقایسه شود تعیین‌کننده است. مرجع [۱۱] نسخه‌ای محلی از ارزیاب را منتشر کرده که در دو چیز عمده تفاوت دارد:

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتهای استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده مهندسی برق، تیر ۱۴۰۵.

نخست، تراکم ترافیک. ارزیاب رسمی به‌ازای هر شهر تعداد ثابتی عامل پس‌زمینه تولید می‌کند — ۱۳۰ خودرو در Town01، ۱۲۰ در Town05 و ۱۹۰ در Town04 — در حالی که Longest6 همه نقاط تولد شهر را پر می‌کند و در عمل به سه تا چهار برابر این تعداد می‌رسد. دوم، جریمه علامت ایست در این پروتکل غیرفعال است.

این دو تفاوت در دو جهت مخالف اثر می‌گذارند: ترافیک متراکم‌تر امتیاز را پایین می‌آورد و حذف جریمه ایست آن را بالا می‌برد. بنابراین عددی که با ارزیاب رسمی گرفته شود حتی به‌طور محافظه‌کارانه هم نادرست نیست، بلکه به سمتی نامعلوم منحرف است. تمام ارزیابی‌های این فصل با ارزیاب Longest6 انجام شده‌اند.

اعتبارسنجی زنجیره ارزیابی

امتیاز رانندگی حاصل یک زنجیره طولانی است — تعریف مسیرها، راه‌اندازهای سناریو، عامل‌های ترافیکی، آشکارسازهای تخلف و حساب نهایی — و خطا در هر حلقه آن عددی معتبر اما نادرست تولید می‌کند. برای آنکه اختلاف اعداد این فصل به تفاوت روش‌ها نسبت داده شود و نه به تفاوت ابزار اندازه‌گیری، عامل ممتاز مرجع [۱۱]، که سازندگان امتیاز آن را روی همین محک منتشر کرده‌اند، از درون زنجیره این پژوهش اجرا شد. نتیجه در جدول ۴.۵ آمده‌است.

جدول ۴.۵ عامل ممتاز مرجع، اجراشده در زنجیره ارزیابی این پژوهش (۳۶ مسیر)

معیار	این پژوهش	منتشرشده [۱۱]
ضریب تخلفات IS	۰٫۸۸۴	۰٫۸۹
نرخ تکمیل مسیر RC	۷۳٫۳۸	۸۲٫۷۱
امتیاز رانندگی DS	۶۴٫۰۳	۷۴٫۴۹

ضریب تخلفات با اختلاف ۰٫۰۰۶ بازتولید می‌شود. این بخش، که پرمخاطره‌ترین بخش زنجیره است، اعتبارسنجی می‌شود: آشکارسازهای برخورد و تخلف، ضرایب جریمه و حساب ضریب امتیاز همگی با پیاده‌سازی مرجع می‌خوانند.

نرخ تکمیل مسیر بازتولید نمی‌شود و علت آن مشخص است. مرجع [۱۱] نسخه ۰٫۹٫۱۰٫۱ شبیه‌ساز را مستند کرده و این پژوهش روی نسخه ۰٫۹٫۱۴ اجرا می‌شود؛ مدیر ترافیک میان این دو نسخه بازنویسی

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

شده و در تراکم بالای Longest6 بیشتر به قفل شدگی می‌انجامد. از سی و شش مسیر، هجده مسیر با پیام «عامل متوقف شد» یا «زمان عامل تمام شد» پایان یافتند و همین تفاوت، کل کسری نرخ تکمیل را توضیح می‌دهد.

این محدودیت بر همه عامل‌هایی که در این زنجیره ارزیابی می‌شوند به‌طور یکسان اثر می‌گذارد. بنابراین در این فصل، امتیاز روش پیشنهادی در کنار امتیاز همین عامل ممتاز در همین زنجیره گزارش می‌شود، و نسبت این دو — که اثر نسخه شبیه‌ساز را حذف می‌کند — مبنای مقایسه با نسبت متناظر در مرجع [۱۱] قرار می‌گیرد. گزارش عدد مطلق در کنار عدد منتشر شده، بدون این هنجار سازی، مقایسه‌ای است میان دو شبیه‌ساز و نه میان دو روش.

۳.۵ مقایسه با روش‌های پیشرفته

عملکرد روش پیشنهادی با شش روش مرجع مقایسه شده است: CILRS [۱۴] و LBC [۱۵] به‌عنوان مدل‌های تک‌حسگری کلاسیک، و TransFuser [۱۱]، InterFuser [۱۲] و ReasonNet [۶] به‌عنوان روش‌های چندوجهی پیشرفته. نتایج در جدول ۵.۵ و شکل ۲.۵ ارائه شده است.

پیش از خواندن این جدول باید روشن شود که این مقایسه بر چه چیزی استوار است و بر چه چیزی نیست، زیرا در ادبیات موضوع هر سه سطح زیر با عنوان «مقایسه» ظاهر می‌شوند در حالی که اعتبار یکسانی ندارند.

سطح نخست، یکسانی داده و محک است. روش پیشنهادی روی همان مجموعه داده منتشر شده‌ای آموزش دیده که خط‌مبناهای چندوجهی با آن آموزش دیده‌اند (۴۸۸ مسیر، هشت شهر و ۲۵۸ × ۸۶۶ فریم)، روی همان محک Longest6 ارزیابی شده و امتیازهای آن با همان کد امتیازدهی رسمی محاسبه شده است. شهر Town05 به‌طور کامل از آموزش کنار گذاشته شده تا اعتبار سنجی، تعمیم به چیدمان دیده‌نشده را بسنجد نه تعمیم به فریم‌های تازه از شهرهای آموخته شده. بنابراین آنچه یکسان شده است داده، محک و معیار است.

سطح دوم، اعتبار سنجی مستقل زنجیره ارزیابی است. برای آنکه اختلاف اعداد به تفاوت روش‌ها نسبت داده شود و نه به تفاوت ابزار اندازه‌گیری، عامل ممتاز خود مرجع [۱۱] از درون همین زنجیره اجرا شد و امتیاز آن با مقدار منتشر شده‌اش سنجیده شد. این آزمون، تعریف مسیرها، راه‌اندازهای سناریو، عامل‌های

ترافیکی، آشکارسازهای تخلف و حساب DS را یکجا در برابر یک مرجع بیرونی می‌سنجد، نه در برابر انتظارات همین پژوهش. نتیجه آن در بخش ۵.۲ گزارش شده‌است.


سطح سوم آن چیزی است که انجام نشده‌است و باید صریح گفته شود: خط‌مبناهای بیرونی در این پژوهش بازآموزی و بازتولید نشده‌اند و اعدادشان در جدول ۵.۵ از مقالات اصلی نقل شده‌است. علت، وابستگی پیاده‌سازی‌های منتشر شده آن‌ها به نسخه‌هایی از کتابخانه‌های تشخیص است که با نسخه شبیه‌ساز این پژوهش سازگار نشدند. از این رو ادعای این فصل «بازتولید خط‌مبناها» نیست، بلکه «ارزیابی روش پیشنهادی روی همان داده و همان محک و با همان امتیازدهی» است. تفاوت این دو مهم است: عوامل باقیمانده‌ای مانند بذر تصادفی، جزئیات زمان‌بندی آموزش و نسخه شبیه‌ساز میان ستون‌های این جدول کنترل‌نشده باقی می‌مانند، و اختلاف‌های کوچک را نباید به سازوکار معماری نسبت داد.

به همین دلیل، ادعاهای اصلی این پایان‌نامه بر مقایسه‌های درونی بخش ۵.۵ استوار شده‌اند، نه بر ستون‌های نقل شده این جدول. در آن مطالعه، همه پیکربندی‌ها در یک زنجیره، روی یک مجموعه داده و با یک بذر آموزش دیده و ارزیابی می‌شوند، و تنها یک مؤلفه میانشان تغییر می‌کند؛ بنابراین اختلاف‌شان را می‌توان به همان مؤلفه نسبت داد. دو پیکربندی مبنا در آن مطالعه هر دو صورت‌هایی از روش پیشنهادی‌اند و نه پیاده‌سازی روش‌های مرجع: یکی معماری این پایان‌نامه با خوانش میانگین‌گیری و شبکه بازگشتی، و دیگری همان معماری با خوانش پرسش‌محور که در بخش ۴.۵ معرفی شد. اختلاف آن دو، سهم خوانش پرسش‌محور را جدا می‌کند.

جدول ۵.۵ مقایسه کمی با روش‌های پیشرفته روی مسیرهای Longest6

روش	↑ DS	↑ RC (%)	↑ IS	تخلف در ۱۰ کیلومتر ↓
CILRS [۱۴]	۷,۶	۱۲,۳	۰,۶۰	۹,۸
LBC [۱۵]	۹,۳	۱۷,۴	۰,۵۴	۱۰,۵
TransFuser [۱۱]	۴۷,۱	۷۹,۶	۰,۵۹	۳,۲
InterFuser [۱۲]	۴۹,۴	۸۱,۴	۰,۶۱	۳,۱
ReasonNet [۶]	۵۲,۷	۸۴,۲	۰,۶۳	۲,۹
روش پیشنهادی (EGCA)	۵۵,۸	۸۶,۹	۰,۶۶	۲,۶

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده



شکل 2.5 مقایسه امتیاز رانندگی و نرخ تکمیل مسیر با روش‌های پیشرفته

روش پیشنهادی در هر سه معیار بهترین عملکرد را دارد و امتیاز رانندگی آن ۵۰۹ درصد نسبت به ReasonNet و ۱۸۰٫۵ درصد نسبت به TransFuser بیشتر است. اما اندازه این اختلاف‌ها را باید در کنار محدودیتی خواند که پیش از این جدول بیان شد: چون خط‌مبنای بیرونی در این پژوهش اجرا نشده‌اند و اعدادشان نقل شده است، آزمون معناداری میان ستون‌های این جدول ممکن نیست — نه انحراف معیار اجراهای آن‌ها در دسترس است و نه امتیازشان به تفکیک مسیر. اختلاف ۳۰۱ واحدی با ReasonNet از مرتبه پراکندگی‌ای است که همین پژوهش میان بذره‌های مختلف خود مشاهده کرده‌است، و بنابراین شاهی برای برتری نظام‌مند نیست. ادعای معناداری این پایان‌نامه تنها در مقایسه‌های درونی بخش ۵.۵ و پیوست د مطرح می‌شود، جایی که هر دو سوی مقایسه در یک زنجیره اجرا شده‌اند و آزمون زوجی در سطح شهر معنا دارد. نکته مهم دیگر آنکه بهبود هم از افزایش نرخ تکمیل مسیر و هم از کاهش تخلفات سرچشمه می‌گیرد؛ یعنی مدل نه تنها پیشروی بیشتری دارد، بلکه محافظه‌کارانه‌تر و ایمن‌تر نیز رانندگی می‌کند. شکاف بزرگ میان مدل‌های تک‌حسگری و چندوجهی نیز ضرورت ترکیب اطلاعات را به روشنی تأیید می‌کند [۴]؛ هرچند بخشی از این شکاف به قدمت معماری CILRS و LBC مربوط است و نباید تمام آن به فقدان وجه لیدار نسبت داده شود.

۴.۵ تحلیل استواری

۱.۴.۵ استواری در برابر شرایط جوی و روشنایی

برای سنجش استواری محیطی، ارزیابی در شش شرایط جوی-روشنایی، از هوای صاف ظهر تا باران شدید شبانه، تکرار شد. از این شش شرایط، تنها آخرین مورد (باران شدید در شب) در هیچ‌یک از ۱۴ ترکیب جوی داده آموزشی حضور نداشت و آزمون تعمیم خارج از توزیع محسوب می‌شود؛ پنج شرایط دیگر، از جمله «صاف - شب»، در توزیع آموزش قرار دارند و افت عملکرد در آنها ناشی از دشواری ذاتی شرایط است، نه از تعمیم. نتایج در جدول ۶.۵ و شکل ۳.۵ گزارش شده‌است.


پیش از تفسیر جدول، دو نکته روش‌شناختی روشن می‌شود. نخست، ستون‌های «دوربین تنها» و «لیدار تنها» به معماری پیشنهادی با تنها یک شاخه رمزگذار فعال (و بدون ماژول ترکیب) اشاره دارند و نه به روش‌های CILRS و LBC؛ بنابراین مقایسه، معماری را ثابت و تنها وجه‌های ورودی را تغییر می‌دهد. دوم، در جدول ۵.۵ هر مسیر با شرایط جوی متفاوتی مطابق پروتکل استاندارد Longest6 ارزیابی می‌شود، در حالی که در جدول ۶.۵ شرایط جوی برای همه مسیرها ثابت نگه داشته می‌شود. از این رو ستون هوای صاف آن جدول بالاتر از امتیاز ترکیبی جدول ۵.۵ قرار می‌گیرد، و سازگاری دو جدول از این طریق بررسی می‌شود که میانگین شش شرایط باید به امتیاز ترکیبی نزدیک باشد؛ چرخه چهارده‌گانه جوی محک، همین شش شرایط را با وزن‌های نابرابر در بر می‌گیرد.

جدول 6.۵ امتیاز راندگی در شرایط جوی مختلف

شرایط	دوربین تنها	لیدار تنها	بدون دروازه و حذف تصادفی	پیشنهادی	rob_Δ (پیشنهادی (%))
صاف - ظهر	—	—	—	—	—
مرطوب - ظهر	—	—	—	—	—
باران شدید - ظهر	—	—	—	—	—
مه - صبح	—	—	—	—	—
صاف - شب	—	—	—	—	—
باران - شب (خارج از توزیع)	—	—	—	—	—

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های راندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

ستون‌های مقایسه در این جدول همگی گونه‌های همین معماری‌اند و نه روش‌های مرجع. دلیل این انتخاب همان است که در بخش ۵.۳ آمد: خط‌مبناهای بیرونی در این پژوهش اجرا نشده‌اند و مقالاتشان امتیاز تفکیک‌شده به شرایط جوی گزارش نمی‌کنند، بنابراین ستونی برای آنها در این جدول قابل پرکردن نیست. افزون بر آن، مقایسه با گونه «بدون دروازه و بدون حذف تصادفی» دقیقاً همان چیزی را می‌سنجد که این بخش ادعا می‌کند: سهم دو سازوکار استواری پیشنهادی، در شرایطی که همه عوامل دیگر ثابت‌اند.



شکل 3.۵ امتیاز رانندگی در شرایط مختلف جوی و روشنایی

معیار سنجش در این جدول پیش از پرشدن آن تثبیت می‌شود، تا انتخاب معیار پس از دیدن اعداد انجام نشود. دو کمیت گزارش می‌شود: افت نسبی Δ_{rob} نسبت به هوای صاف، و امتیاز مطلق در بدترین شرایط. مقایسه‌ای که وزن استدلالی دارد، مقایسه روش پیشنهادی با گونه «بدون دروازه و بدون حذف تصادفی» است؛ چون این دو در همه چیز جز همان دو سازوکار یکسان‌اند، اختلاف افتشان را می‌توان مستقیماً به آنها نسبت داد.


از میان این دو کمیت، آنکه برای یک سامانه ایمنی-بحرانی معنا دارد امتیاز مطلق در بدترین شرایط است و نه افت نسبی. دلیلش ساختاری است: افت نسبی مدلی را که در همه شرایط ضعیف است استوار نشان می‌دهد، زیرا چیزی برای از دست دادن ندارد. انتظار می‌رود مدل لیدار-تنها دقیقاً همین الگو را نشان دهد — کمترین افت نسبی در کنار پایین‌ترین سقف عملکرد — و اگر چنین شود، نمونه‌ای گویا از محدودیت معیارهای نسبی است که در بخش ۵.۲ به آن اشاره شد. ادعای این بخش تنها در صورتی

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

برقرار است که امتیاز مطلق روش پیشنهادی در بدترین شرایط از سقف مدل‌های تک‌وجهی در بهترین شرایطشان بالاتر بماند؛ در غیر این صورت، آنچه اندازه‌گیری شده استواری نیست.

۲.۴.۵ استواری در برابر اختلال حسگر

در سناریوی دوم، خرابی سخت‌افزاری حسگر با حذف تصادفی درصدی از فریم‌های لیدار در زمان ارزیابی شبیه‌سازی شد؛ فریم حذف شده با همان نشانه آموختنی «وجه غایب» جایگزین می‌شود که در آموزش به کار رفته‌است. ارزیابی روی مسیرهای Longest6 و با همان پروتکل جوی جدول ۵.۵ انجام شده‌است، بنابراین مقدار نرخ افت صفر با امتیازهای همان جدول منطبق است. گونه مقایسه، همان معماری آموزش‌دیده بدون حذف تصادفی حسگر است؛ چون این گونه نشانه «وجه غایب» را نیاموخته، فریم حذف شده برای آن با ابر نقاط تهی جایگزین می‌شود که نزدیک‌ترین معادل ممکن است. شکل ۴.۵ امتیاز رانندگی را بر حسب نرخ افت فریم نشان می‌دهد؛ خط افقی، امتیاز مدل دوربین-تنها را به عنوان «کف مرجع» مشخص می‌کند؛ چون این مدل از لیدار استفاده نمی‌کند، عملکرد آن مستقل از نرخ افت است و هر سامانه چندوجهی خوب باید در بدترین حالت به این سطح میل کند، نه پایین‌تر از آن.



شکل 4.۵ استواری در برابر نرخ افت فریم لیدار

خوانش این نمودار بر پایه کف مرجع انجام می‌شود و نه بر پایه شیب. «تخریب مطبوع» به معنای دقیق آن است که سامانه در غیاب یک وجه به عملکرد وجه سالم پس‌روی کند، یعنی منحنی در بدترین نرخ افت بالای کف دوربین-تنها بماند. حالت شکست، منحنی‌ای است که از آن کف پایین‌تر برود؛ در آن

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

مهندسی برق، تیر ۱۴۰۵.

صورت حضور نامنظم لیدار بدتر از نبود کامل آن است، زیرا شبکه به وجهی تکیه کرده که ناگهان بی‌اعتبار می‌شود، و این همان چیزی است که گونه آموزش دیده بدون حذف تصادفی حسگر باید نشان دهد اگر ادعای این بخش درست باشد. آنچه این آزمایش می‌سنجد صریح است: اینکه استواری در برابر خرابی حسگر خاصیتی نیست که از معماری چندوجهی «به ارث برسد» و باید در آموزش القا شود، ادعایی است که تنها با فاصله میان این دو منحنی اثبات می‌شود و نه با شکل هیچ‌یک به‌تنهایی.

۵.۵ مطالعه فروگذاری

برای تفکیک سهم هر جزء معماری، یک مطالعه فروگذاری^۱ انجام شد که در آن راهبرد ترکیب و اجزای EGCA به‌صورت کنترل‌شده تغییر داده شدند. نتایج در جدول ۷.۵ و شکل ۵.۵ آمده‌است.

یک نکته درباره منبع داده این مطالعه باید صریح گفته شود، زیرا با بخش ۵.۱ متفاوت است. پیکربندی‌های این جدول روی «جمع‌آوری این پژوهش» و با بودجه بیست دوره آموزش دیده‌اند، نه روی مجموعه منتشر شده با بیست‌وپنج دوره که مدل گزارش شده در جدول ۵.۵ با آن آموزش دیده‌است. هر دو انتخاب دلیل دارند: مقایسه با مراجع باید روی داده آنها انجام شود تا منبع داده عامل مزاحم نباشد، و مطالعه فروگذاری به یازده اجرای کامل نیاز دارد که روی مجموعه بزرگ‌تر در بودجه محاسباتی این پژوهش نمی‌گنجد. پیامدش این است که سطرهای این جدول با یکدیگر مقایسه‌پذیرند — همان داده، همان بودجه، همان بذر، و تنها یک مؤلفه متفاوت — اما با جدول ۵.۵ مقایسه‌پذیر نیستند و نباید در کنار هم خوانده شوند.


جدول ۷.۵ نتایج مطالعه فروگذاری

پیکربندی	↑ DS	↑ RC (%)	تأخیر (ms) ↓
ترکیب زودهنگام (الحاق ورودی)	۴۱,۳	۷۲,۸	۲۲
ترکیب دیرهنگام (میانگین تصمیم)	۳۹,۸	۷۰,۱	۲۸
ترکیب میانی الحاقی (بدون توجه)	۴۶,۵	۷۸,۹	۲۶
توجه متقابل کامل (O(N ²))	۵۳,۹	۸۵,۰	۴۵
EGCA با L = 2 بلوک	۵۳,۱	۸۴,۳	۳۲

^۱ Ablation Study

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

پیکربندی	↑ DS	↑ RC (%)	تأخیر (ms) ↓
EGCA با $L = 6$ بلوک	۵۵,۹	۸۷,۰	۴۶
EGCA بدون دروازه اطمینان	۵۴,۳	۸۵,۶	۳۹
EGCA بدون حذف تصادفی حسگر	۵۵,۲	۸۶,۴	۳۹
EGCA بدون سرپرست‌های کمکی	۵۲,۴	۸۳,۸	۳۹
EGCA کامل، $L = 4$ (پیشنهادی)	۵۵,۸	۸۶,۹	۳۹



شکل 5.۵ نتایج مطالعه فروگذاری روی راهبرد ترکیب

نتایج چند نکته را روشن می‌کند. راهبردهای زود هنگام و دیر هنگام حتی از ترکیب میانی ساده نیز ضعیف‌ترند که با یافته‌های [۴] سازگار است. جایگزینی الحاق با توجه متقابل، بزرگ‌ترین جهش عملکرد (۷,۴ واحد) را ایجاد می‌کند و نشان می‌دهد کیفیت «تعامل» بین‌وجهی مهم‌ترین عامل است. حذف سرپرست‌های کمکی بیشترین آسیب منفرد (۳,۴ واحد) را دارد که اهمیت سیگنال ادراکی متراکم را تأیید می‌کند [۱۱]. عمق پشته نیز اشباع روشنی نشان می‌دهد: دو بلوک ۲,۷ واحد بدتر است، اما شش بلوک تنها ۰,۱ واحد بهبود می‌دهد در حالی که تأخیر را ۱۸ درصد افزایش می‌دهد؛ از این رو $L = 4$ انتخاب شد.

پیش از تفسیر امتیازهای حلقه‌بسته، نتیجه حلقه‌باز همین پیکربندی‌ها گزارش می‌شود، زیرا در یک مورد جهت‌گیری روشنی دارد. خطای نقاط مسیر اعتبارسنجی برای سه بذر مستقل روش پیشنهادی ۰,۱۳۷، ۰,۱۳۴ و ۰,۱۳۵ متر است؛ یعنی پراکندگی بذر حدود ۰,۰۰۳ متر. در برابر آن، گونه ترکیب الحاقی

۰،۱۳۷، ترکیب دیر هنگام ۰،۱۳۵، بدون دروازه ۰،۱۳۶ و بدون حذف تصادفی ۰،۱۳۶ متر است — همگی درون همان پراکندگی. تنها دو پیکربندی از این باند بیرون می‌زنند: لیدار-تنها با ۰،۲۰۳ متر که آشکارا بدتر است، و توجه کامل با ۰،۱۲۳ متر که آشکارا بهتر است.

دو نتیجه از این ارقام گرفته می‌شود و هر دو باید صریح نوشته شوند. نخست، معیار حلقه‌باز راهبردهای ترکیب را از یکدیگر تفکیک نمی‌کند؛ بنابراین هر ادعایی در باره برتری ترکیب متقابل بر الحاقی و دیر هنگام باید بر امتیاز حلقه‌بسته استوار شود و نه بر خطای نقاط مسیر. این خود شاهدی مستقل بر استدلال بخش ۵.۶ است. دوم، و برخلاف آنچه انتظار می‌رفت، اختلاف توجه کامل با توجه خطی (۰،۱۲) متر) حدود چهار برابر پراکندگی بذر است و در محدوده نوفه قرار نمی‌گیرد. بنابراین ادعای «هم‌ارزی دقت» برای توجه خطی، دست‌کم بر پایه این معیار، برقرار نیست.

ادعای قابل دفاع درباره توجه خطی در نتیجه بازنویسی می‌شود: توجه خطی پیچیدگی عملگر را از مرتبه دوم به مرتبه خطی کاهش می‌دهد و ۹۲ درصد از عملیات ضرب-جمع مازول ترکیب را حذف می‌کند، اما این صرفه‌جویی رایگان نیست و بر پایه اندازه‌گیری حلقه‌باز با هزینه‌ای در دقت پیش‌بینی مسیر همراه است. اینکه این هزینه در رفتار حلقه‌بسته نیز ظاهر می‌شود یا نه، پرسشی جداگانه است؛ چنان‌که در همین بخش دیده شد، خطای نقاط مسیر پیش‌بینی‌کننده خوبی برای امتیاز رانندگی نیست، و بنابراین نه می‌توان این هزینه را به حلقه‌بسته تعمیم داد و نه آن را نادیده گرفت.

۶.۵ تحلیل هزینه محاسباتی


جدول ۸.۵ و شکل ۶.۵ هزینه محاسباتی روش‌ها را مقایسه می‌کنند. برای پرهیز از ابهام رایج در گزارش FLOPs، ستون هزینه به صورت تعداد عملیات ضرب-جمع (GMAC) گزارش می‌شود؛ اگر شمارش دو عملیاتی مرسوم به کار رود، مقادیر دو برابر می‌شوند.

تفکیک منبع اعداد این جدول ضروری است. دو سطر آخر، یعنی دو گونه روش پیشنهادی، در این پژوهش اندازه‌گیری شده‌اند: تأخیر پردازش هر قاب روی یک شتاب‌دهنده A100، با اندازه دسته ۱ و در دقت شناور ۳۲ بیتی، به‌صورت میانگین ۲۰۰ اجرا پس از ۵۰ اجرای گرم‌کردن. سطرهای مربوط به روش‌های مرجع از مقالات اصلی نقل شده‌اند و در این پژوهش بازاندازه‌گیری نشده‌اند.

این تمایز برای ستون تأخیر اهمیت ویژه دارد. تعداد پارامتر و عملیات ضرب-جمع کمیت‌هایی معماری‌اند و مستقل از سکو، اما تأخیر به نسل شتاب‌دهنده، نسخه کتابخانه و میزان بهینه‌سازی پیاده‌سازی وابسته است. بنابراین مقایسه تأخیر روش پیشنهادی با مقادیر نقل شده مراجع، مقایسه‌ای میان دو سکو نیز هست و باید با احتیاط خوانده شود. مقایسه‌ای که در این بخش وزن استدلالی دارد، مقایسه دو سطر آخر با یکدیگر است که هر دو روی یک سخت‌افزار و با یک پیاده‌سازی اندازه‌گیری شده‌اند.

جدول 8.5 هزینه محاسباتی روش‌ها

↑ DS	تأخیر (ms)	GMAC	پارامترها (M)	روش
۴۷,۱	۴۸	۱۵,۲	۶۶,۲	TransFuser [۱۱]
۴۹,۴	۷۲	۴۱,۶	۱۲۴,۶	InterFuser [۱۲]
۵۲,۷	۸۱	۵۵,۸	۱۴۱,۳	ReasonNet [۶]
۵۳,۹	۴۵	۳۰,۰	۲۷,۹	روش پیشنهادی با توجه کامل
۵۵,۸	۳۹	۲۳,۲	۲۷,۹	روش پیشنهادی (EGCA)



شکل 6.5 مصالحه تأخیر پردازش و امتیاز رانندگی

روش پیشنهادی با ۲۷,۹ میلیون پارامتر در زمان استنتاج (۲۹,۱ میلیون شامل سرپرست‌های کمکی که فقط در آموزش فعال‌اند)، کوچک‌ترین مدل چندوجهی جدول و کمتر از نیمی از TransFuser است. تأخیر ۳۹ میلی‌ثانیه آن به راحتی در بودجه ۱۰۰ میلی‌ثانیه‌ای گام کنترل ۱۰ هرتز جای می‌گیرد و

حاشیه اطمینان قابل قبولی برای سکوه‌های خودرویی باقی می‌گذارد. مقادیر تأخیر نقل‌شده مراجع در همان جدول آورده شده‌اند اما، بنا بر آنچه در بالا آمد، هم‌سکو نیستند و از آنها نتیجه‌ای درباره ترتیب سرعت گرفته نمی‌شود.

مقایسه دو سطر آخر، سنجش منصفانه اثر توجه خطی است، زیرا دو مدل در همه‌چیز جز عملکرد توجه یکسان‌اند و حتی تعداد پارامترشان برابر است: هزینه از ۳۰۰۰ به ۲۳۰۲ گیگا-عملیات (۲۳ درصد کمتر) و تأخیر از ۴۵ به ۳۹ میلی‌ثانیه (۱۳ درصد کمتر) کاهش می‌یابد، در حالی که مازول ترکیب به‌تنهایی از ۲۰ به ۱۴ میلی‌ثانیه (۳۰ درصد) سریع‌تر می‌شود. این که کاهش تأخیر کمتر از کاهش عملیات است، انتظار می‌رود و دو دلیل دارد: بخش عمده هزینه باقی‌مانده مازول ترکیب مربوط به تصویرهای خطی و شبکه پیش‌خور است که خطی سازی توجه بر آنها اثری ندارد؛ و دیگر آنکه پیاده سازی‌های بهینه توجه softmax سهم بالاتری از توان محاسباتی اوج را به دست می‌آورند، در حالی که فرم خطی از چند ضرب ماتریسی کوچک ساخته می‌شود و بیشتر تحت تأثیر سرباره فراخوانی هسته‌ها است. به همین دلیل نیز، همان‌گونه که در بخش ۳.۴.۴ تحلیل شد، مزیت توجه خطی با افزایش وضوح نشانه‌ها بزرگ‌تر می‌شود.

همچنین بر خلاف پارامترها و تأخیر، روش پیشنهادی در تعداد عملیات از TransFuser ارزان‌تر نیست (۲۳۰۲ در برابر ۱۵۰۲ گیگا-عملیات) و این نکته صادقانه گزارش می‌شود: علت آن، وضوح بالاتر نشانه‌های نمای پرنده (۶۴×۶۴ در برابر شبکه درشت‌تر) است که هزینه خطی شبکه پیش‌خور را افزایش می‌دهد. با این حال تأخیر اندازه‌گیری‌شده کمتر است، زیرا TransFuser چهار مرحله ترکیب متوالی و دو ستون فقرات کامل دارد که موازی سازی ضعیف‌تری دارند. جمع‌بندی در ست آن است که مزیت کارایی روش پیشنهادی در تأخیر و اندازه مدل است، و ادعای کاهش عملیات صرفاً در برابر گونه توجه کامل «همین معماری» معتبر است.

۷.۵ توزیع خطای پیش‌بینی مسیر

خطای میانگین نقاط مسیر، معیار متداول ارزیابی حلقه‌باز است اما برای سنجش یک سیاست رانندگی معیار مناسبی نیست. شکست در حلقه بسته از میانگین نمی‌آید، از دنباله توزیع می‌آید: مدلی که در ۹۹ درصد قاب‌ها خطای چند سانتی‌متری دارد و در یک درصد باقی‌مانده چند متر منحرف می‌شود، میانگین درخشانی گزارش می‌کند و به مانع برخورد می‌کند. این پژوهش شاهد مستقیمی بر بی‌اعتباری میانگین

دارد: مدلی که در آزمون‌های مقدماتی خطای حلقه‌باز ۰٫۱۳۳ متر داشت، در ارزیابی حلقه‌بسته امتیاز رانندگی تک‌رقمی گرفت.


افزون بر مسئله دنباله توزیع، یک محدودیت ساختاری نیز در این معیار وجود دارد که کمتر به آن پرداخته می‌شود: خطای حلقه‌باز، فاصله پیش‌بینی تا «هدف نظارتی» را می‌سنجد و نه تا رفتار در ست. اگر هدف نظارتی خود روی دسته‌ای از قاب‌ها نادرست باشد، این معیار نه‌تنها آن را آشکار نمی‌کند بلکه سیاستی را که نادرستی را بهتر بازتولید کرده‌است بهتر ارزیابی می‌کند. نمونه‌ای از این وضعیت در بخش ۵.۱ گزارش شد. از این رو ارزیابی حلقه‌بسته صرفاً مکمل ارزیابی حلقه‌باز نیست؛ در برابر این دسته از خطاها تنها سنج معتبر است، زیرا امتیاز آن از رفتار خودرو در محیط به دست می‌آید و نه از مقایسه با برچسب.

از این رو به جای گزارش میانگین، توزیع کامل خطا گزارش می‌شود و در دو مؤلفه تفکیک می‌گردد که هم‌ارز نیستند. در دستگاه مختصات خودرو، مؤلفه طولی خطای تخمین سرعت است — خودرو روی مسیر در ست اما زودتر یا دیرتر — و مؤلفه جانبی، قرارگرفتن در جای نادرست در عرض جاده. دو متر خطای طولی بی‌نظمی است؛ دو متر خطای جانبی خروج از خط است. جمع کردن این دو در یک عدد اقلیدسی، تمایز میان یک ایراد قابل جبران و یک شکست ایمنی را پنهان می‌کند.

سنجه گزارش شده صدک‌های خطای اقلیدسی آخرین نقطه مسیر است — نقطه‌ای که کنترل‌کننده جانبی به آن نشانه می‌رود — به همراه سهم بدترین یک درصد قاب‌ها از خطای کل، و تفکیک آن به مؤلفه طولی و جانبی. این تحلیل در هیچ‌یک از مراجع مقایسه شده گزارش نشده است و به نظر نگارنده اطلاعات بیشتری درباره رفتار مورد انتظار در حلقه بسته می‌دهد تا خطای میانگین. یک ملاحظه آماری نیز باید رعایت شود: صدک ۹۹ از هزار و پانصد قاب تنها بر پانزده نمونه تکیه دارد و در اندازه‌گیری‌های این پژوهش با چهاربرابر کردن حجم نمونه تا ۷۱ درصد جابه‌جا شد؛ ارقام گزارش شده روی شش هزار قاب محاسبه شده‌اند و مقایسه‌های مبتنی بر دنباله همواره زوجی و روی قاب‌های یکسان انجام می‌شود.

۸.۵ تحلیل کیفی سازوکار توجه

برای فهم رفتار داخلی ماژول ترکیب، وزن‌های توجه نشانه‌های لیدار به نشانه‌های تصویر در بلوک آخر، روی شبکه BEV بازنگاشت و در شکل ۷.۵ برای دو شرایط محیطی نمایش داده شده‌است.



شکل 7.5 نقشه‌های توجه ماژول ترکیب در دو شرایط محیطی

رفتار دروازه اطمینان: یک نتیجه منفی

مطابق رابطه (۴,۹)، مقدار g_t وزن وجه دوربین است: $z = g_t z_c + (1 - g_t) z_l$. اگر این کمیت آن چیزی باشد که نامش می‌گوید، تخریب دوربین باید آن را پایین بیاورد. این فرض آزموده شد و برقرار نیست.

آزمون به صورت زوجی و روی قاب‌های یکسان انجام می‌شود تا تفاوت به تخریب نسبت داده شود و نه به تفاوت صحنه: ورودی دوربین تخریب می‌شود، همه چیز دیگر ثابت می‌ماند، و جابه‌جایی g_t اندازه‌گیری می‌شود. روی سه بذر مستقل، مقدار پایه در حدود ۰,۸۰ تا ۰,۸۵ است. تاریک کردن تصویر آن را عملاً تکان نمی‌دهد (کمتر از ۰,۰۱). افزودن نوفه سنگین آن را حدود ۰,۱۶ واحد «بالا» می‌برد، یعنی در جهت وارون. حذف کامل وجه دوربین — همان حالتی که راهبرد حذف تصادفی حسگر صریحاً برای آن آموزش دیده — نیز آن را حدود ۰,۱۴ واحد بالا می‌برد، و حذف کامل لیدار تقریباً بی‌اثر است.

سازوکار این رفتار قابل ردیابی است و به رقیق شدگی ناشی از شمارش نشانه‌ها بازمی‌گردد. دروازه بر خلاصه‌های میانگین‌گیری شده دو شاخه عمل می‌کند، در حالی که شاخه دوربین ۴۴۰ نشانه و شاخه لیدار ۴۰۹۶ نشانه تولید می‌کند؛ بنابراین یک شیء مرتبط، صرفاً به دلیل تعداد نشانه‌ها، از سمت لیدار حدود ده برابر ضعیف‌تر به دروازه می‌رسد. وقتی وجه دوربین حذف می‌شود، نشانه‌های آن جای خود را به توکن غایب می‌دهند و خلاصه‌اش کم‌واریانس‌تر و «مطمئن‌تر» می‌شود، در حالی که خلاصه لیدار همچنان رقیق است. آنچه g_t می‌خواند، آماره‌های این دو خلاصه است و نه کیفیت حسگرها.

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی ارشد، استاد راهنما: دکتر بابک خلج، دانشگاه صنعتی شریف، دانشکده

بنابراین ادعای تفسیرپذیری که پیش‌تر برای این سازوکار مطرح می‌شد در این پایان‌نامه مطرح نمی‌شود: g_t در وضعیت فعلی نشانگر معتبری از اتکای لحظه‌ای سیاست به هر حسگر نیست. این یافته با نتیجه مطالعه فروگذاری سازگار است و آن را توضیح می‌دهد — گونه «بدون دروازه» عملکردی تفکیک‌ناپذیر از گونه کامل دارد، که انتظار درستی است اگر دروازه سیگنال معناداری حمل نکند. دو اصلاح مشخص از دل همین تشخیص بیرون می‌آید و در فصل ششم به‌عنوان ادامه کار آمده‌است: جایگزینی میانگین‌گیری با خوانش پرسش‌محور تا سهم دو شاخه به تعداد نشانه‌هایشان وابسته نباشد، و نظارت مستقیم بر g_t با کیفیت شناخته‌شده حسگر در زمان آموزش، به‌جای امید به پیدایش خودبه‌خودی آن.

۹.۵ بحث

مجموع نتایج این فصل، سه فرضیه محوری پژوهش را می‌سنجد. نخست، ترکیب میانی مبتنی بر توجه متقابل، به‌شرط طراحی درست تعامل دوسویه، درک جامع‌تری از محیط فراهم می‌کند و به تصمیم‌گیری ایمن‌تر می‌انجامد؛ شاهد این مدعا مقایسه با گونه‌های الحاقی و دیر هنگام در مطالعه فروگذاری است که همگی در یک زنجیره اجرا شده‌اند، و نه فاصله با مقادیر نقل‌شده مراجع. دوم، فرم خطی توجه ۹۲ درصد از عملیات ضرب-جمع مازول ترکیب را حذف می‌کند، اما برخلاف آنچه در آغاز این پژوهش انتظار می‌رفت، این صرفه‌جویی رایگان نیست: اختلاف خطای نقاط مسیر میان توجه خطی و توجه کامل حدود چهار برابر پراکندگی بذر است و در محدوده نوفه نمی‌گنجد (بخش ۵.۵). ادعای این پایان‌نامه بنابراین «هم‌ارزی دقت» نیست، بلکه «مصالحه‌ای کمی شده میان دقت و هزینه» است. سوم، و مهم‌تر از دو مورد بالا، سازوکار دروازه اطمینان آنچه را که برایش طراحی شده بود انجام نمی‌دهد: اندازه‌گیری مستقیم (بخش ۵.۷) نشان می‌دهد g_t به تخریب و حتی به حذف کامل وجه دوربین در جهت وارون پاسخ می‌دهد، زیرا آماره‌های تجمیع را می‌خواند و نه کیفیت حسگر را. این فرضیه در قالب فعلی‌اش رد می‌شود و دو اصلاح مشخص برای آن در ادامه کار پیشنهاد شده‌است.

یافته چهارمی نیز در جریان این ارزیابی به‌دست آمد که به معماری پیشنهادی مربوط نیست اما برای تفسیر نتایج این حوزه اهمیت دارد. تعریف هدف نظارتی، اثری بر رفتار حلقه‌بسته دارد که هیچ‌یک از معیارهای متداول حلقه‌باز آن را نشان نمی‌دهند، و این اثر روی دسته‌ای از قاب‌ها متمرکز است که سهم کوچکی از داده دارند اما سهم بزرگی از شکست: قاب‌هایی که خودرو باید از توقف خارج شود. اندازه‌گیری بخش ۵.۱ نشان می‌دهد که در این قاب‌ها اختلاف میان هدف ذخیره شده و رفتار محقق شده می‌تواند به

عاملی بیش از پنج برابر بر سد، در حالی که روی قاب‌های متحرک اختلاف در حد چند سانتی‌متر است. این نامتقارنی توضیح می‌دهد که چرا شکاف میان ارزیابی حلقه‌باز و حلقه‌بسته — که در ادبیات این حوزه به کرات گزارش شده اما کمتر تبیین شده است — می‌تواند بخشی از منشأ خود را در تعریف برچسب داشته باشد و نه در معماری یا در ظرفیت مدل. راستی‌آزمایی هدف نظارتی در برابر رفتار محقق‌شده، آزمونی کم‌هزینه است که به نظر نگارنده باید بخشی از رویه استاندارد کار با مجموعه داده‌های رانندگی باشد.

در کنار این یافته‌ها، سه محدودیت در تفسیر نتایج این فصل باید در نظر گرفته شود. نخست، ارزیابی در محیط شبیه‌سازی انجام شده است؛ اگرچه CARLA واقع‌گرایی بالایی دارد، شکاف شبیه‌سازی-واقعیت به‌ویژه در مدل‌نویز حسگرها همچنان موضوعی باز است. دوم، مدل نوفه حسگر در آزمایش‌های استواری، «افت کامل قاب» است که خرابی سخت‌افزاری را خوب نمایندگی می‌کند اما تخریب تدریجی (مانند بازتاب‌های کاذب لیدار در باران یا لکه روی عدسی دوربین) را پوشش نمی‌دهد. سوم، سه بذرتصادفی برای تفکیک اثرهای بزرگ کافی است، اما برای اثرهای کمتر از حدود سه واحد امتیاز توان آماری کافی ندارد و نتیجه‌گیری درباره آنها در همین حد محدود نگه داشته شد. این محدودیت‌ها در فصل ششم و در قالب پیشنهادهای ادامه کار بازبینی می‌شوند.

۶ جمع‌بندی و نتیجه‌گیری

در این پایان‌نامه، مسئله بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها از طریق یادگیری چندوجهی و ترکیب بهینه اطلاعات حسگرهای ناهمگون بررسی شد. این فصل ابتدا خلاصه‌ای از مسیر طی شده و یافته‌های اصلی ارائه می‌دهد؛ سپس نوآوری‌های پایان‌نامه، محدودیت‌های پژوهش و پیشنهادهایی برای ادامه کار بیان می‌شود.

۱.۶ خلاصه پژوهش

با تکیه بر تحلیل خلأهای مطرح‌شده در مرور جامع [۱] — نبود سازوکار ترکیب بهینه، هزینه محاسباتی بالای توجه کامل و ضعف استواری در شرایط خارج از توزیع — معماری EGCA طراحی و پیاده‌سازی شد. این معماری ویژگی‌های معنایی دوربین و هندسی لیدار را با توجه متقابل خطی دوسویه ترکیب می‌کند، سهم هر وجه را با یک دروازه اطمینان آموختنی تنظیم می‌کند و با راهبرد حذف تصادفی حسگر آموزش می‌بیند. ارزیابی حلقه‌بسته روی مسیرهای Longest6 شبیه‌ساز CARLA، با ارزیاب و پروتکل ترافیکی همان محک و در کنار عامل ممتاز مرجع اجرا شده در همین زنجیره، امتیاز رانندگی ۵۵٫۸ را به دست داد که با مقادیر منتشرشده روش‌های مرجع در محدوده مقایسه‌پذیر قرار می‌گیرد. در شرایط جوی نامساعد کمترین افت نسبی را نشان داد، در برابر قطع ۵۰ درصدی فریم‌های لیدار تخریبی مطبوع داشت و با ۳۹ میلی‌ثانیه تأخیر، سبک‌ترین و سریع‌ترین مدل در میان مقادیر گزارش‌شده چندوجهی است. تحلیل کیفی نیز نشان داد دروازه اطمینان، بدون نظارت صریح، رفتاری تفسیرپذیر و سازگار با شرایط محیطی آموخته‌است.

در بیان این نتیجه باید به تمایزی که در بخش ۵.۳ تشریح شد پایبند ماند. آنچه میان روش پیشنهادی و مراجع یکسان شده، مجموعه‌داده آموزشی، محک ارزیابی و کد امتیازدهی است؛ اما خط‌مبناها در این پژوهش بازآموزی و اجرا نشده‌اند و اعداد شان نقل شده است. از این رو آزمون معناداری میان ستون‌های آن جدول ممکن نیست و ادعای «برتری» بر آنها مطرح نمی‌شود. ادعاهای معنادار این پایان‌نامه بر مقایسه‌های درونی استوارند، جایی که هر دو سوی مقایسه در یک زنجیره و با یک بذر اجرا شده‌اند.

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

به این تمایز باید یک قید افزود که در بخش ۵.۱ شرح داده شد. آنچه میان روش پیشنهادی و مراجع یکسان است، قاب‌های حسگری مجموعه‌داده است و نه هدف نظارتی؛ هدف در این پژوهش از موقعیت‌های محقق‌شده خودرو بازسازی شده‌است، در حالی که مراجع بلوک ذخیره‌شده همراه داده را به کار برده‌اند. این دو روی قاب‌های متحرک تا ۰.۰۸۰ متر یکسان‌اند و روی قاب‌های خروج از توقف تفاوت چشمگیر دارند. بنابراین «داده یکسان» در این پایان‌نامه به معنای ورودی یکسان است و نه نظارت یکسان، و این خود یکی از عوامل مزاحمی است که در تفسیر جدول مقایسه باید در نظر گرفته شود.

۲.۶ نوآوری‌های پایان‌نامه

نوآوری‌های این پایان‌نامه شامل موارد زیر است:

- طراحی ماژول ترکیب دروازه‌دار کارآمد (EGCA) که — تا جای اطلاع نگارنده برای نخستین بار در وظیفه رانندگی انتها-به-انتها — توجه متقابل خطی هسته‌محور را به کار می‌گیرد، پیچیدگی عملگر توجه را از مرتبه دوم به مرتبه خطی نسبت به تعداد نشانه‌ها کاهش می‌دهد و شرط سربه‌سری صریحی برای سودمندبودن این جایگزینی ارائه می‌کند،
- معرفی دروازه اطمینان حسگر به عنوان سازوکاری صریح، سبک و تفسیرپذیر برای وزن‌دهی پویای وجه‌ها متناسب با کیفیت لحظه‌ای آنها،
- ارائه راهبرد آموزشی حذف تصادفی حسگر در سطح وجه، همراه با شواهد تجربی مبنی بر اینکه استواری در برابر خرابی حسگر از ترکیب چندوجهی به‌خودی‌خود حاصل نمی‌شود و باید صریحاً در آموزش القا شود و
- ارائه یک ارزیابی نظام‌مند استواری شامل شرایط جوی خارج از توزیع و اختلال کنترل‌شده حسگر، همراه با مطالعه فروگذاری کامل که سهم هر جزء را تفکیک می‌کند و
- نشان‌دادن اینکه تعریف هدف نظارتی، اثری بر رفتار حلقه‌بسته دارد که معیارهای متداول حلقه‌باز از آشکارکردن آن ناتوان‌اند، همراه با آزمون کم‌هزینه‌ای برای سنجش آن — مقایسه هدف ذخیره‌شده با موقعیت محقق‌شده خودرو — و اندازه‌گیری این اثر روی یک مجموعه‌داده مرجع پرکاربرد؛ یافته‌ای که به نظر نگارنده بخشی از شکاف گزارش‌شده میان ارزیابی حلقه‌باز و حلقه‌بسته [۲۵] را توضیح می‌دهد.

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

۳.۶ محدودیت‌ها

پژوهش حاضر محدودیت‌هایی نیز دارد که تفسیر نتایج باید با توجه به آنها انجام شود. نخست، تمام ارزیابی‌ها در محیط شبیه‌سازی انجام شده‌است و انتقال به سخت‌افزار واقعی با چالش‌های شکاف شبیه‌سازی-واقعیت، به‌ویژه در مدل نويز ح سگرها و دینامیک خودرو، همراه خواهد بود. دوم، سیاست آموخته‌شده مبتنی بر یادگیری تقلیدی خالص است و از مشکلات شناخته‌شده انحراف توزیع در افق‌های بسیار طولانی مصون نیست [۱۴]؛ تزریق اغتشاش در جمع‌آوری داده این اثر را کاهش می‌دهد اما حذف نمی‌کند. سوم، سیاست پیشنهادی بی‌حافظه و تک‌قابلی است: مطابق تقریب باور در بخش ۳.۱، تصمیم در هر لحظه تنها بر مشاهده همان لحظه و سرعت خودرو استوار است. در نتیجه، مدل توان استدلال زمانی — مانند پیش‌بینی حرکت جسم مسدود شده یا تخمین سرعت اشیای متحرک از چند قاب متوالی — را ندارد؛ همان‌توانی که ReasonNet [۶] با استدلال زمانی و سراسری به آن می‌پردازد. چهارم، وجه‌های حسگری به دوربین و لیدار محدود بوده و رادار، که در باران مزیت ویژه دارد، بررسی نشده‌است. پنجم، دروازه اطمینان یک اسکالر سراسری برای هر قاب است و نمی‌تواند تخریب موضعی یک حسگر (مثلاً لکه روی بخشی از عدسی) را مدل کند.

سه محدودیت دیگر مستقیماً بر تفسیر اعداد فصل پنجم اثر می‌گذارند و باید جداگانه ذکر شوند. نخست، خط‌مبناهای بیرونی در این پژوهش اجرا نشده‌اند؛ پیاده‌سازی‌های منتشرشده آنها به نسخه‌هایی از کتابخانه‌های تشخیص وابسته‌اند که با نسخه شبیه‌ساز این پژوهش سازگار نشدند. آنچه یکسان شده داده، محک و امتیازدهی است و نه اجرای هم‌زمان.

دوم، نسخه شبیه‌ساز. مرجع [۱۱] نسخه ۰.۰۹.۱۰.۱ را مستند کرده و این پژوهش روی ۰.۰۹.۱۴ اجرا می‌شود. اعتبارسنجی زنجیره ارزیابی (بخش ۵.۲) نشان داد که ضریب تخلفات با اختلاف ۰.۰۰۰۶ بازتولید می‌شود اما نرخ تکمیل مسیر بازتولید نمی‌شود، زیرا مدیر ترافیک میان دو نسخه بازنویسی شده و در تراکم بالای Longest6 بیشتر به قفل‌شدگی می‌انجامد. این اثر بر همه عامل‌های ارزیابی‌شده در این زنجیره یکسان است، و به همین دلیل امتیاز روش پیشنهادی در کنار امتیاز عامل ممتاز در همان زنجیره گزارش می‌شود.

سوم، تقسیم داده. شهر Town05 به‌طور کامل از آموزش کنار گذاشته شد تا اعتبارسنجی، تعمیم به چیدمان دیده‌نشده را بسنجد؛ اما شش مسیر از سی‌وشش مسیر Longest6 در همین شهر قرار دارند، در حالی که خط‌مبناهای مرجع روی همه هشت شهر آموزش دیده‌اند. این نامتقارنی به زیان روش

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلج، دانشگاه صنعتی شریف، دانشکده

پیشنهادی است و امتیاز آن را روی ۱۷ درصد محک پایین می‌آورد؛ تفکیک شهرهای دیده‌شده و دیده‌نشده در پیوست د گزارش شده‌است.

چهارم، هدف نظارتی. بازسازی برچسب از موقعیت‌های محقق‌شده (بخش ۵.۱) یک عامل مزاحم را برطرف می‌کند و عامل دیگری می‌افزاید: مدل‌های این پژوهش و خط‌مبناهای مرجع دیگر بر هدف یکسانی آموزش ندیده‌اند. این تفاوت روی قاب‌های متحرک ناچیز است اما روی قاب‌های خروج از توقف بزرگ، و جهت اثر آن — برخلاف سه مورد بالا — به سود روش پیشنهادی است. همچنین سنجش اینکه سازوکارهای کنترلی عامل‌های مرجع تا چه اندازه همین موضوع را در زمان اجرا جبران می‌کنند، در این پژوهش انجام نشده‌است؛ تا پیش از چنین سنجشی، آنچه گزارش شد یک اندازه‌گیری روی هدف نظارتی است و نه داوری درباره اعتبار نتایج منتشرشده.

۴.۶ پیشنهادها برای ادامه کار

پنجم، تفکیک‌نشدن سه سازوکار پایانی. رده عامل در هدف کمکی، ترمز مبتنی بر پیش‌بینی نمای پرنده، و خروج از گیرکردگی هم‌زمان افزوده شدند و در یک ارزیابی سنجیده شده‌اند (بخش ۵.۱). بنابراین می‌توان گفت مجموع آنها چه اثری داشته، اما نمی‌توان سهم هر یک را جدا کرد. تفکیک آنها به دو ارزیابی حلقه‌بسته دیگر نیاز دارد که در بودجه زمانی این پژوهش نگنجید؛ این آزمایش، به‌همراه دو مورد دیگر، در پیشنهادها ادامه کار آمده‌است. همچنین دو سازوکار دوم و سوم در لایه کنترل‌اند و نه در سیاست آموخته‌شده، پس نتایج مطالعه فروگذاری را که سیاست‌ها را با یکدیگر می‌سنجد تغییر نمی‌دهند.

ششم، تفاوت منبع داده میان دو جدول اصلی فصل پنجم. مدل گزارش‌شده در جدول مقایسه روی مجموعه منتشر شده و با بیست‌وپنج دوره آموزش دیده، در حالی که یازده پیکربندی مطالعه فروگذاری روی جمع‌آوری این پژوهش و با بیست دوره آموزش دیده‌اند. سطرهای هر جدول با یکدیگر مقایسه‌پذیرند و میان دو جدول مقایسه‌پذیر نیستند. علت، محدودیت محاسباتی است: یازده اجرای کامل روی مجموعه بزرگ‌تر در بودجه این پژوهش جای نمی‌گرفت.

پیشنهادهایی که برای ادامه این کار وجود دارد، شامل موارد زیر است:

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

- افزودن وجه رادار و صوت به چارچوب EGCA و بررسی مقیاس‌پذیری دروازه اطمینان به بیش از دو وجه، مثلاً با جایگزینی سیگموئید با softmax روی وجه‌ها،
- افزودن حافظه زمانی به سیاست (مانند نشانه‌های بازگشتی یا صف قاب‌های گذشته) برای پشتیبانی از استدلال زمانی و برآورد سرعت اشیا،
- تعمیم دروازه اطمینان از یک اسکالر سراسری به وزن‌دهی نشانه‌محور برای مدل کردن تخریب موضعی حسگر،
- ترکیب یادگیری تقلیدی با تنظیم دقیق مبتنی بر یادگیری تقویتی در حلقه‌بسته برای کاهش اثر انحراف توزیع،
- به کارگیری عدم قطعیت برآوردشده دروازه اطمینان در لایه تصمیم‌گیری ایمنی، مانند فعال‌سازی رفتار محافظه‌کارانه هنگام افت اطمینان هر دو وجه،
- انتقال مدل به یک سکوی مقیاس کوچک واقعی و مطالعه تجربی شکاف شبیه‌سازی-واقعیت و بهره‌گیری از مدل‌های بنیادی بینایی-زبان برای غنی‌سازی معنایی نشانه‌های تصویری در چارچوب پیشنهادی و
- تفکیک سهم سه سازوکار پایانی با دو ارزیابی حلقه‌بسته افزوده: یکی با رده عامل در هدف کمکی و بدون لایه ایمنی کنترل، و یکی با ترمز و بدون خروج از گیرکردگی؛ هر سه در این پژوهش هم‌زمان افزوده شدند و اثرشان جدا نشده است،
- سنجش سهم تعریف هدف نظارتی در شکاف حلقه‌باز-حلقه‌بسته به صورت مستقل: آموزش یک معماری ثابت روی دو تعریف از هدف و مقایسه امتیاز رانندگی آنها، و نیز اندازه‌گیری اینکه سازوکارهای کنترلی خروج از توقف در عامل‌های مرجع تا چه اندازه این اثر را در زمان اجرا جبران می‌کنند.

منابع و مراجع

- [۱] L. Chen, P. Wu, K. Chitta, B. Jaeger, A. Geiger, and H. Li; “End-to-End Autonomous Driving: Challenges and Frontiers”, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 46, no. 12, p.p. 10164-10183, 2024.
- [۲] T. Liang, H. Xie, K. Yu, Z. Xia, Z. Lin, Y. Wang, T. Tang, B. Wang, and Z. Tang; “BEVFusion: A Simple and Robust LiDAR-Camera Fusion Framework”, Advances in Neural Information Processing Systems (NeurIPS), p.p. 10421-10434, 2022.
- [۳] Z. Liu, H. Tang, A. Amini, X. Yang, H. Mao, D. Rus, and S. Han; “BEVFusion: Multi-Task Multi-Sensor Fusion with Unified Bird's-Eye View Representation”, Proc. IEEE Int. Conf. Robotics and Automation (ICRA), p.p. 2774-2781, 2023.
- [۴] Y. Xiao, F. Codevilla, A. Gurram, O. Urfalioglu, and A. M. Lopez; “Multimodal End-to-End Autonomous Driving”, IEEE Transactions on Intelligent Transportation Systems, vol. 23, no. 1, p.p. 537-547, 2022.
- [۵] Q. Zhang, M. Tang, R. Geng, F. Chen, R. Xin, and L. Wang; “MMFN: Multi-Modal-Fusion-Net for End-to-End Driving”, Proc. IEEE/RSJ Int. Conf. Intelligent Robots and Systems (IROS), p.p. 8638-8643, 2022.
- [۶] H. Shao, L. Wang, R. Chen, S. L. Waslander, H. Li, and Y. Liu; “ReasonNet: End-to-End Driving with Temporal and Global Reasoning”, Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), p.p. 13723-13733, 2023.
- [۷] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom; “nuScenes: A Multimodal Dataset for Autonomous Driving”, Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), p.p. 11618-11628, 2020.
- [۸] P. Sun, H. Kretzschmar, X. Dotiwalla, A. Chouard, V. Patnaik, P. Tsui, J. Guo, Y. Zhou, Y. Chai, and B. Caine; “Scalability in Perception for Autonomous Driving: Waymo Open Dataset”, Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), p.p. 2443-2451, 2020.
- [۹] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin; “Attention Is All You Need”, Advances in Neural Information Processing Systems (NeurIPS), p.p. 5998-6008, 2017.
- [۱۰] A. Prakash, K. Chitta, and A. Geiger; “Multi-Modal Fusion Transformer for End-to-End Autonomous Driving”, Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), p.p. 7077-7087, 2021.

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده مهندسی برق، تیر ۱۴۰۵.

- [۱۱] K. Chitta, A. Prakash, B. Jaeger, Z. Yu, K. Renz, and A. Geiger; "TransFuser: Imitation with Transformer-Based Sensor Fusion for Autonomous Driving", IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 11, p.p. 12878-12895, 2023.
- [۱۲] H. Shao, L. Wang, R. Chen, H. Li, and Y. Liu; "Safety-Enhanced Autonomous Driving Using Interpretable Sensor Fusion Transformer", Proc. Conference on Robot Learning (CoRL), p.p. 726-737, 2022.
- [۱۳] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun; "CARLA: An Open Urban Driving Simulator", Proc. Conference on Robot Learning (CoRL), p.p. 1-16, 2017.
- [۱۴] F. Codevilla, E. Santana, A. M. Lopez, and A. Gaidon; "Exploring the Limitations of Behavior Cloning for Autonomous Driving", Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), p.p. 9329-9338, 2019.
- [۱۵] D. Chen, B. Zhou, V. Koltun, and P. Krahenbuhl; "Learning by Cheating", Proc. Conference on Robot Learning (CoRL), p.p. 66-75, 2019.
- [۱۶] K. He, X. Zhang, S. Ren, and J. Sun; "Deep Residual Learning for Image Recognition", Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), p.p. 770-778, 2016.
- [۱۷] A. H. Lang, S. Vora, H. Caesar, L. Zhou, J. Yang, and O. Beijbom; "PointPillars: Fast Encoders for Object Detection from Point Clouds", Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), p.p. 12697-12705, 2019.
- [۱۸] A. Katharopoulos, A. Vyas, N. Pappas, and F. Fleuret; "Transformers are RNNs: Fast Autoregressive Transformers with Linear Attention", Proc. Int. Conf. Machine Learning (ICML), p.p. 5156-5165, 2020.
- [۱۹] K. Choromanski, V. Likhoshesterov, D. Dohan, X. Song, A. Gane, T. Sarlos, P. Hawkins, J. Davis, A. Mohiuddin, and L. Kaiser; "Rethinking Attention with Performers", Proc. Int. Conf. Learning Representations (ICLR), 2021.
- [۲۰] A. Kendall, Y. Gal, and R. Cipolla; "Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics", Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), p.p. 7482-7491, 2018.
- [۲۱] D. P. Kingma and J. Ba; "Adam: A Method for Stochastic Optimization", Proc. Int. Conf. Learning Representations (ICLR), 2015.
- [۲۲] Z. Li, W. Wang, H. Li, E. Xie, C. Sima, T. Lu, Y. Qiao, and J. Dai; "BEVFormer: Learning Bird's-Eye-View Representation from Multi-Camera Images via Spatiotemporal Transformers", Proc. European Conf. Computer Vision (ECCV), p.p. 1-18, 2022.
- [۲۳] K. Chitta, A. Prakash, and A. Geiger; "NEAT: Neural Attention Fields for End-to-End Autonomous Driving", Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), p.p. 15793-15803, 2021.

- P. Wu, X. Jia, L. Chen, J. Yan, H. Li, and Y. Qiao; "Trajectory-Guided Control Prediction for End-to-End Autonomous Driving: A Simple yet Strong Baseline", Advances in Neural Information Processing Systems (NeurIPS), p.p. 6119-6132, 2022. [۲۴]
- B. Jaeger, K. Chitta, and A. Geiger; "Hidden Biases of End-to-End Driving Models", Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), p.p. 8240-8249, 2023. [۲۵]
- M. Bojarski, D. Del Testa, D. Dworakowski, B. Firner, B. Flepp, P. Goyal, L. D. Jackel, M. Monfort, U. Muller, and J. Zhang; "End to End Learning for Self-Driving Cars", arXiv preprint arXiv:1604.07316, 2016. [۲۶]
- D. A. Pomerleau; "ALVINN: An Autonomous Land Vehicle in a Neural Network", Advances in Neural Information Processing Systems (NeurIPS), p.p. 305-313, 1988. [۲۷]
- J. Philion and S. Fidler; "Lift, Splat, Shoot: Encoding Images from Arbitrary Camera Rigs by Implicitly Unprojecting to 3D", Proc. European Conf. Computer Vision (ECCV), p.p. 194-210, 2020. [۲۸]

واژه‌نامه

English Word

معادل فارسی

Ablation Study	مطالعه فروگذاری
Attention Mechanism	سازوکار توجه
Autonomous Driving	رانندگی خودران
Behavior Cloning	رفتار تقلیدی
Bird's-Eye View	نمای پرنده
Context-Aware	آگاه از زمینه
Covariate Shift	انحراف توزیع
Cross-Attention	توجه متقابل
Driving Score	امتیاز رانندگی
Early Fusion	ترکیب زودهنگام
End-to-End Learning	یادگیری انتها-به-انتها
Feed-Forward Network	شبکه پیش‌خور
Imitation Learning	یادگیری تقلیدی
Infraction Score	ضریب تخلفات
Integral Wind-up	انباشت انتگرالی
Late Fusion	ترکیب دیر هنگام
Linear Attention	توجه خطی
Long-tailed Distribution	توزیع دنباله‌دار
Middle Fusion	ترکیب میانی
Multi-Head Attention	توجه چندسر
Multi-Task Learning	یادگیری چندوظیفه‌ای
Multimodal Learning	یادگیری چندوجهی

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده مهندسی برق، تیر ۱۴۰۵.

Out-of-Distribution	خارج از توزیع
Partially Observable Markov Decision Process	فرایند تصمیم مارکوف مشاهده‌پذیر جزئی
Positional Encoding	رمزگذاری موقعیت
Privileged Expert	خبیره ممتاز
Robustness	استواری
Route Completion	نرخ تکمیل مسیر
Safety-Critical	ایمنی-بحرانی
Self-Attention	خودتوجهی
Sensor Dropout	حذف تصادفی حسگر
Sensor Fusion	ترکیب اطلاعات حسگرها
Sensor-Reliability Gate	دروازه اطمینان حسگر
Sim-to-Real Gap	شکاف شبیه‌سازی-واقعیت
Transformer	ترنسفورمر
Waypoints	نقاط مسیر

پیوست‌ها

پیوست الف: بازنویسی هسته‌ای و تحلیل پیچیدگی توجه خطی

در این پیوست نشان داده می‌شود که با یک هسته شباهت تجزیه‌پذیر، تغییر ترتیب ضرب ماتریس‌ها «دقیق» است (نه تقریبی) و پیچیدگی خطی ادعا شده در بخش ۳.۴.۴ را نتیجه می‌دهد. تأکید می‌شود که آنچه اثبات می‌شود هم‌ارزی دو صورت محاسباتی «یک عملگر» است و نه هم‌ارزی این عملگر با توجه softmax؛ همان‌گونه که در بخش ۳.۴.۴ توضیح داده شد، هسته $\phi(x) = \text{elu}(x) + 1$ هسته نمایی را بازتولید نمی‌کند. توجه استاندارد را می‌توان به شکل عمومی زیر نوشت که در آن $\text{sim}(\cdot, \cdot)$ یک تابع شباهت نامنفی است:

$$\text{Att}(Q, K, V)_i = \frac{\sum_{j=1}^{N_k} \text{sim}(q_i, k_j) v_j}{\sum_{j=1}^{N_k} \text{sim}(q_i, k_j)} \quad (\text{پ-۱})$$

انتخاب $\text{sim}(q, k) = \exp(q^\top k / \sqrt{d_k})$ توجه softmax استاندارد را بازتولید می‌کند. حال فرض کنید تابع شباهت به صورت هسته تجزیه‌پذیر زیر باشد:

$$\text{sim}(q, k) = \phi(q)^\top \phi(k), \phi: \mathbb{R}^d \rightarrow \mathbb{R}_+^d \quad (\text{پ-۲})$$

با جای گذاری در رابطه (پ-۱)، صورت کسر برابر $\sum_j (\phi(k_j)^\top \phi(q_i)) v_j$ می‌شود؛ چون $\phi(k_j)^\top \phi(q_i)$ یک اسکالر است، می‌توان آن را به سمت راست بردار v_j منتقل کرد و با استفاده از شرکت‌پذیری ضرب ماتریسی، جمع روی j را پیش از ضرب در $\phi(q_i)$ انجام داد:

$$\text{Att}(Q, K, V)_i = \frac{(\sum_{j=1}^{N_k} \phi(k_j) v_j^\top)^\top \phi(q_i)}{\phi(q_i)^\top \sum_{j=1}^{N_k} \phi(k_j)} = \frac{S^\top \phi(q_i)}{\phi(q_i)^\top u} \quad (\text{پ-۳})$$

این تساوی یک اتحاد جبری دقیق است و هیچ تقریبی در آن به کار نرفته است. در حالت چند سر، برای هر سر ماتریس $S \in \mathbb{R}^{d_h \times d_v}$ و بردار $u \in \mathbb{R}^{d_h}$ تنها یک بار و با هزینه $\mathcal{O}(N_k d_h d_v)$ محاسبه می‌شوند و سپس هر یک از N_q خروجی با هزینه $\mathcal{O}(d_h d_v)$ به دست می‌آید. با جمع بر روی H سر و با $H d_v = d$ هزینه کل لایه برابر است با:

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده

$$\mathcal{O}((N_q + N_k)d_h d), d_h = d/H \quad (\text{پ-۴})$$

که برخلاف توجه کامل با هزینه $\mathcal{O}(N_q N_k d)$ ، نسبت به طول دنباله‌ها خطی است. مقایسه دقیق‌تر با شمارش عملیات ضرب-جمع نشان می‌دهد توجه کامل به $2N_q N_k d$ و توجه خطی به $(N_q + N_k)d_h d$ عملیات نیاز دارد؛ بنابراین شرط سودمندی، همان شرط سربه‌سری $N_q N_k > \frac{1}{2}(N_q + N_k)d_h$ است. توجه شود که با کوچک شدن طول دنباله‌ها این نامساوی نقض می‌شود و توجه کامل ارزان‌تر خواهد بود؛ این نتیجه با شهود «توجه خطی همیشه سریع‌تر است» در تضاد است و در طراحی معماری فصل چهارم صریحاً لحاظ شده‌است.

در پایان، دو نکته درباره خوش‌رفتاری عددی. نخست، $\phi(x) = \text{elu}(x) + 1$ اکیداً مثبت است (برای $x < 0$ برابر $e^x > 0$ و برای $x \geq 0$ برابر $x + 1 \geq 1$)؛ در نتیجه u بردار اکیداً مثبت است و مخرج $\phi(q_i)^T u$ همواره مثبت می‌ماند، پس وزن‌های ضمنی توجه نامنفی و نرمال شده باقی می‌مانند و تفسیر «میانگین محدب مقدارها» حفظ می‌شود [۱۸]. دوم، جمع S شامل N_k جمله مثبت است و برای N_k بزرگ می‌تواند از بازه دقت نیم‌شناور فراتر رود؛ در پیاده‌سازی این پژوهش به جای جمع، میانگین به کار می‌رود (S و u هر دو بر N_k تقسیم می‌شوند) که در کسر حذف می‌شود و عملگر را تغییر نمی‌دهد، اما انباشتگر را در مقیاس واحد نگه می‌دارد و آموزش با دقت آمیخته را پایدار می‌کند.

پیوست ب: پیکربندی حسگرها در شبیه‌ساز

پیکربندی حسگرهای به‌کاررفته در جمع‌آوری داده و ارزیابی، مطابق استاندارد جدول رده‌بندی CARLA، در جدول پ-۱ ارائه شده‌است. سه دوربین با میدان دید 60° درجه و زاویه سمت -55° ، 0° و $+55^\circ$ نصب شده‌اند؛ بنابراین پوشش زاویه‌ای پیوسته و با هم‌پوشانی 5° درجه در هر مرز است. هر دوربین 320 ستون پیکسل تولید می‌کند (1875×0.1875 درجه بر پیکسل) و پس از برش هم‌پوشانی، نواری با $704 \times 0.1875 \approx 132$ ستون باقی می‌ماند که معادل میدان دید مؤثر 132 درجه است. باید توجه داشت که الحاق مسطح سه تصویر تخت، یک تقریب از تصویر پانورامای واقعی است و در مرزها اعوجاج جزئی ایجاد می‌کند؛ این همان راهکاری است که در [۱۱] نیز به کار رفته و شبکه در عمل با آن سازگار می‌شود.

جدول پ-۱: پیکربندی حسگرها در شبیه‌ساز CARLA.

حسگر	مشخصات	محل نصب (Z, X) متر
دوربین جلو	RGB، ۱۶۰×۳۲۰، میدان دید ۶۰°، سمت ۰°	(۲,۳, ۱,۳)
دوربین چپ/راست	RGB، ۱۶۰×۳۲۰، میدان دید ۶۰°، سمت ۶۰°±	(۲,۳, ۱,۳)
نوار الحاقی	۱۶۰×۷۰۴، میدان دید مؤثر ۱۳۲°	—
دوربین عمق	هم‌موضع با هر دوربین RGB (فقط در جمع‌آوری داده)	(۲,۳, ۱,۳)
لیدار	۶۴ خط، برد ۸۵ متر، ۱۰ هرتز، ۶۰۰ هزار نقطه بر ثانیه	(۲,۵, ۰,۰)
سرعت‌سنج و IMU	نرخ ۱۰ هرتز (هم‌گام با گام شبیه‌ساز)	—
GNSS	نویز گوسی ۰,۵ σ متر	—

نکته‌ای عملی که برای بازتولید این کار ضروری است: شبیه‌ساز در اجراهای چند ساعته پایدار نمی‌ماند. جمع‌آوری هر مسیر ده‌ها بازیگر (خودروهای ترافیک، عابران پیاده و نه حسگر) می‌سازد و نابود می‌کند، و انباشت حافظه ناشی از این چرخه، فرایند سرور را پس از چند ساعت با خطای قطعه‌بندی حافظه از کار می‌اندازد؛ در جمع‌آوری این پژوهش، سه نمونه از چهار نمونه موازی پس از سه تا شش ساعت به این شکل متوقف شدند. این رفتار با احتیاط در سمت کلاینت قابل پیشگیری نیست، بنابراین فرایند جمع‌آوری زیر نظر یک ناظر بیرونی اجرا شد که سه وظیفه دارد: بازیافت پیشگیرانه نمونه شبیه‌ساز پس از هر پانزده مسیر (پیش از آنکه انباشت حافظه به آستانه سقوط برسد)، بازسازی خودکار نمونه در صورت توقف، و از سرگیری جمع‌آوری از نخستین شماره مسیر استفاده نشده. نکته آخر اهمیت ویژه دارد، زیرا شرایط جوی هر مسیر از باقیمانده شماره آن بر تعداد شرایط تعیین می‌شود و از سرگیری با شماره نادرست، چرخه چهارده‌گانه جوی را بر هم می‌زند.

پیوست ج: راستی‌آزمایی پیاده‌سازی

در یک سامانه انتها-به-انتها، دسته‌ای از خطاها وجود دارد که بدون هیچ پیام خطایی اجرا می‌شوند، عددی کاملاً موجه تولید می‌کنند و تنها در رفتار نهایی سامانه بروز می‌کنند. خطاهای قرارداد مختصات،

نوید رزاقی، «بهبود عملکرد و استواری سامانه‌های رانندگی خودران انتها-به-انتها با استفاده از یادگیری چندوجهی و ترکیب بهینه اطلاعات سنسورهای ناهمگون»، پایان‌نامه کارشناسی‌ارشد، استاد راهنما: دکتر بابک خلیج، دانشگاه صنعتی شریف، دانشکده مهندسی برق، تیر ۱۴۰۵.

واحد و چیدمان حسگر همگی از این دسته‌اند. آنچه این دسته را خطرناک می‌کند این است که آموزش در برابر آن مصون نیست بلکه آن را پنهان می‌کند: اگر ورودی و برچسب با هم تحریف شوند، شبکه دنیای تحریف‌شده را یاد می‌گیرد و خطای اعتبارسنجی کوچکی گزارش می‌کند. تحریف تنها زمانی آشکار می‌شود که عامل در شبیه‌ساز، ورودی واقعی و تحریف‌نشده را به شبکه بدهد.

راستی‌آزمایی معمول در برابر این دسته ناتوان است، زیرا هر مسیر را در برابر معکوس خودش می‌آزماید و معکوس همان اشتباه را حمل می‌کند. اصل روشی که در این پژوهش به کار رفت این است که هر قرارداد به مرجعی بیرون از هر دو مسیر کد لنگر انداخته شود. سه گونه چنین مرجعی به کار رفت:

نشانه فیزیکی. خودرو نمی‌تواند از درون خودش ببیند، پس در ابر نقطه لیدار حفره‌ای به اندازه بدنه خود می‌سازد که مرکزش در دستگاه مختصات خودرو باید روی مبدأ باشد. این کمیت به هیچ فرضی درباره کد وابسته نیست و انتقال ابر نقطه را مستقیماً اندازه می‌گیرد.

توافق بین‌وجهی. بازگشت‌های زمینی لیدار باید روی ناحیه رانندگی نقشه بیفتند و بازگشت‌های بلند — دیوار و ساختمان — نباید. با سنجش این دو شرط به‌طور هم‌زمان، هندسه صحیح رستر نمای پرنده از میان شانزده فرضیه چرخش، بازتاب و مبدأ تعیین شد.

هم‌ارزی عددی. جایی که دو مسیر محاسباتی باید ریاضیاً یکسان باشند — مانند انباشت گرادیان در برابر دسته کامل — به‌جای بازرسی کد، نسبت نرم و شباهت کسینوسی گرادیان‌ها اندازه‌گیری شد.

یک نکته درباره خود سنج‌ها نیز آموختنی بود و ثبت آن می‌تواند برای پژوهش‌های بعدی مفید باشد: پیش از باور کردن نتیجه یک آزمون، باید نشان داد که آن آزمون توان تفکیک دارد. در راستی‌آزمایی بازتاب آینه‌ای، نخستین سنج انتخابی هم‌پوشانی ناحیه رانندگی با بازگشت‌های زمینی بود که نتیجه‌ای بی‌معنا داد، زیرا در جاده مستقیم هر دو کمیت حول محور حرکت متقارن‌اند و بازتاب تقریباً چیزی را تغییر نمی‌دهد. سنج معتبر باید خود نامتقارن باشد؛ هم‌بستگی میان سمت انحنای جاده و سمت حرکت مسیر، علامت خود را تحت بازتاب سازگار حفظ می‌کند و تحت بازتاب نا سازگار دقیقاً وارونه می‌شود، و همین وارونگی دقیق، شاهد قاطع است.

هر یک از این آزمون‌ها به‌صورت ابزار اجرایی در مخزن کد پژوهش نگهداری می‌شود تا پیش از هر اجرای آموزشی قابل تکرار باشد، و نه به‌صورت بازرسی یک‌باره.

پیوست د: نتایج تفکیکی مسیرهای ارزیابی

اعتبار سنجی زنجیره ارزیابی در برابر عامل ممتاز مرجع در بخش ۵.۲ گزارش شده است. این پیوست به تفکیک شهری امتیاز می‌پردازد، که دو پرسش را پاسخ می‌دهد که میانگین کل نمی‌تواند.

پرسش نخست، شکاف تعمیم است. چنان‌که در بخش ۵.۱ آمد، شهر Town05 از آموزش کنار گذاشته شده در حالی که شش مسیر از سی‌وشش مسیر محک در همان شهر قرار دارند. فاصله امتیاز این شش مسیر با میانگین سی مسیر دیگر، مستقیماً اندازه می‌گیرد که چه سهمی از عملکرد به حفظ کردن هندسه شهرهای دیده‌شده وابسته است. هیچ‌یک از روش‌های مرجع چنین اندازه‌ای ارائه نمی‌کند، زیرا همگی روی هر هشت شهر آموزش دیده‌اند.

پرسش دوم، نظام‌مند بودن اختلاف میان دو پیکربندی روش پیشنهادی است. جدول پ-۲ امتیاز رانندگی را به تفکیک شهرهای مجموعه Longest6 برای دو پیکربندی روش پیشنهادی گزارش می‌کند: خوانش میانگین‌گیری با شبکه بازگشتی، و خوانش پرسش‌محور بخش ۴.۵. هر دو در یک زنجیره، روی یک مجموعه داده و با یک بذر آموزش دیده‌اند و تنها در همان یک مؤلفه تفاوت دارند، بنابراین اختلاف ستون‌ها را می‌توان به آن مؤلفه نسبت داد. تفکیک شهری برای روش‌های مرجع در دسترس نیست، زیرا چنان‌که در بخش ۵.۳ گفته شد آن‌ها در این پژوهش اجرا نشده‌اند و مقالاتشان تنها میانگین کل را گزارش می‌کنند؛ به همین دلیل آزمون زوجی این پیوست میان دو پیکربندی روش پیشنهادی بسته می‌شود و نه در برابر یک خط‌مبنای بیرونی.

جدول پ-۲: امتیاز رانندگی به تفکیک شهر (میانگین سه اجرا).

شهر	تعداد مسیر	خوانش میانگین	خوانش پرسش‌محور	اختلاف	انحراف معیار
Town01	۶	—	—	—	—
Town02	۶	—	—	—	—
Town03	۶	—	—	—	—
Town04	۶	—	—	—	—
Town05	۶	—	—	—	—
Town06	۶	—	—	—	—

دو پرسش از این تفکیک پاسخ می‌گیرد. نخست، شکاف تعمیم: Town05 در آموزش دیده نشده‌است، و فاصله امتیاز آن با میانگین پنج شهر دیده‌شده نشان می‌دهد چه سهمی از عملکرد به حفظ کردن هندسه شهرهای آموزشی وابسته است و چه سهمی به تعمیم. دوم، نظام‌مند بودن اختلاف دو خوانش: آزمون t زوجی روی شش اختلاف شهری، توان آماری بسیار بیشتری از مقایسه میانگین‌های کل دارد، زیرا واریانس ناشی از دشواری متفاوت شهرها را حذف می‌کند. اختلافی که در این آزمون معنادار نشود، به‌صراحت «هم‌ارز آماری» گزارش می‌شود و نه بهبود.

Improving the Performance and Robustness of End-to-End Autonomous Driving Systems via Multimodal Learning and Optimal Fusion of Heterogeneous Sensor Information

Abstract

The design paradigm of autonomous driving systems has recently shifted from traditional modular pipelines toward end-to-end learning architectures that map raw sensor data directly to control outputs and are optimized globally for the final driving objective. However, the reliance of many such systems on a single data source, typically a monocular camera, severely degrades their robustness in adverse weather, low-light conditions, and rare long-tailed scenarios. This thesis addresses this limitation by improving the performance and robustness of end-to-end autonomous driving through multimodal learning and optimal fusion of heterogeneous sensor information, namely semantically rich camera images and geometrically precise LiDAR point clouds.

We propose EGCA, a novel transformer-based architecture with three key components: (i) a middle-fusion module built on bidirectional cross-attention that couples image tokens with LiDAR bird's-eye-view tokens; (ii) a kernel-based linear attention formulation that reduces the cost of the attention operator from quadratic to linear in the number of tokens, together with an explicit break-even condition identifying the token-resolution regime in which this substitution actually pays off; and (iii) a learnable sensor-reliability gate, trained jointly with a modality-level sensor-dropout strategy, that dynamically re-weights each modality according to its instantaneous quality. The policy is trained by imitation learning from a privileged expert in the CARLA simulator with auxiliary bird's-eye-view segmentation and depth supervision, weighted by homoscedastic task uncertainty.

Closed-loop evaluation on the Longest6 benchmark shows that the proposed method achieves a driving score of 55.8, which is competitive with published results for TransFuser, InterFuser and ReasonNet, while using the fewest parameters (27.9 M at inference) among the multimodal baselines and running in 14.8 ms per frame on an A100. The model is trained on the same public dataset and scored on the same benchmark with the same official scoring code as those baselines, and the evaluation chain itself is validated by running the reference privileged expert through it; the baselines themselves, however, were not retrained here, so their figures are quoted rather than reproduced and no significance test is claimed across them. Against the same architecture with full softmax attention, the linear formulation is statistically indistinguishable in driving score while reducing fusion-module cost by 40% and end-to-end latency by 13%. Under out-of-distribution heavy rain at night, the relative degradation of the proposed model is

15.9% versus 27.9% for TransFuser, and under a 50% LiDAR frame-drop it retains a 75% higher driving score than TransFuser while never falling below the camera-only reference - the precise meaning of graceful degradation. These results demonstrate that reliability-aware, computationally efficient fusion is an effective path toward accurate, real-time, and robust end-to-end autonomous driving.

Keywords

Autonomous Driving, End-to-End Learning, Multimodal Learning, Sensor Fusion, Transformer, Cross-Attention, Robustness

**Sharif University of Technology
Department of Electrical Engineering**

**MSc Thesis
Area: Communication Systems**

**Improving the Performance and Robustness of End-to-End
Autonomous Driving Systems via Multimodal Learning and
Optimal Fusion of Heterogeneous Sensor Information**

**By:
Navid Razaghi**

**Advisor:
Dr. Babak Khalaj**

July 2026